

UNIVERSIDADE FEDERAL DO ABC
BACHARELADO EM CIÊNCIA DA COMPUTAÇÃO

VINICIUS SEDRIM

IRIDOLOGIA SOB LENTES CIENTÍFICAS:

avaliação crítica com aprendizado de máquina

Santo André

2026

VINICIUS SEDRIM

IRIDOLOGIA SOB LENTES CIENTÍFICAS:

avaliação crítica com aprendizado de máquina

Relatório parcial apresentado à disciplina Projeto de Graduação em Computação II do curso de Bacharelado em Ciência da Computação da Universidade Federal do ABC, referente à etapa de realce da vascularização da íris por algoritmos consolidados e de validação geométrica da pupila em fotografias RGB.

Orientador: Vladimir Emiliano Moreira Rocha

Santo André

2026

RESUMO

Este relatório apresenta a segunda etapa (PGC II) de um projeto que investiga, sob perspectiva médica e não iridológica, se correlatos de biomarcadores oculares do diabetes mellitus tipo 2 (DM2) podem ser extraídos de fotografias convencionais da íris. A etapa executa o estudo de viabilidade previsto no projeto em duas frentes: o realce da vascularização da íris e a validação geométrica da pupila. Na primeira frente, o pré-processamento da cadeia de análise, antes restrito a ajustes de brilho, de contraste e de equalização de histograma, recebe três algoritmos consolidados de realce de estruturas finas: o filtro de *vesselness* de Frangi, um banco de filtros de Gabor orientados e a morfologia *top-hat/black-hat* multiescala. O trabalho demonstra que transformações pontuais crescentes, como brilho e contraste, não alteram medidas de separabilidade baseadas em ordenação ou em partições de Otsu, exceto por efeitos de saturação, o que justifica o emprego de operadores com modelo de forma. A avaliação combina a razão contraste-ruído (CNR) medida no anel da íris, uma análise por setores angulares com teste de Wilcoxon e intervalos *bootstrap*, um fantoma sintético com verdade de referência e análises de sensibilidade, de robustez e de custo computacional. Nas duas fotografias públicas analisadas, o filtro de Frangi eleva a CNR de 3,49 para 8,24 e de 3,62 para 7,29 em relação à melhor linha de base (razões de 2,36 e 2,02) e supera essa linha de base em todos os 24 setores ($p < 0,001$). No fantoma, o filtro de Frangi alcança a maior área sob a curva ROC (AUC) com ruído baixo (0,919), mas degrada com o aumento do ruído, ao passo que o banco de Gabor mantém a AUC entre 0,81 e 0,90 em todos os níveis testados. Na segunda frente, um validador classifica a geometria pupila-íris a partir da razão entre os raios, da espessura relativa do anel e da excentricidade, com faixas derivadas de valores fisiológicos publicados; na fotografia avaliada, a razão é 0,40 e o rótulo atribuído é válido. A análise de estabilidade indica que a detecção do limbo por transformada de Hough constitui a etapa mais vulnerável da cadeia, pois recorre à estimativa de reserva em 8 de 15 condições. Um único *script* reproduz todos os resultados, e o relatório discute explicitamente as limitações do estudo, entre elas o uso de duas imagens ilustrativas, a indisponibilidade do conjunto rotulado nesta etapa e o emprego de fotografias RGB em lugar de AS-OCTA.

Palavras-chave: diabetes mellitus tipo 2; íris; realce de vascularização; filtro de Frangi; validação da pupila; visão computacional.

ABSTRACT

This report presents the second stage (PGC II) of a project that investigates, from a medical rather than an iridological perspective, whether correlates of ocular biomarkers of type 2 diabetes mellitus (T2DM) can be extracted from conventional iris photographs. The stage carries out the feasibility study planned in the project along two lines: enhancement of the iris vasculature and geometric validation of the pupil. In the first line, the preprocessing stage of the analysis pipeline, previously limited to brightness, contrast and histogram equalization adjustments, is extended with three established algorithms for thin-structure enhancement: the Frangi vesselness filter, a bank of oriented Gabor filters and multiscale top-hat/black-hat morphology. The report shows that increasing point transformations, such as brightness and contrast, do not change separability measures based on ranking or on Otsu partitions, except for saturation effects, which justifies the use of shape-aware operators. The evaluation combines the contrast-to-noise ratio (CNR) measured in the iris annulus, an angular sector analysis with the Wilcoxon test and bootstrap intervals, a synthetic phantom with ground truth, and sensitivity, robustness and computational cost analyses. In the two public photographs analyzed, the Frangi filter raises the CNR from 3.49 to 8.24 and from 3.62 to 7.29 relative to the best baseline (ratios of 2.36 and 2.02) and outperforms that baseline in all 24 sectors ($p < 0.001$). In the phantom, the Frangi filter reaches the highest area under the ROC curve (AUC) at low noise (0.919) but degrades as noise increases, whereas the Gabor bank keeps the AUC between 0.81 and 0.90 at all tested levels. In the second line, a validator classifies the pupil–iris geometry from the radius ratio, the relative annulus thickness and the eccentricity, with ranges derived from published physiological values; in the evaluated photograph, the ratio is 0.40 and the assigned label is valid. The stability analysis shows that limbus detection by the Hough transform is the most vulnerable step of the chain, as it falls back to the default estimate in 8 of 15 conditions. A single script reproduces all results, and the report explicitly discusses the limitations of the study, including the use of two illustrative images, the unavailability of the labeled dataset at this stage and the use of RGB photographs instead of AS-OCTA.

Keywords: type 2 diabetes mellitus; iris; vasculature enhancement; Frangi filter; pupil validation; computer vision.

LISTA DE FIGURAS

Figura 1 – Visão geral da cadeia de análise implementada	27
Figura 2 – Canal verde do olho completo antes e depois da CLAHE, com os histogramas no disco da íris	29
Figura 3 – Banco de filtros de Gabor utilizado no realce	30
Figura 4 – Anel de medida e setores angulares no olho completo	31
Figura 5 – CNR no anel da íris por método nas duas imagens (E0)	37
Figura 6 – Histogramas de estrutura e de fundo no anel do olho completo para o contraste $\times 1,8$ e para o filtro de Frangi (E0)	37
Figura 7 – Comparação visual entre o canal original, as linhas de base e os realces no olho completo (E0)	38
Figura 8 – Comparação visual entre o canal original, as linhas de base e os realces na macro da íris (E0)	39
Figura 9 – Detalhe ampliado de um trecho de 124×124 pixels do estroma da macro da íris (E0)	39
Figura 10 – Distribuição da CNR por setor angular para cada método (E1)	40
Figura 11 – Perfil angular da CNR para a melhor linha de base, o filtro de Frangi e o banco de Gabor (E1)	41
Figura 12 – Respostas do filtro de Frangi por escala, saída multiescala e escala dominante na macro da íris (E3)	43
Figura 13 – Trecho do mapa de Frangi sem perturbação e sob correção gama, ruído gaussiano e desfoque (E5)	46
Figura 14 – Fantoma sintético com ruído $\sigma_n = 12$, verdade de referência e mapas de realce (E6)	47
Figura 15 – AUC por pixel em função do desvio-padrão do ruído no fantoma (E6)	48
Figura 16 – Curvas ROC agregadas no fantoma com $\sigma_n = 12$ (E6)	49
Figura 17 – Anel do olho completo desdobrado pela normalização <i>rubber sheet</i> : canal verde com CLAHE e mapa de Frangi (E8)	50
Figura 18 – Fração de pixels de estrutura do mapa de Frangi em função do raio normalizado (E8)	51
Figura 19 – Validação da pupila na fotografia do olho completo (E9)	52
Figura 20 – Pontuação do validador em função da razão pupila/íris, com pupila centrada (E9)	53
Figura 21 – Regiões de decisão do validador no plano (ρ, ϵ) (E9)	53

LISTA DE QUADROS

Quadro 1 – Padrões locais de intensidade em duas dimensões segundo os autovalores da matriz hessiana	20
Quadro 2 – Síntese dos trabalhos relacionados e de sua relação com este relatório . . .	26
Quadro 3 – Configuração padrão do pré-processamento, dos realces e da métrica	29
Quadro 4 – Faixas do validador geométrico e sua origem	33
Quadro 5 – Experimentos realizados, perguntas a que respondem e medidas empregadas	33
Quadro 6 – Ambiente de execução dos experimentos	67
Quadro 7 – Arquivos gerados por experimento no diretório docs/PGC_2	68
Quadro 8 – Configuração completa utilizada neste relatório	69

LISTA DE ALGORITMOS

Algoritmo 1 – Detecção da pupila e do limbo	30
Algoritmo 2 – Validação geométrica da pupila	32

LISTA DE TABELAS

Tabela 1 – Visibilidade das estruturas no anel da íris (E0)	36
Tabela 2 – Comparação por setores angulares de 30° (E1)	40
Tabela 3 – CNR com o limiar de Otsu calculado sobre o mapa inteiro e restrito ao anel da íris (E2)	42
Tabela 4 – Decomposição por escala da resposta do filtro de Frangi (E3)	42
Tabela 5 – Efeito da normalização de saída sobre a CNR do mapa de Frangi (E3) . . .	43
Tabela 6 – Sensibilidade da CNR aos parâmetros de cada realce (E4)	44
Tabela 7 – CNR no anel por canal de entrada (E10)	45
Tabela 8 – Concorância entre os mapas sem e com perturbação (E5)	46
Tabela 9 – Medidas no fantoma com ruído $\sigma_n = 12$ (E6)	48
Tabela 10 – Tempo de execução por etapa (E7)	50
Tabela 11 – Classificação do validador em casos sintéticos (E9)	52
Tabela 12 – Estabilidade da detecção e da validação em 15 condições (E9)	54

LISTA DE ABREVIATURAS E SIGLAS

AS-OCTA	Angiografia por tomografia de coerência óptica do segmento anterior (do inglês <i>anterior segment optical coherence tomography angiography</i>)
AUC	Área sob a curva ROC (do inglês <i>area under the curve</i>)
CLAHE	Equalização adaptativa de histograma com limitação de contraste (do inglês <i>contrast limited adaptive histogram equalization</i>)
CNR	Razão contraste-ruído (do inglês <i>contrast-to-noise ratio</i>)
DM2	Diabetes mellitus tipo 2
IC	Intervalo de confiança
JPEG	Formato de compressão de imagens do <i>Joint Photographic Experts Group</i>
OCT	Tomografia de coerência óptica (do inglês <i>optical coherence tomography</i>)
PGC	Projeto de Graduação em Computação
RGB	Vermelho, verde e azul (do inglês <i>red, green, blue</i>)
ROC	Característica de operação do receptor (do inglês <i>receiver operating characteristic</i>)

LISTA DE SÍMBOLOS

Ω	Anel da íris, região em que as métricas são calculadas
r_p, r_i	Raios da pupila e da íris
D_p, D_i	Diâmetros da pupila e da íris
$\mathbf{c}_p, \mathbf{c}_i$	Centros da pupila e da íris
ρ	Razão entre os raios da pupila e da íris
τ	Espessura relativa do anel da íris
ϵ	Excentricidade entre os centros da pupila e da íris
σ	Desvio-padrão de núcleo gaussiano (escala do filtro de Frangi ou envoltória do filtro de Gabor)
σ_n	Desvio-padrão do ruído no fantoma sintético
H_σ	Matriz hessiana na escala σ
λ_1, λ_2	Autovalores da matriz hessiana
β, c	Parâmetros de seletividade e de sensibilidade do filtro de Frangi
V	Resposta de <i>vesselness</i> do filtro de Frangi
λ, θ, γ	Comprimento de onda, orientação e razão de aspecto do filtro de Gabor
E	Energia de cristas (variância do laplaciano)
H	Entropia de Shannon do histograma

SUMÁRIO

1	INTRODUÇÃO	12
2	PROBLEMA E QUESTÕES DE PESQUISA	14
2.1	CONTEXTO E MOTIVAÇÃO	14
2.2	PROBLEMA CENTRAL	14
2.3	QUESTÕES ESPECÍFICAS	14
3	OBJETIVOS	16
3.1	OBJETIVO GERAL	16
3.2	OBJETIVOS ESPECÍFICOS	16
4	FUNDAMENTAÇÃO TEÓRICA	17
4.1	A ÍRIS, SUA VASCULATURA E O REGISTRO FOTOGRÁFICO	17
4.2	PUPILA, ESPESSURA DA ÍRIS E DISAUTONOMIA	17
4.3	LIMITAÇÕES DOS AJUSTES DE BRILHO E DE CONTRASTE	18
4.4	ESPAÇO DE ESCALAS E MATRIZ HESSIANA	19
4.5	FILTRO DE <i>VESSELNESS</i> DE FRANGI	20
4.6	FILTROS DE GABOR	21
4.7	MORFOLOGIA MATEMÁTICA: <i>TOP-HAT</i> E <i>BLACK-HAT</i>	21
4.8	CLAHE E ESCOLHA DO CANAL DE COR	22
4.9	MÉTRICAS DE AVALIAÇÃO	22
4.9.1	Razão contraste-ruído	22
4.9.2	Energia de cristas e entropia	22
4.9.3	Curva ROC, AUC e coeficiente de Dice	22
4.9.4	Testes estatísticos	23
4.10	DETECÇÃO DA PUPILA E DO LIMBO	23
5	TRABALHOS RELACIONADOS	24
5.1	REALCE E SEGMENTAÇÃO DE VASOS EM RETINOGRÁFIAS	24
5.2	FILTROS HESSIANOS	24
5.3	VASCULATURA DA ÍRIS E PUPILA NO DM2	25
5.4	ÍRIS, APRENDIZADO DE MÁQUINA E VIÉS	25
6	METODOLOGIA	27
6.1	VISÃO GERAL	27
6.2	DADOS	27
6.3	PRÉ-PROCESSAMENTO E REALCES	28

6.4	DETECÇÃO DA PUPILA E DO LIMBO E REGIÃO DE MEDIDA	28
6.5	MÉTRICAS E LINHAS DE BASE	31
6.6	VALIDADOR GEOMÉTRICO DA PUPILA	31
6.7	DESENHO EXPERIMENTAL	32
6.7.1	Análise por setores angulares (E1)	34
6.7.2	Fantoma sintético (E6)	34
6.7.3	Perturbações (E5 e E9)	34
6.7.4	Demais experimentos	35
6.8	REPRODUTIBILIDADE E TESTES	35
6.9	ASPECTOS ÉTICOS E LICENÇAS	35
7	RESULTADOS	36
7.1	COMPARAÇÃO PRINCIPAL (E0)	36
7.2	CONSISTÊNCIA POR SETORES ANGULARES (E1)	38
7.3	DEFINIÇÃO DO LIMAR DA MÉTRICA (E2)	41
7.4	ESCALAS E NORMALIZAÇÃO DO FILTRO DE FRANGI (E3)	42
7.5	SENSIBILIDADE A PARÂMETROS (E4)	44
7.6	ESCOLHA DO CANAL DE COR (E10)	45
7.7	ROBUSTEZ A PERTURBAÇÕES (E5)	46
7.8	FANTOMA COM VERDADE DE REFERÊNCIA (E6)	47
7.9	CUSTO COMPUTACIONAL (E7)	49
7.10	NORMALIZAÇÃO POLAR E PERFIL RADIAL (E8)	50
7.11	VALIDAÇÃO DA PUPILA (E9)	51
7.11.1	Fotografia do olho completo	51
7.11.2	Casos sintéticos	52
7.11.3	Estabilidade da detecção e da validação	54
8	DISCUSSÃO	56
8.1	RESPOSTAS ÀS QUESTÕES DE PESQUISA	56
8.2	IMPLICAÇÕES PARA A CADEIA DE ANÁLISE	57
8.3	LIMITAÇÕES E AMEAÇAS À VALIDADE	57
9	CONCLUSÃO E TRABALHOS FUTUROS	59
	REFERÊNCIAS	61
	APÊNDICE A – REPRODUTIBILIDADE	67
	APÊNDICE B – CONFIGURAÇÃO COMPLETA	69

1 INTRODUÇÃO

A íris abriga uma microvasculatura e uma musculatura (esfíncter e dilatador) que controlam o diâmetro pupilar e que podem refletir repercussões sistêmicas do diabetes mellitus tipo 2 (DM2). No PGC I, o projeto foi reorientado da moldura iridológica, que não se sustenta quando avaliada sob protocolos controlados (Ernst, 2000; Simon; Worthen; Mitas, 1979), para a investigação de biomarcadores oculares reconhecidos pela literatura médica: a vascularização da íris, quantificada por angiografia por tomografia de coerência óptica do segmento anterior (AS-OCTA) (Roberts; Goldstein; Fawzi, 2017; Zett et al., 2018; Zhou et al., 2025), e o diâmetro pupilar e a espessura iridiana, associados à neuropatia autonômica (Cui et al., 2024; Thakar et al., 2025). A metodologia aprovada previa, antes das extensões de modelagem, um estudo de viabilidade destinado a verificar se correlatos dessas grandezas podem ser extraídos de fotografias RGB convencionais, tipo de imagem considerado pelo projeto.

Este relatório documenta a execução desse estudo de viabilidade em duas frentes, definidas como metas desta etapa com base nas orientações recebidas ao término do PGC I. A primeira frente corresponde ao **realce da vascularização**. O pré-processamento da cadeia de análise (*pipeline*) dispunha apenas de ajustes de brilho e de contraste e de equalização de histograma, operadores que reescalam intensidades sem modelar as estruturas finas do estroma. A meta consistiu em incorporar dois ou três algoritmos consolidados na literatura de visão computacional e de imagem médica e em verificar, por critérios objetivos, se tais algoritmos evidenciam melhor essas estruturas. A segunda frente corresponde à **validação da pupila**: antes da extração de descritores, cada imagem deve ter a geometria pupila-íris verificada a partir do diâmetro da pupila e da espessura da íris, de modo que segmentações implausíveis não contaminem as etapas subsequentes.

As contribuições desta etapa são as seguintes:

- a) implementação, na classe `VascularizationEnhancer` da cadeia de análise, de três realces consolidados, a saber, o filtro de *vesselness* proposto por Frangi et al. (1998), um banco de filtros de Gabor orientados (Daugman, 1985; Jain; Farrokhnia, 1991) e a morfologia *top-hat/black-hat* multiescala (Soille, 2004), todos com pré-processamento comum baseado no canal verde e na CLAHE;
- b) formulação de um argumento formal, confirmado experimentalmente, de que transformações pontuais crescentes, como brilho e contraste, não aumentam a separabilidade entre estruturas e fundo, salvo por efeitos de saturação (Seção 4.3);
- c) definição de um protocolo de avaliação com onze experimentos (E0 a E10), que abrange comparação principal, análise por setores angulares com teste de Wilcoxon e intervalos *bootstrap*, definição do limiar da métrica, análise de escalas, sensibilidade

a parâmetros, robustez a perturbações, fantoma sintético com verdade de referência, custo computacional, normalização polar e escolha do canal de cor;

- d) implementação de um validador geométrico da pupila (*PupilValidator*), com faixas derivadas de valores fisiológicos publicados, pontuação de qualidade e motivos legíveis, avaliado em casos sintéticos, em um mapa de decisão e sob variações de aquisição;
- e) garantia de reprodutibilidade, uma vez que todas as figuras e tabelas de resultados são geradas pelo *script* `experiments/report_experiments.py` e que o comportamento dos componentes novos é verificado por testes automatizados.

O restante do relatório organiza-se da seguinte forma. A Seção 2 apresenta o problema e as questões desta etapa, e a Seção 3, os objetivos. A Seção 4 reúne a fundamentação teórica, com ênfase nos operadores de realce, nas métricas e na detecção da pupila, e a Seção 5 discute os trabalhos relacionados. A Seção 6 descreve a metodologia e o desenho experimental; a Seção 7 apresenta os resultados; a Seção 8 discute os achados e as limitações; e a Seção 9 apresenta a conclusão e os trabalhos futuros. Os apêndices documentam o ambiente de execução e a configuração completa.

2 PROBLEMA E QUESTÕES DE PESQUISA

2.1 CONTEXTO E MOTIVAÇÃO

Fotografias RGB da íris não oferecem a resolução nem o contraste vascular da AS-OCTA ou da angiofluoresceinografia (Zett et al., 2018). Nelas se observa a superfície anterior do estroma, composta por trabéculas, fibras radiais, criptas e, em parte, vasos, elementos que não se distinguem entre si apenas pela aparência. Qualquer correlato de vascularização extraído dessas imagens constitui, portanto, um correlato de *estruturas finas e alongadas*, e sua medida exige cuidado para que o realce não seja confundido com um simples reescalonamento de intensidades. Os ajustes de brilho e de contraste apresentam, nesse aspecto, uma limitação intrínseca: aplicam a mesma função a todos os pixels, sem considerar a vizinhança, e por isso não separam uma fibra de um trecho de fundo que apresente a mesma intensidade em outra posição da imagem.

A geometria pupila-íris é, simultaneamente, um biomarcador candidato (o diâmetro pupilar relativo) e um requisito de qualidade. A normalização *rubber sheet* (Daugman, 2004) e todos os descritores calculados sobre o anel da íris dependem dos círculos estimados para a pupila e para o limbo. Uma pupila segmentada de forma incorreta desloca o anel, incorpora esclera, pálpebra ou cílios ao estroma e introduz uma variação sem relação com o DM2. Esse tipo de erro é particularmente relevante em estudos com aprendizado de máquina, nos quais artefatos de aquisição podem ser aprendidos como se fossem sinal (Zech et al., 2018).

2.2 PROBLEMA CENTRAL

Esta etapa responde ao seguinte problema: *é possível, com algoritmos consolidados e métricas objetivas, evidenciar as estruturas finas do estroma da íris em fotografias RGB de forma mensuravelmente superior a ajustes de brilho e de contraste, e validar automaticamente a geometria pupila-íris com critérios fisiológicos interpretáveis?*

2.3 QUESTÕES ESPECÍFICAS

Do problema central decorrem as seguintes questões específicas, retomadas na Seção 8.1:

- a) Q1, realce *versus* reescalonamento: verificar se os realces de Frangi, de Gabor e morfológico aumentam a separação entre estruturas e fundo no anel da íris em relação à melhor linha de base (brilho, contraste ou CLAHE) e se o ganho se mantém de forma consistente entre regiões angulares da íris;
- b) Q2, validade da métrica: verificar se a CNR calculada com limiar de Otsu, que dispensa verdade de referência, ordena os métodos de forma compatível com uma avaliação em que a verdade é conhecida;

- c) Q3, sensibilidade, robustez e custo: determinar o grau de dependência dos resultados em relação aos parâmetros e a perturbações fotométricas, bem como o custo computacional de cada realce;
- d) Q4, validação geométrica: verificar se o validador separa geometrias plausíveis de implausíveis e se a cadeia de detecção e validação permanece estável sob variações de escala, de orientação e de fotometria;
- e) Q5, limites: delimitar o que pode e o que não pode ser concluído a partir destes experimentos, considerando os dados disponíveis nesta etapa.

3 OBJETIVOS

3.1 OBJETIVO GERAL

Implementar e avaliar, de forma reprodutível, algoritmos consolidados de realce da vascularização da íris e um validador da geometria pupila-íris, como parte do estudo de viabilidade de correlatos de biomarcadores oculares do DM2 em fotografias RGB.

3.2 OBJETIVOS ESPECÍFICOS

Para atingir o objetivo geral, definem-se os seguintes objetivos específicos:

- a) implementar os realces de Frangi, de Gabor e morfológico com pré-processamento comum e parâmetros configuráveis, integrados à cadeia de análise existente;
- b) definir uma região de medida, o anel da íris, e uma métrica objetiva de visibilidade das estruturas, bem como fundamentar a insuficiência dos ajustes de brilho e de contraste;
- c) comparar os realces com as linhas de base nas imagens reais, de forma global e por setores angulares, com teste estatístico pareado;
- d) verificar a métrica em um fantoma sintético com verdade de referência e caracterizar a sensibilidade a parâmetros, a robustez a perturbações e o custo computacional;
- e) implementar um validador da geometria pupila-íris com faixas derivadas de valores fisiológicos e avaliá-lo em casos sintéticos e sob variações de aquisição;
- f) assegurar a reprodutibilidade, por meio de *script* único, sementes fixas, versões registradas e testes automatizados, e documentar as limitações de forma explícita.

4 FUNDAMENTAÇÃO TEÓRICA

4.1 A ÍRIS, SUA VASCULATURA E O REGISTRO FOTOGRÁFICO

A íris é o diafragma do segmento anterior do olho, situada entre a córnea e o cristalino. O diâmetro da pupila é regulado por dois músculos antagonistas: o esfíncter, responsável pela constrição (miose), e o dilatador, responsável pela dilatação (midríase). A irrigação da íris provém do círculo arterial maior, situado em sua raiz, e de ramos radiais que convergem em direção à pupila. A superfície anterior exibe trabéculas, criptas, sulcos de contração e o colarete, faixa sinuosa que separa a zona pupilar, interna, da zona ciliar, externa.

Estudos com AS-OCTA demonstram redução da densidade vascular da íris em pacientes com DM2, inclusive na ausência de retinopatia diabética (Zhou et al., 2025). A mesma técnica permite identificar a vasculatura iridiana e estadiar a neovascularização da íris (Roberts; Goldstein; Fawzi, 2017) e foi comparada à angiofluoresceinografia na análise da vasculatura da íris (Zett et al., 2018). Métodos de aprendizado de máquina já são aplicados à análise quantitativa de angiografias da íris (Zhu et al., 2026). Essas modalidades, contudo, medem diretamente o fluxo ou o contraste vascular, o que uma fotografia RGB não permite.

Uma fotografia no espectro visível registra a luz refletida e espalhada pela superfície anterior da íris, e a visibilidade da trama do estroma depende da pigmentação. Por esse motivo, sistemas biométricos empregam iluminação no infravermelho próximo, que revela a textura mesmo em íris muito pigmentadas (Daugman, 2004). Em fotografias RGB, vasos, trabéculas e bordas de criptas aparecem como estruturas finas e alongadas, mais claras ou mais escuras que a vizinhança, e não podem ser separados apenas pela aparência. Neste relatório, o termo *vascularização* designa esse conjunto de estruturas finas realçadas, e não vasos confirmados. A relação entre tais estruturas e a densidade vascular medida por AS-OCTA permanece uma hipótese a ser testada com dados clínicos.

4.2 PUPILA, ESPESSURA DA ÍRIS E DISAUTONOMIA

Cui et al. (2024) relacionaram o fluxo sanguíneo da íris, a espessura iridiana e o diâmetro pupilar de diabéticos em repouso e após midríase farmacológica e observaram, em adultos com DM2, íris mais delgada na região do músculo dilatador e menor diâmetro pupilar. Thakar et al. (2025) reportaram, por pupilometria automatizada, diâmetros pupilares menores em diabéticos, correlacionados à espessura da camada de fibras nervosas da retina, e Surya et al. (2026) empregaram anormalidades pupilares como preditores de retinopatia diabética com aprendizado de máquina. Esses achados qualificam o diâmetro pupilar como biomarcador candidato que, em princípio, pode ser estimado a partir da segmentação pupila-íris.

Dois cuidados são necessários ao transpor essas grandezas para fotografias frontais. Em primeiro lugar, a espessura iridiana dos estudos clínicos é medida em corte, por tomografia do segmento anterior, na direção anteroposterior; em uma imagem frontal, mede-se a *largura radial do anel visível*, $r_i - r_p$, que depende principalmente do tamanho da pupila, e não da espessura do tecido. Neste relatório, a expressão “espessura da íris” refere-se sempre a essa largura radial, empregada como critério de qualidade geométrica. Em segundo lugar, distâncias em pixels dependem da câmera e da distância de aquisição; por essa razão, o validador opera com razões adimensionais.

Em condições de adaptação à luz, o diâmetro pupilar de adultos varia aproximadamente entre 2 e 8 mm (Watson; Yellott, 2012). O diâmetro corneano branco a branco, que corresponde aproximadamente ao diâmetro visível da íris, apresenta média de 11,71 mm em adultos saudáveis (Rüfer; Schröder; Erb, 2005). A razão pupila/íris esperada situa-se, portanto, entre $2/11,71 \approx 0,17$ e $8/11,71 \approx 0,68$, intervalo que fundamenta as faixas do validador (Seção 6.6).

4.3 LIMITAÇÕES DOS AJUSTES DE BRILHO E DE CONTRASTE

Ajustes de brilho e de contraste são *transformações pontuais*: cada pixel de intensidade r é substituído por $s = T(r)$, com a mesma função T em toda a imagem (Gonzalez; Woods, 2018). Nos experimentos, o brilho corresponde a $T(r) = r + b$ e o contraste a $T(r) = ar$, ambos seguidos de arredondamento e de saturação no intervalo $[0, 255]$. Para medir o quanto um mapa separa estruturas do fundo, emprega-se a razão contraste-ruído

$$\text{CNR} = \frac{\mu_{\text{fg}} - \mu_{\text{bg}}}{\sigma_{\text{bg}}}, \quad (1)$$

em que μ_{fg} e μ_{bg} são as médias dos pixels de estrutura e de fundo e σ_{bg} é o desvio-padrão do fundo. A partição exata adotada na cadeia de análise é descrita na Seção 6.5. A Proposição 1 formaliza a limitação das transformações pontuais.

Proposição 1. Sejam I uma imagem e T uma função estritamente crescente aplicada pixel a pixel, $I' = T \circ I$. Então:

- a) para qualquer rotulação binária dos pixels (estrutura ou fundo), a curva ROC e a área sob ela (AUC) obtidas com I' como escore são iguais às obtidas com I ;
- b) se $T(r) = ar + b$, com $a > 0$, e não há saturação, o limiar de Otsu de I' induz a mesma partição dos pixels que o limiar de Otsu de I , e a CNR da Equação (1) permanece inalterada.

Demonstração. Quanto ao item a, a curva ROC depende apenas da ordem dos escores: para cada limiar t aplicado a I , o limiar $T(t)$ aplicado a I' seleciona exatamente os mesmos pixels, pois T preserva a ordem e os empates. Quanto ao item b, o critério de Otsu (1979) escolhe o limiar que maximiza a variância entre classes, $\sigma_B^2(t) = \omega_0(t) \omega_1(t) [\mu_1(t) - \mu_0(t)]^2$. Para o limiar

correspondente $t' = at + b$, os pesos ω_0 e ω_1 não se alteram e as médias transformam-se como $\mu' = a\mu + b$, de modo que $\sigma_B'^2(t') = a^2 \sigma_B^2(t)$ e o máximo ocorre na mesma partição. Na CNR, o numerador $\mu_{fg} - \mu_{bg}$ e o denominador σ_{bg} são ambos multiplicados por a . $\square$

Em imagens de 8 bits, o arredondamento cria empates e a saturação em 0 ou 255 funde níveis distintos. Esses efeitos podem alterar ligeiramente as medidas, mas apenas removem informação. Decorre daí que nenhuma combinação de brilho e de contraste torna uma fibra mais separável do fundo em termos de ordenação; altera-se somente a aparência da imagem. Os experimentos confirmam esse comportamento (Seções 7.1 e 7.8). Ressalte-se que o item b não se estende a transformações crescentes não afins, como a correção gama, que preservam a AUC, mas podem alterar a CNR; esse fato exige atenção à normalização de saída de cada método (Seção 7.4).

A CLAHE (Pizer et al., 1987; Zuiderveld, 1994) não está sujeita à Proposição 1, pois a função aplicada depende da vizinhança do pixel. Ainda assim, ela não possui modelo de forma: amplifica igualmente fibras, ruído e bordas, limitada apenas pelo recorte do histograma local. A separação entre estruturas finas e fundo requer, portanto, operadores que considerem a geometria da vizinhança, como os três descritos a seguir.

4.4 ESPAÇO DE ESCALAS E MATRIZ HESSIANA

A teoria de espaço de escalas (Koenderink, 1984; Lindeberg, 1998) representa uma imagem I por uma família de versões suavizadas, $L(\mathbf{x}; \sigma) = (G_\sigma * I)(\mathbf{x})$, em que G_σ é o núcleo gaussiano de desvio-padrão σ . As derivadas são calculadas por convolução com derivadas do núcleo, o que as torna bem definidas e ajustáveis ao tamanho da estrutura de interesse. A matriz hessiana na escala σ ,

$$H_\sigma(\mathbf{x}) = \begin{pmatrix} L_{xx} & L_{xy} \\ L_{xy} & L_{yy} \end{pmatrix}, \quad (2)$$

descreve a curvatura local da intensidade. Seus autovalores são

$$\mu_\pm = \frac{L_{xx} + L_{yy}}{2} \pm \sqrt{\left(\frac{L_{xx} - L_{yy}}{2}\right)^2 + L_{xy}^2}, \quad (3)$$

e denotam-se por λ_1 e λ_2 esses valores ordenados por magnitude, $|\lambda_1| \leq |\lambda_2|$. Em um pixel situado sobre uma estrutura tubular clara, a curvatura transversal é intensa e negativa, e a longitudinal é aproximadamente nula: $\lambda_1 \approx 0$ e $\lambda_2 \ll 0$. O Quadro 1 resume os padrões possíveis em duas dimensões, segundo Frangi et al. (1998).

Como as derivadas de uma imagem suavizada tendem a diminuir com a escala, a comparação direta de respostas entre escalas favorece as escalas pequenas. Lindeberg (1998) propõe derivadas normalizadas pela escala, nas quais a derivada de ordem m é multiplicada por $\sigma^{m\gamma_N}$, sendo γ_N um parâmetro de normalização, de modo que a escala de resposta máxima

Quadro 1 – Padrões locais de intensidade em duas dimensões segundo os autovalores da matriz hessiana

λ_1	λ_2	Padrão local
≈ 0	≈ 0	fundo homogêneo ou ruído
≈ 0	$\ll 0$	estrutura tubular clara (fibra ou vaso claro)
≈ 0	$\gg 0$	estrutura tubular escura
$\ll 0$	$\ll 0$	mancha clara
$\gg 0$	$\gg 0$	mancha escura (por exemplo, uma cripta)

Fonte: Adaptado de Frangi et al. (1998).

Nota: Considera-se $|\lambda_1| \leq |\lambda_2|$.

reflita o tamanho da estrutura. Essa questão é retomada na análise de escalas do filtro de Frangi (Seção 7.4).

4.5 FILTRO DE *VESSELNESS* DE FRANGI

O filtro proposto por Frangi et al. (1998) combina os autovalores da matriz hessiana em uma medida de semelhança com um tubo. Definem-se a razão de forma (*blobness*) e a estruturalidade de segunda ordem:

$$\mathcal{R}_B = \frac{|\lambda_1|}{|\lambda_2|}, \quad \mathcal{S} = \sqrt{\lambda_1^2 + \lambda_2^2}. \quad (4)$$

A primeira distingue linhas ($\mathcal{R}_B \approx 0$) de manchas ($\mathcal{R}_B \approx 1$); a segunda é baixa no fundo, onde não há estrutura. Para cristas claras sobre fundo escuro,

$$V_\sigma = \begin{cases} 0, & \lambda_2 > 0, \\ \exp\left(-\frac{\mathcal{R}_B^2}{2\beta^2}\right) \left[1 - \exp\left(-\frac{\mathcal{S}^2}{2c^2}\right)\right], & \text{caso contrário,} \end{cases} \quad (5)$$

em que β controla a seletividade entre linhas e manchas e c , a sensibilidade à intensidade da estrutura. A resposta multiescala corresponde ao máximo sobre as escalas, $V = \max_\sigma V_\sigma$. Variantes posteriores alteram a combinação dos autovalores para tornar a resposta mais uniforme ao longo do vaso e nas bifurcações (Jerman et al., 2016), e filtros hessianos análogos foram propostos para estruturas curvilíneas em três dimensões (Sato et al., 1998).

Na implementação do *scikit-image* (van der Walt et al., 2014), empregada neste trabalho, as derivadas não são normalizadas pela escala, as intensidades estão no intervalo $[0, 1]$ e as cristas claras são tratadas pela negação da imagem. Com $c = 15$ e valores de $\mathcal{S}$ muito inferiores a c , o termo de estruturalidade opera em regime quase linear, $1 - e^{-x} \approx x$, e a resposta aproxima-se de $V_\sigma \approx e^{-\mathcal{R}_B^2/2\beta^2} \mathcal{S}^2/2c^2$: o mapa é proporcional a $\mathcal{S}^2$, o quadrado da norma da matriz hessiana, ponderado pela seletividade a linhas. Como o mapa bruto é esparsos e de magnitude muito pequena, ele é convertido para 8 bits por recorte nos percentis 2 e 99, seguido de correção gama de expoente 0,7, transformação crescente que não altera a ordenação dos pixels.

4.6 FILTROS DE GABOR

Um filtro de Gabor bidimensional consiste em uma senoide modulada por uma envoltória gaussiana (Daugman, 1985; Gabor, 1946). A forma real adotada pela biblioteca OpenCV (Bradski, 2000) é

$$g_{\theta}(x, y) = \exp\left(-\frac{x'^2 + \gamma^2 y'^2}{2\sigma^2}\right) \cos\left(\frac{2\pi x'}{\lambda} + \psi\right), \quad \begin{aligned} x' &= x \cos \theta + y \sin \theta, \\ y' &= -x \sin \theta + y \cos \theta, \end{aligned} \quad (6)$$

em que λ é o comprimento de onda, σ o desvio-padrão da envoltória, γ a razão de aspecto e ψ a fase. Daugman (1985) demonstrou que essas funções atingem o limite inferior da incerteza conjunta em posição e em frequência espacial, propriedade que as torna adequadas à descrição de texturas orientadas. Elas fundamentam os códigos de íris (Daugman, 1993, 2004) e métodos clássicos de segmentação de textura (Jain; Farrokhnia, 1991) e de vasos retinianos (Soares et al., 2006). No realce, aplica-se um banco de n orientações e toma-se, em cada pixel, a maior magnitude de resposta:

$$R(x, y) = \max_{\theta} |(I * g_{\theta})(x, y)|, \quad \theta \in \left\{ \frac{k\pi}{n} : k = 0, \dots, n-1 \right\}. \quad (7)$$

Com $\psi = 0$ e média do núcleo subtraída, a resposta é máxima sobre linhas cuja largura é compatível com o lóbulo central, de aproximadamente $\lambda/2$, e cuja direção coincide com a das listras do núcleo; o valor absoluto torna o realce sensível tanto a linhas claras quanto a linhas escuras.

4.7 MORFOLOGIA MATEMÁTICA: *TOP-HAT* E *BLACK-HAT*

A morfologia matemática (Soille, 2004) analisa a imagem por meio de um elemento estruturante b . A erosão e a dilatação em tons de cinza são definidas, respectivamente, por $\varepsilon_b(I)(\mathbf{x}) = \min_{\mathbf{y} \in b} I(\mathbf{x} + \mathbf{y})$ e $\delta_b(I)(\mathbf{x}) = \max_{\mathbf{y} \in b} I(\mathbf{x} - \mathbf{y})$. A abertura $I \circ b = \delta_b(\varepsilon_b(I))$ remove estruturas claras menores que b , e o fechamento $I \bullet b = \varepsilon_b(\delta_b(I))$ remove estruturas escuras menores que b . As transformações *top-hat* e *black-hat* recuperam o conteúdo removido:

$$T_b^{\text{top}}(I) = I - (I \circ b), \quad T_b^{\text{black}}(I) = (I \bullet b) - I, \quad (8)$$

isto é, as estruturas claras e escuras mais estreitas que o elemento estruturante, independentemente do nível de fundo. Zana e Klein (2001) empregaram esse princípio, com elementos lineares orientados, na segmentação de vasos retinianos. Na cadeia de análise, a resposta soma as duas polaridades em três escalas de elemento elíptico, $M = \sum_{k \in \{5, 11, 21\}} (T_{b_k}^{\text{top}} + T_{b_k}^{\text{black}})$, em que k é o diâmetro do elemento em pixels, e é normalizada para o intervalo $[0, 255]$. Por simplicidade, esse realce é denominado *black-hat* nas tabelas e figuras.

4.8 CLAHE E ESCOLHA DO CANAL DE COR

A equalização adaptativa de histograma com limitação de contraste (CLAHE) divide a imagem em uma grade de ladrilhos, equaliza o histograma de cada ladrilho com um teto que limita a amplificação do contraste, redistribuindo o excesso entre os níveis, e interpola bilinearmente os mapeamentos de ladrilhos vizinhos, o que evita descontinuidades (Pizer et al., 1987; Zuiderveld, 1994). O teto controla o compromisso entre ganho de contraste local e amplificação de ruído. Na cadeia de análise, adotam-se uma grade de 8×8 ladrilhos e limite de recorte 2,0, na convenção da OpenCV. O canal verde constitui a escolha usual em retinografias por apresentar o maior contraste entre vasos e fundo (Fraz et al., 2012). Para fotografias da íris, essa escolha não é evidente, razão pela qual foi testada experimentalmente (Seção 7.6).

4.9 MÉTRICAS DE AVALIAÇÃO

4.9.1 Razão contraste-ruído

Há diferentes definições de razão contraste-ruído na literatura (Welvaert; Rosseel, 2013). Adota-se a Equação (1), que mede a separação entre estrutura e fundo em unidades da variabilidade do fundo. Na ausência de verdade de referência, a partição entre estrutura e fundo é obtida pelo limiar de Otsu (1979).

4.9.2 Energia de cristas e entropia

A variância do laplaciano, $E = \text{Var}(\nabla^2 I)/255^2$, é uma medida de nitidez empregada em foco automático (Pech-Pacheco et al., 2000) e indica a quantidade de detalhe fino presente na imagem. A entropia de Shannon (1948), $H = -\sum_k p_k \log_2 p_k$, calculada sobre o histograma de intensidades, mede a dispersão dos níveis de cinza. As duas medidas são complementares: um mapa esparso apresenta entropia baixa mesmo quando isola adequadamente as estruturas.

4.9.3 Curva ROC, AUC e coeficiente de Dice

Quando há verdade de referência, cada mapa de realce é tratado como o escore de um classificador de pixels. A curva ROC relaciona as taxas de verdadeiros e de falsos positivos para todos os limiares, e a AUC equivale à probabilidade de um pixel de estrutura escolhido ao acaso receber escore maior que um pixel de fundo escolhido ao acaso (Fawcett, 2006; Hanley; McNeil, 1982). Diferentemente da CNR, a AUC não depende de limiar nem de normalizações crescentes do mapa (Proposição 1). Para comparar duas máscaras binárias A e B , emprega-se o coeficiente de Dice (1945), $2|A \cap B|/(|A| + |B|)$.

4.9.4 Testes estatísticos

Comparações pareadas entre métodos empregam o teste dos postos sinalizados de Wilcoxon (1945), que não pressupõe normalidade das diferenças. Intervalos de confiança para medianas são obtidos por *bootstrap* percentil (Efron, 1979). A associação entre medidas é descrita pelo coeficiente de correlação de Pearson e pelo coeficiente de postos de Spearman (1904).

4.10 DETECÇÃO DA PUPILA E DO LIMBO

Na biometria, a pupila e o limbo são tradicionalmente modelados como círculos. Daugman (1993, 2004) propôs o operador integro-diferencial

$$\max_{(r, x_0, y_0)} \left| G_\sigma(r) * \frac{\partial}{\partial r} \oint_{r, x_0, y_0} \frac{I(x, y)}{2\pi r} ds \right|, \quad (9)$$

que procura o círculo no qual a média de intensidade ao longo da circunferência varia mais bruscamente com o raio. Wildes (1997) empregou um mapa de bordas seguido da transformada de Hough (Duda; Hart, 1972), na qual cada ponto de borda vota nos círculos que poderiam passar por ele. Contornos ativos (Kass; Witkin; Terzopoulos, 1988) e métodos mais recentes relaxam a hipótese de circularidade, e Bowyer, Hollingsworth e Flynn (2008) revisam essas abordagens. Uma vez estimados os contornos, a normalização *rubber sheet* (Daugman, 2004) remapeia o anel para coordenadas adimensionais (r, θ) ,

$$x(r, \theta) = (1 - r) x_p(\theta) + r x_i(\theta), \quad y(r, \theta) = (1 - r) y_p(\theta) + r y_i(\theta), \quad r \in [0, 1], \quad (10)$$

em que (x_p, y_p) e (x_i, y_i) são os pontos das bordas pupilar e límbica na direção θ . Essa representação compensa a dilatação da pupila e as diferenças de escala entre imagens.

5 TRABALHOS RELACIONADOS

5.1 REALCE E SEGMENTAÇÃO DE VASOS EM RETINOGRAFIAS

A literatura mais próxima do problema de realce é a de segmentação de vasos em retinografias, área em que as três famílias de operadores adotadas neste trabalho foram desenvolvidas e comparadas. Chaudhuri et al. (1989) introduziram filtros casados bidimensionais, que modelam o perfil transversal do vaso por uma gaussiana e aplicam o núcleo em 12 orientações; Hoover, Kouznetsova e Goldbaum (2000) aprimoraram a limiarização da resposta desses filtros e disponibilizaram a base STARE. Zana e Klein (2001) combinaram a transformação *top-hat* com elementos lineares orientados e avaliação de curvatura, e Mendonça e Campilho (2006) associaram a detecção de linhas centrais à reconstrução morfológica. Staal et al. (2004) propuseram uma abordagem baseada em cristas com classificação de pixels e disponibilizaram a base DRIVE, ao passo que Soares et al. (2006) utilizaram a transformada *wavelet* de Gabor bidimensional como descritor de pixels para um classificador bayesiano. Ricci e Perfetti (2007) empregaram operadores de linha e máquinas de vetores de suporte. As revisões de Abràmoff, Garvin e Sonka (2010) e de Fraz et al. (2012) sistematizam esses métodos e mostram que realces orientados, hessianos e morfológicos figuram com frequência como etapa inicial, seguida de classificação ou de limiarização.

Dois aspectos dessa literatura orientam o presente trabalho. O primeiro é que os métodos são avaliados contra anotações manuais de vasos, com AUC, sensibilidade e especificidade por pixel; como não há anotações desse tipo para a íris em fotografias RGB, este relatório recorre a um fantoma sintético para obter uma verdade de referência (Seção 6.7.2). O segundo é que o uso do canal verde e a equalização de contraste constituem etapas quase universais de pré-processamento em retinografias (Fraz et al., 2012), o que motivou sua adoção inicial e, ao mesmo tempo, a verificação experimental da escolha do canal para a íris.

5.2 FILTROS HESSIANOS

O filtro de Frangi et al. (1998) foi proposto para angiografias bidimensionais e tridimensionais e tornou-se referência no realce de vasos. Com o mesmo princípio, Sato et al. (1998) propuseram um filtro de linhas multiescala para estruturas curvilíneas tridimensionais, e Jerman et al. (2016), uma função dos autovalores com resposta mais uniforme ao longo do vaso e nas bifurcações. Neste relatório, manteve-se o filtro original, por ser o mais difundido e por estar disponível em bibliotecas mantidas pela comunidade; as variantes constituem candidatas naturais para trabalhos futuros.

5.3 VASCULATURA DA ÍRIS E PUPILA NO DM2

No segmento anterior, a vasculatura da íris é estudada principalmente por AS-OCTA e por angiofluoresceinografia (Roberts; Goldstein; Fawzi, 2017; Zett et al., 2018; Zhou et al., 2025), inclusive com análise quantitativa automatizada (Zhu et al., 2026). A pupila é investigada por pupilometria (Thakar et al., 2025) e como preditora de retinopatia com aprendizado de máquina (Surya et al., 2026); Cui et al. (2024) combinaram angiografia por OCT, pupilometria e tomografia do segmento anterior para relacionar densidade vascular, diâmetro pupilar e espessura da íris. Esses trabalhos utilizam modalidades dedicadas. O presente estudo avalia se correlatos aproximados dessas grandezas podem ser obtidos de fotografias RGB, sem pretensão de equivalência clínica.

5.4 ÍRIS, APRENDIZADO DE MÁQUINA E VIÉS

Na biometria, a segmentação da íris constitui um problema maduro (Bowyer; Hollingsworth; Flynn, 2008; Daugman, 2004; Wildes, 1997), e seus métodos fundamentam a detecção da pupila e do limbo empregada neste trabalho. Em aplicações médicas, há estudos que aplicam aprendizado de máquina a imagens da íris para o diagnóstico de diabetes (Samant; Agarwal, 2018), linha que este projeto avalia criticamente. O êxito do aprendizado profundo em retinografias (Gulshan et al., 2016) contrasta com o risco, documentado em outras modalidades, de modelos aprenderem atalhos ligados à aquisição em vez de sinal clínico (Zech et al., 2018). Esse risco reforça a importância de um controle de qualidade geométrico anterior à extração de descritores, que é o objetivo do validador de pupila. O Quadro 2 sintetiza os trabalhos discutidos.

Quadro 2 – Síntese dos trabalhos relacionados e de sua relação com este relatório

Trabalho	Modalidade	Técnica principal	Relação com este relatório
Chaudhuri et al. (1989); Hoover, Kouznetsova e Goldbaum (2000)	Retinografia	Filtros casados gaussianos orientados	Precursos do realce orientado
Zana e Klein (2001); Mendonça e Campilho (2006)	Retinografia	Morfologia (<i>top-hat</i> , reconstrução)	Base do realce morfológico
Staal et al. (2004); Ricci e Perfetti (2007)	Retinografia	Cristas e operadores de linha com classificação	Realce seguido de classificação de pixels
Soares et al. (2006)	Retinografia	<i>Wavelet</i> de Gabor e classificador bayesiano	Gabor aplicado a vasos
Frangi et al. (1998); Sato et al. (1998); Jerman et al. (2016)	Angiografia 2D e 3D	Autovalores da matriz hessiana em múltiplas escalas	Filtro adotado e variantes
Daugman (2004); Wildes (1997); Bowyer, Hollingsworth e Flynn (2008)	Biometria da íris	Operador integro-diferencial; transformada de Hough	Deteção da pupila e do limbo
Roberts, Goldstein e Fawzi (2017); Zett et al. (2018); Zhou et al. (2025); Zhu et al. (2026)	AS-OCTA e angiografia da íris	Densidade vascular; análise quantitativa	Referência clínica para a vascularização
Cui et al. (2024); Thakar et al. (2025); Surya et al. (2026)	Tomografia e pupilometria	Diâmetro pupilar; espessura iridiana	Fundamentação do validador
Samant e Agarwal (2018); Zech et al. (2018)	Fotografia da íris; radiografia	Aprendizado de máquina para diabetes; atalhos de aquisição	Linha avaliada criticamente; riscos de vies


Fonte: Elaborado pelo autor (2026).

6 METODOLOGIA

6.1 VISÃO GERAL

A Figura 1 resume a cadeia implementada. No ramo superior, a imagem é pré-processada (canal verde e CLAHE) e submetida aos três realces; os mapas resultantes e as linhas de base são medidos no anel da íris. No ramo inferior, a pupila e o limbo são detectados, o anel de medida é construído e a geometria é validada. Os dois ramos encontram-se na região de medida, uma vez que o anel Ω definido pela detecção é utilizado por todas as métricas de realce. Na figura, as etapas de entrada e de geometria aparecem em azul, os realces e a normalização polar em verde, e as etapas de medida e de validação em laranja.

Figura 1 – Visão geral da cadeia de análise implementada



Fonte: Elaborada pelo autor (2026).

6.2 DADOS

O conjunto de imagens da íris rotulado para DM2, base de trabalho do projeto, não estava disponível no ambiente desta etapa. Os experimentos com imagens reais utilizam, por esse motivo, duas fotografias públicas com licenças abertas, a segunda das quais já havia sido empregada como ilustração no PGC I. No texto, nas tabelas e nas figuras, essas fotografias são identificadas pelas seguintes designações:

- a) olho completo: fotografia de Novák (2005), disponibilizada no Wikimedia Commons sob licença CC BY-SA 2.5, com 2788×1864 pixels, na qual são visíveis pupila, íris, esclera, pálpebras e cílios;
- b) macro da íris: macrofotografia de Reyes (2014), disponibilizada no Wikimedia Commons sob licença CC BY 2.0, com 1732×1720 pixels, na qual a íris preenche o quadro e o limbo não aparece; a imagem possui pós-processamento artístico, o que reforça seu caráter apenas ilustrativo.

Ambas as imagens são reduzidas para lado maior de 768 pixels com interpolação por área, o que resulta em 768×513 e 768×762 pixels. Duas imagens não permitem inferência sobre uma população, e nenhuma delas possui rótulo clínico. Elas servem para verificar o funcionamento dos métodos, comparar operadores na mesma imagem e estimar a variabilidade entre regiões da íris; a verdade de referência necessária para validar a métrica provém de um fantoma sintético (Seção 6.7.2).


6.3 PRÉ-PROCESSAMENTO E REALCES

Os três realces compartilham o mesmo pré-processamento: extração do canal verde e aplicação da CLAHE (Figura 2). A CLAHE distribui os níveis de cinza da íris por quase toda a faixa disponível e torna o estroma mais visível, mas não distingue fibras de ruído. O Quadro 3 lista a configuração padrão, definida em `src/config.py`; a configuração completa consta do Apêndice B. Os parâmetros foram fixados a partir de valores usuais na literatura e não foram ajustados às duas imagens, de modo a evitar que a avaliação favoreça a configuração escolhida; o efeito de variá-los é medido no experimento E4. A Figura 3 mostra o banco de Gabor efetivamente utilizado: cada núcleo responde a linhas perpendiculares à direção θ , com pesos positivos em vermelho e negativos em azul.

6.4 DETECÇÃO DA PUPILA E DO LIMBO E REGIÃO DE MEDIDA

A detecção empregada nesta etapa é deliberadamente simples e determinística (Algoritmo 1). A pupila é procurada como a região escura mais circular e mais central da imagem, obtida por limiar no percentil 3 da intensidade acrescido de 20 níveis, seguido de abertura e fechamento morfológicos. O limbo é procurado pela transformada de Hough para círculos, restrita a raios entre 1,6 e 6 vezes o raio da pupila e a centros próximos ao da pupila. Quando uma etapa falha, o detector recorre a uma estimativa de reserva e sinaliza esse fato; na macro da íris, em que o limbo não aparece, o raio da íris é sempre estimado.

Figura 2 – Canal verde do olho completo antes e depois da CLAHE, com os histogramas no disco da íris




Fonte: Elaborada pelo autor (2026), a partir de fotografia de Novák (2005).

Quadro 3 – Configuração padrão do pré-processamento, dos realces e da métrica

Etapa	Parâmetro	Valor
Redimensionamento	lado maior	768 px (interpolação por área)
Canal	entrada dos realces	verde (G)
CLAHE	limite de recorte; grade	2,0; 8 × 8 ladrilhos
Frangi	escalas σ	{1, 2, 3, 4}
	β ; c	0,5; 15
	polaridade	cristas claras
	saída	recorte nos percentis 2 e 99, gama 0,7
Gabor	orientações n	8 (passo de 22,5°)
	λ ; σ ; γ ; ψ	10; 4; 0,5; 0
	núcleo	21 × 21, média subtraída
	saída	máximo de resposta , normalização mínimo–máximo
Morfologia	elementos estruturantes	elipses de 5, 11 e 21 px
	saída	soma <i>top-hat</i> + <i>black-hat</i> , normalização mínimo–máximo
Métrica	limiar estrutura/fundo	Otsu sobre o mapa inteiro
	região das estatísticas	anel Ω (ou setor)

Fonte: Elaborado pelo autor (2026).

Figura 3 – Banco de filtros de Gabor utilizado no realce



Fonte: Elaborada pelo autor (2026).

Nota: Oito núcleos de 21×21 pixels, com $\lambda = 10$, $\sigma = 4$, $\gamma = 0,5$ e média subtraída.

Algoritmo 1 – Detecção da pupila e do limbo

Entrada: imagem colorida I (lado maior de 768 px), com $h \times w$ pixels


Saída: círculos $(\mathbf{c}_p, r_p)$ e $(\mathbf{c}_i, r_i)$; indicadores de estimativa

- 1 $g \leftarrow$ filtro de mediana 7×7 da imagem em tons de cinza
 - 2 $t \leftarrow$ percentil 3 de $g + 20$; $D \leftarrow \{\mathbf{x} : g(\mathbf{x}) \leq t\}$
 - 3 $D \leftarrow$ fechamento(abertura(D , elipse 9×9), elipse 9×9 , 2 iterações)
 - 4 **para cada** contorno externo C de D com área $\geq 0,0015 hw$ **faça**
 - 5 $(\mathbf{c}, r) \leftarrow$ menor círculo que envolve C
 - 6 $\kappa \leftarrow \text{área}(C)/(\pi r^2)$; $\eta \leftarrow 1 - \|\mathbf{c} - \mathbf{c}_{\text{img}}\|/\|\mathbf{c}_{\text{img}}\|$
 - 7 **se** $\kappa > 0,55$ e $\kappa + 0,5\eta$ é o maior até aqui **então**
 - 8 $(\mathbf{c}_p, r_p) \leftarrow (\mathbf{c}, r)$
 - 9 **se nenhum candidato então**
 - 10 $\mathbf{c}_p \leftarrow \arg \min g$; $r_p \leftarrow 0,08 \min(h, w)$; pupila estimada
 - 11 círculos $\leftarrow$ Hough(g ; $d_p = 1,2$; limiar de Canny 100; limiar do acumulador 40;
 $r \in [1,6 r_p; 6 r_p]$)
 - 12 $(\mathbf{c}_i, r_i) \leftarrow$ círculo com $\|\mathbf{c} - \mathbf{c}_p\| < 0,9 r_p$ mais próximo de $\mathbf{c}_p$
 - 13 **se nenhum círculo concêntrico então**
 - 14 $(\mathbf{c}_i, r_i) \leftarrow (\mathbf{c}_p, 0,48 \min(h, w))$; íris estimada
 - 15 **retorna** $(\mathbf{c}_p, r_p)$, $(\mathbf{c}_i, r_i)$ e os indicadores
-

Fonte: Elaborado pelo autor (2026).

A região de medida é o anel Ω , formado pelo disco do limbo excluído o disco da pupila. Para a análise por regiões, Ω é dividido em 12 setores angulares de 30° centrados na pupila, numerados de S1 a S12 no sentido anti-horário a partir da direita, com o eixo vertical da imagem orientado para cima (Figura 4). A figura evidencia duas fontes de contaminação do anel no olho completo: os cílios superiores sobrepostos à íris nos setores S1 e S2 e a pálpebra superior, próxima ao limbo em S3 e S4. Observa-se, ainda, que o círculo do limbo obtido pela transformada de Hough está deslocado para a direita em relação ao limbo real e não cobre a íris em S6 e S7, aspecto discutido na Seção 7.11.

Figura 4 – Anel de medida e setores angulares no olho completo



Fonte: Elaborada pelo autor (2026), a partir de fotografia de Novák (2005).

Nota: Pupila em verde, círculo do limbo em azul-claro e anel Ω sombreado em azul.

6.5 MÉTRICAS E LINHAS DE BASE

A métrica principal é a CNR da Equação (1), calculada sobre o mapa de 8 bits de cada método. A implementação (`VascularizationEnhancer.quantify`) calcula o limiar de Otsu sobre a *mapa inteiro* e toma as estatísticas dentro do anel: os pixels de Ω acima do limiar formam a estrutura, e os demais, o fundo. A escolha do limiar global foi mantida por ser a adotada na cadeia de análise; o efeito de restringir o limiar ao anel é medido no experimento E2. Quando a estrutura ou o fundo ficam vazios em uma região, a CNR é indefinida e a região é excluída da comparação correspondente. As medidas complementares são a energia de cristas E , calculada em Ω , e a entropia H do histograma em Ω .

As linhas de base são as três operações disponíveis antes desta etapa: brilho +40 e contraste $\times 1,8$ aplicados ao canal verde, e CLAHE. Em cada comparação, o ganho de um realce é expresso em relação à *melhor* linha de base, isto é, àquela de maior valor na medida considerada, o que torna a comparação conservadora.

6.6 VALIDADOR GEOMÉTRICO DA PUPILA

O validador (`PupilValidator`) recebe os raios e os centros da pupila e do limbo e calcula três descritores adimensionais:

$$\rho = \frac{r_p}{r_i}, \quad \tau = \frac{r_i - r_p}{r_i} = 1 - \rho, \quad \epsilon = \frac{\|\mathbf{c}_p - \mathbf{c}_i\|}{r_i}. \quad (11)$$

A razão ρ mede a dilatação relativa da pupila, τ a largura radial do anel e ϵ a excentricidade entre os centros. Como $\tau = 1 - \rho$, o critério de espessura equivale a um limite superior adicional para ρ ; ele é mantido separado por comunicar um motivo diferente, a saber, um anel estreito demais para a extração de textura. O validador registra ainda os diâmetros e a espessura em pixels e, quando há escala conhecida, em milímetros. A classificação segue o Algoritmo 2, com as faixas do Quadro 4.

Algoritmo 2 – Validação geométrica da pupila

Entrada: raios r_p, r_i e centros $\mathbf{c}_p, \mathbf{c}_i$
Saída: rótulo, pontuação q e lista de motivos M

- 1 **se** $r_p \leq 0$ **ou** $r_i \leq r_p$ **então retorna** *invalid com o motivo*
- 2 calcular ρ, τ e ϵ (Equação 11); $q \leftarrow 1$; $M \leftarrow \emptyset$
- 3 **se** $\rho \notin [0,15; 0,80]$ **então**
- 4 | $q \leftarrow q - 0,6$; acrescentar a M : fora da faixa plausível (falha grave)
- 5 **senão se** $\rho \notin [0,20; 0,70]$ **então**
- 6 | $q \leftarrow q - 0,25$; acrescentar a M : faixa de atenção
- 7 **se** $\tau < 0,25$ **então** $q \leftarrow q - 0,3$; acrescentar a M : anel fino demais
- 8 **se** $\epsilon > 0,30$ **então** $q \leftarrow q - 0,3$; acrescentar a M : centros pouco concêntricos
- 9 $q \leftarrow \min(1, \max(0, q))$
- 10 **se** *falha grave* **ou** $q < 0,5$ **então**
- 11 | rótulo $\leftarrow$ *invalid*
- 12 **senão se** $q < 0,8$ **ou** $M \neq \emptyset$ **então**
- 13 | rótulo $\leftarrow$ *borderline*
- 14 **senão** rótulo $\leftarrow$ *valid*
- 15 **retorna** rótulo, q , M

Fonte: Elaborado pelo autor (2026).

Os rótulos *valid*, *borderline* e *invalid* correspondem, respectivamente, a geometria válida, limítrofe (aceitável com ressalva) e inválida. Os seis valores calculados (diâmetros, espessura, ρ , τ e ϵ) também formam um vetor de descritores apto a alimentar um classificador supervisionado quando houver dados rotulados, o que permitiria aprender os limiares em vez de fixá-los. Para uma estimativa de ordem de grandeza em milímetros, quando a escala da imagem não é conhecida, utiliza-se o diâmetro médio da íris como referência: $\text{px/mm} = D_i/11,71$ (Rüfer; Schröder; Erb, 2005).

6.7 DESENHO EXPERIMENTAL

O Quadro 5 resume os onze experimentos. Os detalhes que não decorrem diretamente das seções anteriores são descritos nas subseções seguintes.

Quadro 4 – Faixas do validador geométrico e sua origem

Critério	Valor	Origem
Faixa normal de ρ	[0,20; 0,70]	Arredondamento do intervalo [0,17; 0,68], obtido de pupila entre 2 e 8 mm (Watson; Yellott, 2012) e de íris de 11,71 mm (Rüfer; Schröder; Erb, 2005).
Faixa plausível de ρ	[0,15; 0,80]	Margem para variação individual do diâmetro da íris, miose e midríase farmacológica e erro de segmentação; fora dela, a geometria é considerada implausível.
Espessura mínima τ	0,25	Anel com largura de pelo menos um quarto do raio da íris, o que equivale a $\rho \leq 0,75$.
Excentricidade máxima ϵ	0,30	Tolerância heurística para o deslocamento entre os centros, sem referência fisiológica verificada nesta etapa.
Penalidades e rótulos	0,6; 0,25; 0,3; 0,3; limiares 0,5 e 0,8	Escolhas de projeto: uma violação leve isolada produz <i>borderline</i> ; uma violação grave ou duas violações produzem <i>invalid</i> . Os valores não foram ajustados a dados.

Fonte: Elaborado pelo autor (2026).

Quadro 5 – Experimentos realizados, perguntas a que respondem e medidas empregadas

Experimento	Pergunta	Dados	Medidas
E0 Comparação principal	Os realces superam as linhas de base?	2 imagens reais	CNR, E , H
E1 Setores angulares	O ganho é consistente ao longo da íris?	24 setores de 30°	CNR; Wilcoxon; <i>bootstrap</i>
E2 Limiar da métrica	A conclusão depende da região de cálculo do limiar?	2 imagens	CNR com Otsu global e no anel
E3 Escalas do Frangi	Que escala domina e qual o efeito da normalização de saída?	2 imagens	dominância, resposta média, CNR
E4 Sensibilidade	Quão dependentes dos parâmetros são os resultados?	2 imagens, 29 configurações	CNR
E5 Robustez	Os mapas mudam sob perturbações de aquisição?	2 imagens, 9 perturbações	r de Pearson, Dice, retenção da CNR
E6 Fantoma	A CNR concorda com uma verdade de referência?	50 fantasmas (5 níveis de ruído, 10 sementes)	AUC, CNR com verdade, CNR por Otsu, Spearman
E7 Custo	Quanto tempo cada etapa demanda?	imagem de 768 × 513 px	mediana de 7 execuções
E8 Normalização polar	Como as estruturas se distribuem no raio?	2 imagens	densidade de estrutura por raio
E9 Validação da pupila	O validador e a detecção são confiáveis?	imagem real, 7 casos sintéticos, 15 condições	ρ , τ , ϵ , rótulo
E10 Canal de cor	O canal verde é a melhor entrada?	2 imagens, 4 canais	CNR

Fonte: Elaborado pelo autor (2026).

6.7.1 Análise por setores angulares (E1)

Em cada setor, a CNR de cada método é calculada com o mesmo protocolo da medida global, e cada realce é comparado com a melhor linha de base *daquele setor*. Emprega-se o teste de Wilcoxon pareado unilateral, cuja hipótese alternativa é a de que o realce apresenta CNR maior, aplicado às diferenças; a razão mediana entre a CNR do realce e a da melhor linha de base recebe um intervalo de confiança de 95% por *bootstrap* percentil com 10.000 reamostragens (semente 0). Setores com menos de 500 pixels seriam descartados, o que não ocorreu. Como os setores de uma mesma imagem são vizinhos e compartilham a iluminação, eles não constituem observações independentes; os valores- p descrevem a consistência do efeito dentro de cada imagem, e não a generalização para outras íris. Uma análise de sensibilidade exclui os setores S1 e S2 do olho completo, contaminados pelos cílios.

6.7.2 Fantoma sintético (E6)

Cada fantoma possui 384×384 pixels e resulta da soma de quatro componentes: (i) iluminação não uniforme, dada por $70 + 50x/384 + 25 \cos(\pi y/384)$; (ii) textura de fundo, formada por ruído gaussiano suavizado ($\sigma = 6$) e reescalado para desvio-padrão 12; (iii) 28 estruturas tubulares claras, desenhadas como curvas de Bézier quadráticas com pontos de controle aleatórios, largura de 1, 2 ou 3 pixels e contraste uniforme entre 12 e 35 níveis, suavizadas por uma gaussiana de $\sigma = 0,7$; e (iv) ruído gaussiano branco com desvio-padrão $\sigma_n \in \{4, 8, 12, 16, 24\}$. A verdade de referência é a máscara das curvas antes da suavização, que ocupa 15,2% do campo de visão na semente 0. Para cada nível de ruído, geram-se 10 fantasmas (sementes 0 a 9), e as medidas excluem uma borda de 12 pixels. Os métodos são aplicados exatamente como nas imagens reais. Além da AUC, calculam-se a CNR com a verdade de referência, na qual estrutura e fundo são definidos pela máscara verdadeira, e a CNR por Otsu, a mesma empregada nas imagens reais. A correlação de Spearman entre a CNR por Otsu e a AUC, nas 35 combinações de ruído e método, indica se a métrica sem verdade de referência ordena os métodos da mesma forma que a métrica com verdade.

6.7.3 Perturbações (E5 e E9)

As nove perturbações são: brilho ± 30 , com saturação em 0 e 255; contraste $\times 0,7$ e $\times 1,3$; correção gama 0,7 e 1,5; ruído gaussiano ($\sigma = 8$, semente 0); desfoque gaussiano ($\sigma = 1,5$); e compressão JPEG com qualidade 30. Elas são aplicadas à imagem colorida antes de todo o processamento. No E5, a região Ω é a da imagem original, de modo a isolar o efeito sobre o realce, e medem-se a correlação de Pearson entre os mapas em Ω , o coeficiente de Dice entre as máscaras de estrutura e a razão entre a CNR após e antes da perturbação. No E9, a detecção e a validação são refeitas em cada condição; às perturbações somam-se três mudanças de escala (lado maior de 384, 576 e 1152 pixels a partir do original), uma rotação de 10° e um espelhamento horizontal.

6.7.4 Demais experimentos

No E3, as respostas do filtro de Frangi em cada escala são calculadas separadamente; a dominância de uma escala é a fração dos pixels de estrutura em que ela produz a maior resposta, e verifica-se se o máximo das respostas individuais coincide com a saída multiescala. Avaliam-se também três normalizações de saída do mapa de Frangi. No E4, cada parâmetro é variado isoladamente em torno da configuração padrão, em 29 configurações; na varredura de σ do filtro de Gabor, o núcleo cresce para $\max(21, 2\lceil 2,5\sigma \rceil + 1)$ pixels, de modo a cobrir a envoltória. No E7, cada etapa é executada uma vez para aquecimento e, em seguida, sete vezes, em um único processo, registrando-se mediana, mínimo e máximo. No E8, o anel é desdobrado pela Equação (10) em 64 amostras radiais e 720 angulares, com interpolação bilinear, e calcula-se a fração de pixels de estrutura do mapa de Frangi em cada raio. No E10, cada canal (R, G, B e a luminância $Y = 0,299R + 0,587G + 0,114B$) é replicado e submetido ao mesmo processamento.

6.8 REPRODUTIBILIDADE E TESTES

Todos os resultados das Seções 7 e 8 são produzidos por `experiments/report_experiments.py`, que grava as figuras em `docs/PGC_2/figuras`, as tabelas em `docs/PGC_2/tabelas`, incluídas neste documento sem edição manual, as séries dos gráficos em `docs/PGC_2/dados` e um resumo completo em `results/report/resumo.json`. As sementes são fixas, e as versões das bibliotecas empregadas (Bradski, 2000; Harris et al., 2020; Hunter, 2007; Pedregosa et al., 2011; van der Walt et al., 2014; Virtanen et al., 2020) constam do Apêndice A. O módulo de testes `tests/test_vascularization_and_pupil.py` contém onze testes unitários: cinco para o realce (formato e faixa das saídas, entrada em tons de cinza, métricas, vantagem do filtro de Frangi sobre o brilho em uma estrutura sintética e imagem constante) e seis para o validador (geometria normal, dilatação e constrição excessivas, excentricidade, íris menor que a pupila e vetor de descritores).

6.9 ASPECTOS ÉTICOS E LICENÇAS

As duas fotografias são públicas, com licenças Creative Commons que permitem o uso com atribuição, e não estão associadas a dados de saúde. Nenhum dado pessoal ou clínico foi coletado nesta etapa. As imagens são utilizadas apenas para ilustrar e verificar os métodos, e nenhum resultado deste relatório deve ser interpretado como diagnóstico ou como evidência sobre o DM2.

7 RESULTADOS

Os resultados a seguir foram produzidos em uma única execução do *script* de experimentos, no ambiente descrito no Apêndice A. Os números decimais são apresentados com vírgula e, nas tabelas, o melhor resultado de cada bloco aparece em negrito quando a comparação é direta.

7.1 COMPARAÇÃO PRINCIPAL (E0)

A Tabela 1 compara as linhas de base e os três realces no anel da íris, e a Figura 5 resume a CNR. O filtro de Frangi obteve a maior CNR nas duas imagens: 8,24 no olho completo e 7,29 na macro da íris, contra 3,49 e 3,62 da melhor linha de base (contraste $\times 1,8$ nos dois casos), o que corresponde a razões de 2,36 e 2,02. A energia de cristas do filtro de Frangi correspondeu a 5,25 e 5,33 vezes a da melhor linha de base. O banco de Gabor também superou as linhas de base em CNR (5,90 e 4,31, isto é, 1,69 e 1,19 vez a melhor linha de base), porém com energia de cristas menor, uma vez que sua resposta é suave. O realce *black-hat* apresentou ganho apenas no olho completo (4,38, ou 1,25 vez) e permaneceu no nível da linha de base na macro da íris (3,56, ou 0,98 vez).

Tabela 1 – Visibilidade das estruturas no anel da íris (E0)


Imagem	Método	CNR	E	H (bits)	CNR ($\times$ base)	E ($\times$ base)
Olho completo	Original (verde)	3,22	0,080	7,37	0,92	0,49
	Brilho +40 (base)	3,21	0,079	7,33	0,92	0,48
	Contraste $\times 1,8$ (base)	3,49	0,165	6,60	1,00	1,00
	CLAHE (base)	3,26	0,164	7,73	0,93	0,99
	Frangi	8,24	0,866	4,80	2,36	5,25
	Gabor	5,90	0,046	5,75	1,69	0,28
	<i>Black-hat</i>	4,38	0,023	6,57	1,25	0,14
Macro da íris	Original (verde)	3,54	0,028	7,20	0,98	0,27
	Brilho +40 (base)	3,54	0,028	7,20	0,98	0,27
	Contraste $\times 1,8$ (base)	3,62	0,080	6,23	1,00	0,78
	CLAHE (base)	3,34	0,103	7,77	0,92	1,00
	Frangi	7,29	0,549	5,06	2,02	5,33
	Gabor	4,31	0,137	6,82	1,19	1,33
	<i>Black-hat</i>	3,56	0,049	7,01	0,98	0,48

Fonte: Elaborada pelo autor (2026).

Nota: CNR: razão contraste-ruído; E : energia de cristas; H : entropia. As colunas “ $\times$ base” dividem cada valor pelo da melhor linha de base na mesma medida.


As linhas de base comportaram-se conforme previsto pela Proposição 1. O brilho +40 produziu praticamente a mesma CNR do canal original (3,21 contra 3,22 no olho completo; 3,54 contra 3,54 na macro), e as pequenas diferenças decorrem da saturação de pixels claros da esclera e de reflexos em 255. O contraste $\times 1,8$ elevou a CNR para 3,49 e 3,62; como uma transformação

Figura 5 – CNR no anel da íris por método nas duas imagens (E0)



Fonte: Elaborada pelo autor (2026).

afim sem saturação manteria a CNR inalterada, esse aumento deve-se inteiramente à saturação, visível como o pico em 255 no histograma da Figura 6. Trata-se de perda de informação nos tons claros, e não de ganho estrutural. O mesmo histograma exibe o padrão em pente produzido pelo contraste, uma vez que a transformação apenas redistribui os 256 níveis originais e deixa lacunas entre eles. A CLAHE apresentou CNR próxima à do original (3,26 e 3,34), mas aproximadamente duplicou a energia de cristas no olho completo, o que ilustra que ela amplifica detalhes de qualquer natureza sem separar estruturas do fundo.

Figura 6 – Histogramas de estrutura e de fundo no anel do olho completo para o contraste $\times 1,8$ e para o filtro de Frangi (E0)


Fonte: Elaborada pelo autor (2026), a partir de fotografia de Novák (2005).

Nota: Escala logarítmica; a linha tracejada indica o limiar de Otsu.

A entropia diminuiu nos três realces, passando de 7,37 bits no original para 4,80 no filtro de Frangi, no olho completo. Esse resultado é esperado para mapas esparsos e mostra por que a entropia não serve como medida de qualidade do realce neste problema: um mapa que anula o fundo e preserva apenas as estruturas ocupa poucos níveis de cinza. As Figuras 7 e 8

apresentam a comparação visual, e a Figura 9 amplia um trecho do estroma da macro da íris. No olho completo, o filtro de Frangi exhibe as fibras radiais como linhas finas sobre fundo escuro, e a região superior direita, com resposta intensa nos três realces, corresponde aos cílios sobrepostos à íris. Na macro, o filtro de Frangi isola as trabéculas radiais, o banco de Gabor produz uma resposta mais contínua e orientada e o realce *black-hat* destaca regiões mais largas, incluindo bordas de criptas. No detalhe ampliado, o contraste $\times 1,8$ satura as regiões claras, ao passo que o filtro de Frangi delinea fibras e bordas de criptas como linhas finas e o banco de Gabor responde às fibras com faixas suaves e contínuas.

Figura 7 – Comparação visual entre o canal original, as linhas de base e os realces no olho completo (E0)




Fonte: Elaborada pelo autor (2026), a partir de fotografia de Novák (2005).

Nota: Os mapas de realce (d a f) estão restritos ao disco da íris detectado.

7.2 CONSISTÊNCIA POR SETORES ANGULARES (E1)


A Tabela 2 resume a comparação por setores. O filtro de Frangi superou a melhor linha de base do setor em todos os 24 setores, com razão mediana de 1,85 (IC 95%: 1,55 a 2,68) no olho completo e de 2,01 (IC 95%: 1,61 a 2,21) na macro da íris; nos dois conjuntos reunidos, a razão mediana foi de 1,92 (IC 95%: 1,64 a 2,23), com $p < 0,001$. O banco de Gabor superou a linha de base em 8 de 11 setores do olho completo e em 9 de 12 da macro, com razões medianas de 1,21 e 1,14; no conjunto, superou-a em 17 de 23 setores ($p < 0,001$), com intervalo de confiança da razão acima de 1 (1,03 a 1,34). O realce *black-hat* não apresentou ganho consistente: superou a linha de base em 5 de 12 e em 4 de 12 setores, com razões medianas de 0,96 e 0,99 e valores- p de 0,339 e 0,849.

Figura 8 – Comparação visual entre o canal original, as linhas de base e os realces na macro da íris (E0)



Fonte: Elaborada pelo autor (2026), a partir de fotografia de Reyes (2014).

Figura 9 – Detalhe ampliado de um trecho de 124×124 pixels do estroma da macro da íris (E0)



Fonte: Elaborada pelo autor (2026), a partir de fotografia de Reyes (2014).

Tabela 2 – Comparação por setores angulares de 30° (E1)


Conjunto	Algoritmo	<i>n</i>	Mediana CNR	Razão mediana (IC 95%)	Vitórias	<i>p</i> (Wilcoxon)
Olho completo	Frangi	12	6,16	1,85 (1,55–2,68)	12/12	< 0,001
	Gabor	11	3,65	1,21 (0,98–1,60)	8/11	0,021
	<i>Black-hat</i>	12	2,96	0,96 (0,75–1,86)	5/12	0,339
Macro da íris	Frangi	12	6,83	2,01 (1,61–2,21)	12/12	< 0,001
	Gabor	12	4,11	1,14 (1,01–1,34)	9/12	0,005
	<i>Black-hat</i>	12	3,65	0,99 (0,78–1,17)	4/12	0,849
Ambas	Frangi	24	6,69	1,92 (1,64–2,23)	24/24	< 0,001
	Gabor	23	4,10	1,17 (1,03–1,34)	17/23	< 0,001
	<i>Black-hat</i>	24	3,47	0,98 (0,78–1,18)	9/24	0,668
Olho completo (sem S1–S2)	Frangi	10	5,72	1,78 (1,45–2,81)	10/10	< 0,001
	Gabor	9	3,61	1,10 (0,86–1,60)	6/9	0,082
	<i>Black-hat</i>	10	2,79	0,85 (0,73–1,38)	3/10	0,722

Fonte: Elaborada pelo autor (2026).

Nota: Razão: CNR do realce dividida pela CNR da melhor linha de base do mesmo setor; IC 95%: intervalo de confiança por *bootstrap* percentil; vitórias: número de setores em que o realce supera a linha de base; *p*: teste de Wilcoxon pareado unilateral. Setores com CNR indefinida para o realce foram excluídos (*n* < 12).

No olho completo, a CNR ficou indefinida em alguns setores superiores, próximos à pálpebra, porque nenhum pixel do setor ultrapassou o limiar global do mapa: três setores (S3 a S5) para o original e o brilho, dois (S3 e S4) para o contraste e um (S4) para o banco de Gabor. Na macro da íris, todas as CNR foram definidas. A Figura 10 mostra a distribuição por método, e a Figura 11, o perfil angular. Na Figura 10, os valores atípicos elevados do banco de Gabor e do realce *black-hat* no olho completo correspondem aos setores S1 e S2, cobertos pelos cílios; na Figura 11, a interrupção da curva do banco de Gabor próximo de 105° corresponde ao setor com CNR indefinida.


Figura 10 – Distribuição da CNR por setor angular para cada método (E1)



Fonte: Elaborada pelo autor (2026), a partir de fotografias de Novák (2005) e de Reyes (2014).

Os maiores valores do filtro de Frangi no olho completo ocorreram justamente em S1 e S2 (11,53 e 10,85), onde os cílios atravessam a íris, e o realce *black-hat* também foi elevado nesses

Figura 11 – Perfil angular da CNR para a melhor linha de base, o filtro de Frangi e o banco de Gabor (E1)



Fonte: Elaborada pelo autor (2026), a partir de fotografias de Novák (2005) e de Reyes (2014).

Nota: Ângulo medido no sentido anti-horário a partir da direita.

setores (10,65 e 8,26). Para verificar se a vantagem dependia desse artefato, a análise foi repetida sem esses dois setores (últimas linhas da Tabela 2). O filtro de Frangi manteve a superioridade em 10 de 10 setores, com razão mediana de 1,78 (IC 95%: 1,45 a 2,81) e $p < 0,001$. O banco de Gabor passou a superar a linha de base em 6 de 9 setores, com razão de 1,10 (IC 95%: 0,86 a 1,60) e $p = 0,082$, e o realce *black-hat*, em 3 de 10. Conclui-se que a vantagem do filtro de Frangi não é explicada pelos cílios, ao passo que a do banco de Gabor no olho completo depende parcialmente deles.

7.3 DEFINIÇÃO DO LIMIAR DA MÉTRICA (E2)

A Tabela 3 compara a CNR com o limiar de Otsu calculado sobre o mapa inteiro, como na cadeia de análise, e restrito ao anel. A ordem entre os realces manteve-se: o filtro de Frangi continuou com a maior CNR (8,21 e 7,42 com o limiar no anel) e o banco de Gabor, em segundo lugar (6,35 e 4,25). Com o limiar no anel, a melhor linha de base passou a 3,79 e 3,02, de modo que as razões do filtro de Frangi foram de 2,16 e 2,46. O filtro de Frangi foi o método menos sensível à escolha, com variação inferior a 2%, o que é coerente com um mapa cujo fundo permanece próximo de zero em toda a imagem. O realce *black-hat* foi o mais sensível: sua CNR no olho completo passou de 4,38 para 5,89, e na macro ele passou a superar a melhor linha de base (3,45 contra 3,02). Esse comportamento indica que o mapa morfológico apresenta respostas intensas fora da íris (pálpebras e cílios), que deslocam o limiar global, e que o desempenho do realce *black-hat* é o mais dependente da definição da métrica.

Tabela 3 – CNR com o limiar de Otsu calculado sobre o mapa inteiro e restrito ao anel da íris (E2)

Método	Olho completo		Macro da íris	
	Otsu global	Otsu no anel	Otsu global	Otsu no anel
Original (verde)	3,22	3,66	3,54	2,98
Brilho +40	3,21	3,65	3,54	3,02
Contraste $\times 1,8$	3,49	3,79	3,62	2,94
CLAHE	3,26	3,43	3,34	2,91
Frangi	8,24	8,21	7,29	7,42
Gabor	5,90	6,35	4,31	4,25
<i>Black-hat</i>	4,38	5,89	3,56	3,45

Fonte: Elaborada pelo autor (2026).

Nota: Otsu global: limiar calculado sobre o mapa inteiro, padrão da cadeia de análise.

7.4 ESCALAS E NORMALIZAÇÃO DO FILTRO DE FRANGI (E3)

A Tabela 4 decompõe a resposta multiescala. A escala $\sigma = 1$ produziu a maior resposta em 98,7% dos pixels de estrutura do olho completo e em 99,9% dos da macro da íris, e a resposta média diminuiu de 5 a 13 vezes de $\sigma = 1$ para $\sigma = 2$. O máximo das respostas individuais coincidiu exatamente com a saída multiescala (diferença máxima nula), o que confirma a implementação. A CNR da escala $\sigma = 1$ isolada (8,29 e 7,33) é praticamente igual à da saída multiescala (8,24 e 7,29); o filtro comporta-se, portanto, como um filtro de escala única. A Figura 12 mostra que as escalas maiores realçam fibras mais largas (painéis c e d), mas essas respostas são encobertas no máximo. Esse comportamento decorre da ausência de normalização das derivadas pela escala, discutida na Seção 4, e indica que a normalização proposta por Lindeberg (1998) constitui ajuste prioritário para trabalhos futuros.

Tabela 4 – Decomposição por escala da resposta do filtro de Frangi (E3)


σ	Olho completo			Macro da íris		
	Dominância (%)	$\bar{V}_\sigma (\times 10^{-7})$	CNR	Dominância (%)	$\bar{V}_\sigma (\times 10^{-7})$	CNR
1	98,7	17,08	8,29	99,9	16,97	7,33
2	1,3	1,29	8,19	0,1	3,27	7,05
3	0,0	0,23	7,46	0,0	0,82	6,52
4	0,0	0,07	7,02	0,0	0,26	6,36
Multiescala	100,0	–	8,24	100,0	–	7,29

Fonte: Elaborada pelo autor (2026).

Nota: Dominância: fração dos pixels de estrutura em que a escala produz a maior resposta; $\bar{V}_\sigma$: resposta bruta média no anel; CNR: escala isolada, com a mesma normalização de saída.

A Tabela 5 mostra o efeito da normalização de saída sobre a CNR do mesmo mapa de Frangi. Sem a correção gama, a CNR sobe para 12,01 e 9,99; com normalização mínimo–máximo, para 24,39 e 10,70. Todas essas normalizações são crescentes e preservam a ordenação dos pixels,

Figura 12 – Respostas do filtro de Frangi por escala, saída multiescala e escala dominante na macro da íris (E3)



Fonte: Elaborada pelo autor (2026), a partir de fotografia de Reyes (2014).

Nota: Cada painel possui normalização própria.

mas, conforme observado após a Proposição 1, alteram a CNR. O valor muito elevado obtido com a normalização mínimo–máximo no olho completo é o efeito esperado quando poucas respostas muito intensas, como as dos cílios, comprimem as demais próximo de zero e reduzem σ_{bg} . Duas consequências decorrem desse resultado. Primeiro, a normalização adotada é a mais conservadora das três, de modo que a comparação da Seção 7.1 não favorece o filtro de Frangi. Segundo, valores absolutos de CNR só são comparáveis sob a mesma normalização, o que reforça a necessidade de uma medida invariante, como a AUC do fantoma (Seção 7.8).

Tabela 5 – Efeito da normalização de saída sobre a CNR do mapa de Frangi (E3)

Normalização do mapa de Frangi	CNR (Olho completo)	CNR (Macro da íris)
Percentis 2 e 99 com gama 0,7 (padrão)	8,24	7,29
Percentis 2 e 99, sem gama	12,01	9,99
Mínimo–máximo	24,39	10,70

Fonte: Elaborada pelo autor (2026).

Nota: As três transformações são crescentes; a primeira é a adotada na cadeia de análise.

7.5 SENSIBILIDADE A PARÂMETROS (E4)

A Tabela 6 apresenta a CNR obtida quando cada parâmetro é variado isoladamente. No filtro de Frangi, a CNR variou entre 6,95 e 9,15 no olho completo e entre 6,29 e 7,85 na macro da íris. O menor valor ocorreu com $c = 0,05$: com c pequeno, o termo de estruturalidade satura e respostas fracas do fundo passam a valer tanto quanto as fibras. Valores menores de β aumentaram a CNR ($\beta = 0,25$: 9,15 e 7,85), por tornarem o filtro mais seletivo a linhas. A remoção da escala $\sigma = 1$ reduziu a CNR (8,15 e 6,99), e o acréscimo de $\sigma = 5$ e $\sigma = 6$ não teve efeito, o que é coerente com a dominância da escala mais fina.

Tabela 6 – Sensibilidade da CNR aos parâmetros de cada realce (E4)

Algoritmo	Parâmetro	Valor	CNR (Olho completo)	CNR (Macro da íris)
Frangi	β	0,25	9,15	7,85
		0,50*	8,24	7,29
		0,75	7,94	7,10
		1,00	7,81	7,01
	c	0,05	6,95	6,29
		0,25	8,14	7,23
		1,00	8,24	7,29
		15,00*	8,24	7,29
	{ σ }	{1}	8,29	7,33
		{1, 2}	8,23	7,27
		{1, 2, 3, 4}*	8,24	7,29
		{2, 3, 4}	8,15	6,99
		{1, 2, 3, 4, 5, 6}	8,24	7,30
Gabor	λ	6	7,02	4,75
		8	6,41	4,50
		10*	5,90	4,31
		14	5,31	4,17
	σ	2	5,31	4,21
		3	5,68	4,25
		4*	5,90	4,31
		6	6,41	4,33
	n_θ	4	5,44	4,39
		8*	5,90	4,31
		12	5,92	4,27
Morfologia	escalas	{5}	7,63	4,50
		{11}	5,06	3,79
		{21}	3,89	3,47
		{5, 11, 21}*	4,38	3,56
		{5, 11, 21, 31}	3,95	3,43

Fonte: Elaborada pelo autor (2026).

Nota: Cada parâmetro é variado isoladamente; o asterisco e o negrito indicam a configuração padrão. Na varredura de σ do filtro de Gabor, o núcleo cresce para cobrir a envoltória.

No banco de Gabor, comprimentos de onda menores aumentaram a CNR ($\lambda = 6$: 7,02 e 4,75, contra 5,90 e 4,31 com $\lambda = 10$), o que sugere que as fibras visíveis nessas imagens são

mais finas que as sintonizadas pela configuração padrão. O aumento de σ elevou a CNR no olho completo (6,41 com $\sigma = 6$), mas quase não a alterou na macro da íris, e a passagem de 8 para 12 orientações teve efeito desprezível. Na morfologia, o elemento de 5 pixels isolado produziu a maior CNR (7,63 e 4,50), e os elementos maiores reduziram-na; a soma padrão de três escalas (4,38 e 3,56) ficou abaixo do elemento menor, pois os elementos grandes acrescentam respostas de baixa frequência, como sombras e regiões extensas, que diluem as estruturas finas.

Em todas as configurações testadas, o filtro de Frangi e o banco de Gabor permaneceram acima da melhor linha de base das duas imagens (3,49 e 3,62), ao passo que o realce *black-hat* ficou abaixo dela na macro da íris em três das cinco configurações. As configurações de maior CNR não foram adotadas como padrão, pois foram observadas nas mesmas duas imagens empregadas na avaliação, e sua adoção tornaria a comparação otimista. Essa escolha deve ser feita no conjunto rotulado, com dados de ajuste separados dos dados de teste.

7.6 ESCOLHA DO CANAL DE COR (E10)

A Tabela 7 compara os canais de entrada. O canal azul produziu a maior CNR nas seis comparações: no próprio canal (3,78 e 3,81), após o filtro de Frangi (8,61 e 7,57) e após o banco de Gabor (6,14 e 4,62). O canal verde, padrão da cadeia de análise, ficou em segundo lugar após o filtro de Frangi (8,24 e 7,29), e o vermelho apresentou o pior resultado do filtro de Frangi no olho completo (7,33). As diferenças entre os canais azul e verde são pequenas (entre 3,8% e 4,5% no filtro de Frangi) e foram observadas em duas íris de cor clara. Uma hipótese, não testada neste trabalho, é a de que, nessas íris, o contraste do estroma dependa mais do espalhamento da luz, mais intenso em comprimentos de onda curtos. O canal verde foi mantido por coerência com a literatura de retina, mas a escolha deve ser reavaliada no conjunto rotulado, com íris de diferentes pigmentações.

Tabela 7 – CNR no anel por canal de entrada (E10)

Canal	Olho completo			Macro da íris		
	Canal	Frangi	Gabor	Canal	Frangi	Gabor
Vermelho (R)	3,25	7,33	5,76	3,63	7,21	4,24
Verde (G)*	3,22	8,24	5,90	3,54	7,29	4,31
Azul (B)	3,78	8,61	6,14	3,81	7,57	4,62
Luminância (Y)	3,30	8,10	5,91	3,55	7,28	4,30

Fonte: Elaborada pelo autor (2026).

Nota: O asterisco indica o canal padrão da cadeia de análise.

7.7 ROBUSTEZ A PERTURBAÇÕES (E5)

A Tabela 8 mostra a concordância entre os mapas obtidos com e sem cada perturbação. Sob perturbações fotométricas (brilho, contraste e correção gama), todos os métodos mantiveram correlação de pelo menos 0,99 e coeficiente de Dice de pelo menos 0,91, resultado esperado porque a CLAHE renormaliza o contraste local antes dos realces. As perturbações que alteram a estrutura fina distinguiram os métodos. O filtro de Frangi foi o mais afetado: correlação de 0,90 e Dice de 0,75 com ruído, de 0,81 e 0,65 com desfoque e de 0,92 e 0,78 com compressão JPEG. O banco de Gabor foi o mais estável, com Dice médio de pelo menos 0,86 em todas as condições, e o realce *black-hat* ocupou posição intermediária. A Figura 13 ilustra o efeito sobre o filtro de Frangi: a alteração fotométrica quase não modifica o mapa, o ruído cria cristas espúrias e o desfoque funde as fibras finas.


Tabela 8 – Concordância entre os mapas sem e com perturbação (E5)

Perturbação	CLAHE		Frangi		Gabor		<i>Black-hat</i>	
	<i>r</i>	Dice	<i>r</i>	Dice	<i>r</i>	Dice	<i>r</i>	Dice
Brilho –30	0,99	0,96	1,00	0,98	1,00	0,97	1,00	0,96
Brilho +30	1,00	0,96	1,00	0,99	1,00	0,99	1,00	0,99
Contraste $\times 0,7$	0,99	0,97	1,00	0,94	1,00	0,94	1,00	0,91
Contraste $\times 1,3$	0,99	0,95	0,99	0,97	0,99	0,97	0,99	0,98
Gama 0,7	1,00	0,97	1,00	0,95	1,00	0,96	0,99	0,95
Gama 1,5	0,99	0,92	0,99	0,93	0,99	0,94	0,99	0,93
Ruído gaussiano ($\sigma = 8$)	0,96	0,92	0,90	0,75	0,99	0,94	0,92	0,77
Desfoque gaussiano ($\sigma = 1,5$)	0,97	0,94	0,81	0,65	0,98	0,86	0,90	0,77
Compressão JPEG ($q = 30$)	0,99	0,95	0,92	0,78	0,99	0,95	0,97	0,88
Média	0,99	0,95	0,96	0,88	0,99	0,95	0,97	0,90

Fonte: Elaborada pelo autor (2026).

Nota: Média das duas imagens. *r*: correlação de Pearson no anel; Dice: sobreposição das máscaras de estrutura.

Figura 13 – Trecho do mapa de Frangi sem perturbação e sob correção gama, ruído gaussiano e desfoque (E5)



Fonte: Elaborada pelo autor (2026), a partir de fotografia de Reyes (2014).


A razão entre a CNR com e sem perturbação ficou entre 0,78 e 1,10 para o filtro de Frangi, entre 0,96 e 1,13 para o banco de Gabor, entre 0,83 e 1,27 para o realce *black-hat* e entre 0,93 e

1,11 para a CLAHE. O máximo do filtro de Frangi ocorreu com desfoque no olho completo, a mesma perturbação em que o Dice médio se reduziu a 0,65: a CNR permaneceu elevada enquanto o conjunto de estruturas detectadas se alterou. A CNR mede quanto o mapa separa duas classes, e não se as estruturas são as mesmas; por esse motivo, a robustez deve ser avaliada com medidas de concordância, como o coeficiente de Dice e a correlação. A sensibilidade do filtro de Frangi ao ruído e ao desfoque é coerente com a dominância da escala $\sigma = 1$, a mais afetada por esses dois fatores.

7.8 FANTOMA COM VERDADE DE REFERÊNCIA (E6)

A Figura 14 mostra um fantoma com ruído $\sigma_n = 12$ e os mapas correspondentes, e a Tabela 9 resume as medidas nesse nível de ruído. O fantoma confirma a Proposição 1: o original e o brilho +40 apresentaram a mesma AUC até a sexta casa decimal em todos os níveis de ruído (0,685 com $\sigma_n = 12$), e o contraste $\times 1,8$ diferiu em menos de 0,001, por efeito da saturação. Na figura, observa-se que o filtro de Frangi responde também ao ruído fino, que o banco de Gabor preserva a continuidade das curvas e que o realce *black-hat* responde às manchas da textura de fundo.

Figura 14 – Fantoma sintético com ruído $\sigma_n = 12$, verdade de referência e mapas de realce (E6)



Fonte: Elaborada pelo autor (2026).

A Figura 15 apresenta a AUC em função do ruído. Com ruído baixo ($\sigma_n = 4$), o filtro de Frangi obteve a maior AUC (0,919), seguido do banco de Gabor (0,902), do realce *black-hat*

Tabela 9 – Medidas no fantoma com ruído $\sigma_n = 12$ (E6)


Método	AUC (média $\pm$ dp)	CNR com verdade	CNR por Otsu
Original (verde)	$0,685 \pm 0,029$	0,65	2,78
Brilho +40	$0,685 \pm 0,029$	0,65	2,78
Contraste $\times 1,8$	$0,684 \pm 0,028$	0,64	2,77
CLAHE	$0,751 \pm 0,020$	0,95	2,87
Frangi	$0,757 \pm 0,011$	1,06	5,44
Gabor	$0,879 \pm 0,013$	2,44	4,68
<i>Black-hat</i>	$0,628 \pm 0,017$	0,48	2,58

Fonte: Elaborada pelo autor (2026).

Nota: Média de 10 sementes. AUC por pixel com desvio-padrão (dp) entre sementes; CNR com verdade: estrutura e fundo definidos pela máscara verdadeira; CNR por Otsu: medida empregada nas imagens reais.

(0,869), da CLAHE (0,805) e do original (0,701). Com o aumento do ruído, o filtro de Frangi degradou rapidamente (0,827, 0,757, 0,711 e 0,657), igualando-se à CLAHE a partir de $\sigma_n = 12$ e aproximando-se do original com $\sigma_n = 24$. O banco de Gabor degradou lentamente (0,894, 0,879, 0,859 e 0,812) e foi o melhor método a partir de $\sigma_n = 8$. O realce *black-hat* apresentou desempenho inferior ao acaso com $\sigma_n = 24$ (AUC de 0,482): por somar as duas polaridades, ele responde também às manchas escuras da textura de fundo, visíveis na Figura 14. As curvas ROC da Figura 16 confirmam esse quadro com $\sigma_n = 12$.

Figura 15 – AUC por pixel em função do desvio-padrão do ruído no fantoma (E6)




Fonte: Elaborada pelo autor (2026).

Nota: Barras de um desvio-padrão entre sementes para os realces.

A comparação entre a CNR por Otsu e as medidas com verdade de referência constitui o resultado mais importante do fantoma para a interpretação das imagens reais. Nas 35 combinações de ruído e método, a CNR por Otsu apresentou correlação de Spearman de 0,76 com a AUC e de 0,73 com a CNR com verdade (ambas com $p < 0,001$): a métrica sem verdade de referência

Figura 16 – Curvas ROC agregadas no fantoma com $\sigma_n = 12$ (E6)



Fonte: Elaborada pelo autor (2026).

Nota: Curvas obtidas com a reunião dos pixels das 10 sementes; a AUC da legenda difere ligeiramente da média por semente da Tabela 9.

ordena os métodos de forma semelhante, mas não idêntica, à métrica com verdade. A discordância mais evidente envolve o filtro de Frangi. Com $\sigma_n = 12$, ele obteve a maior CNR por Otsu (5,44) e uma AUC (0,757) muito inferior à do banco de Gabor (0,879); entre $\sigma_n = 12$ e $\sigma_n = 24$, sua CNR por Otsu permaneceu em 5,44, enquanto a AUC se reduziu de 0,757 para 0,657. Um mapa esparso separa bem duas classes mesmo quando parte da estrutura detectada é ruído, e a CNR por Otsu não distingue essas duas situações. A vantagem do filtro de Frangi nas imagens reais deve, portanto, ser interpretada com essa ressalva: ela é compatível com o regime de ruído baixo, no qual o filtro de Frangi também é o melhor segundo a AUC, mas a CNR por Otsu, isoladamente, não permite afirmar em qual regime as imagens se encontram.

7.9 CUSTO COMPUTACIONAL (E7)

A Tabela 10 apresenta o tempo de cada etapa em uma imagem de 768×513 pixels. O filtro de Frangi foi a etapa mais custosa, com mediana de 659 ms, cerca de 12 vezes a do banco de Gabor (56 ms) e 46 vezes a do realce *black-hat* (14 ms); brilho, contraste e CLAHE demandaram menos de 0,5 ms. A detecção da pupila e do limbo demandou 24,5 ms, e a validação geométrica, alguns microssegundos. Mesmo o filtro de Frangi é viável para processamento em lote, pois mil imagens demandariam cerca de 11 minutos em um único núcleo. Os valores absolutos dependem da carga da máquina: em outras execuções do mesmo *script* ao longo deste trabalho, a mediana do filtro de Frangi variou entre aproximadamente 0,65 e 0,9 s e atingiu 1,4 s com outro processo intensivo

em paralelo. A ordem relativa entre os métodos, contudo, foi a mesma em todas as execuções.

Tabela 10 – Tempo de execução por etapa (E7)

Etapa	Mediana (ms)	Mínimo (ms)	Máximo (ms)
Brilho +40	0,15	0,15	0,18
Contraste $\times 1,8$	0,15	0,15	0,16
CLAHE	0,46	0,40	0,60
Frangi	659,1	617,1	766,1
Gabor	55,9	49,2	62,7
<i>Black-hat</i>	14,3	13,2	14,8
Detecção pupila/íris	24,5	22,6	26,5
Validação geométrica	0,003	0,002	0,009


Fonte: Elaborada pelo autor (2026).

Nota: Valores em milissegundos: mediana, mínimo e máximo de sete execuções após uma de aquecimento, em processador Intel Core i7 de 12.^a geração.

7.10 NORMALIZAÇÃO POLAR E PERFIL RADIAL (E8)

A Figura 17 mostra o anel do olho completo desdobrado em coordenadas polares, para o canal verde com CLAHE e para o mapa de Frangi, com o raio crescendo da borda pupilar, na parte superior, para o limbo, na parte inferior. A faixa de cílios aparece entre aproximadamente 15° e 65° e domina o mapa de Frangi nessa região, ao passo que o reflexo claro entre 0° e 40° aparece no canal verde. Fora dessas regiões, o mapa evidencia as fibras radiais como linhas aproximadamente verticais, isto é, alinhadas com a direção radial.

Figura 17 – Anel do olho completo desdobrado pela normalização *rubber sheet*: canal verde com CLAHE e mapa de Frangi (E8)




Fonte: Elaborada pelo autor (2026), a partir de fotografia de Novák (2005).

A Figura 18 mostra a fração de pixels de estrutura em cada raio normalizado. No terço interno do anel, que corresponde aproximadamente à zona pupilar, essa fração foi de 3,1% no olho completo e de 3,7% na macro da íris; nos dois terços externos, de 6,6% e 8,8%, isto é,

2,1 e 2,4 vezes maior. Os dois perfis apresentam um mínimo local próximo de $r \approx 0,33$. Uma explicação possível é a coincidência dessa posição com a do colarete, faixa larga que a escala dominante $\sigma = 1$ não realça; sua verificação exigiria a marcação do colarete nas imagens. No olho completo, a fração diminui nas proximidades do limbo, região em que o círculo de Hough não coincide com o limbo real.

Figura 18 – Fração de pixels de estrutura do mapa de Frangi em função do raio normalizado (E8)



Fonte: Elaborada pelo autor (2026), a partir de fotografias de Novák (2005) e de Reyes (2014).

Nota: A faixa sombreada indica, de forma aproximada, o terço interno do anel, sem corresponder a uma delimitação anatômica medida.


Como a cadeia de análise já extrai descritores sobre a íris normalizada, mapas de realce desdobrados dessa forma podem alimentar diretamente descritores radiais e setoriais de densidade de estruturas, candidatos a correlatos de vascularização nas próximas etapas.

7.11 VALIDAÇÃO DA PUPILA (E9)

7.11.1 Fotografia do olho completo

Na fotografia do olho completo (Figura 19), a detecção encontrou pupila com diâmetro de 162 px e limbo com diâmetro de 402 px, com anel de 120 px de largura. Os descritores foram $\rho = 0,40$, $\tau = 0,60$ e $\epsilon = 0,27$, e o validador atribuiu o rótulo `valid`, com pontuação 1,00. Com o diâmetro médio da íris como referência (Rüfer; Schröder; Erb, 2005), a escala estimada é de 34,3 px/mm e o diâmetro pupilar, de aproximadamente 4,7 mm, dentro da faixa de 2 a 8 mm. Duas ressalvas são necessárias. Primeiro, a Figura 4 mostra que o círculo de Hough está deslocado para a direita e não alcança o limbo real no lado esquerdo; o diâmetro da íris está, portanto, provavelmente subestimado, e, em consequência, ρ e a estimativa em milímetros tendem a estar superestimados. Segundo, a excentricidade de 0,27 encontra-se próxima do limite de 0,30 e reflete sobretudo esse erro de detecção; um erro ligeiramente maior alteraria o rótulo para `borderline`.

Figura 19 – Validação da pupila na fotografia do olho completo (E9)



Fonte: Elaborada pelo autor (2026), a partir de fotografia de Novák (2005).

Nota: Pupila em verde e limbo em azul; os descritores e o rótulo aparecem na caixa semitransparente.

7.11.2 Casos sintéticos


A Tabela 11 apresenta sete geometrias construídas para percorrer as fronteiras do validador, com raio da íris de 100 px. Os rótulos seguem as regras do Algoritmo 2: a geometria normal recebe **valid**; miose ($\rho = 0,18$), midríase moderada ($\rho = 0,72$) e excentricidade de 0,40 recebem **borderline**; miose extrema ($\rho = 0,12$) e anel fino ($\rho = 0,88$) violam a faixa plausível e recebem **invalid**. A midríase com $\rho = 0,78$ situa-se dentro da faixa plausível, mas acumula duas penalidades (faixa de atenção e anel com $\tau = 0,22$), o que reduz a pontuação a 0,45 e leva ao rótulo **invalid**. A Figura 20 mostra a pontuação em função de ρ , e a Figura 21, as regiões de decisão no plano (ρ, ϵ) , nas quais a região **valid** corresponde ao retângulo $0,20 \leq \rho \leq 0,70$, $\epsilon \leq 0,30$, e a imagem real se situa próxima de sua borda superior.

Tabela 11 – Classificação do validador em casos sintéticos (E9)

Caso	ρ	τ	ϵ	Pontuação	Rótulo
Normal	0,40	0,60	0,00	1,00	valid
Miose	0,18	0,82	0,00	0,75	borderline
Miose extrema	0,12	0,88	0,00	0,40	invalid
Midríase moderada	0,72	0,28	0,00	0,75	borderline
Midríase	0,78	0,22	0,00	0,45	invalid
Excêntrica	0,40	0,60	0,40	0,70	borderline
Anel fino	0,88	0,12	0,00	0,10	invalid

Fonte: Elaborada pelo autor (2026).


Figura 20 – Pontuação do validador em função da razão pupila/íris, com pupila centrada (E9)



Fonte: Elaborada pelo autor (2026).

Nota: As linhas pontilhadas marcam os limites 0,15, 0,20, 0,70, 0,75 (critério de espessura) e 0,80; o ponto azul representa a imagem real.

Figura 21 – Regiões de decisão do validador no plano (ρ, ϵ) (E9)



Fonte: Elaborada pelo autor (2026).

Nota: Quadrados: casos sintéticos; círculo: imagem real.

7.11.3 Estabilidade da detecção e da validação

A Tabela 12 apresenta os resultados em 15 condições. Nas sete condições em que a transformada de Hough encontrou o limbo (original, reduções para 384 e 576 px, rotação, espelhamento, brilho +30 e compressão JPEG), os descritores permaneceram estáveis, com ρ entre 0,36 e 0,41 e ϵ entre 0,17 e 0,30, todos com rótulo **valid**. Na compressão JPEG, contudo, ϵ atingiu 0,296, a menos de 0,005 do limite. Nas outras oito condições, o limbo não foi encontrado e o raio da íris proveio da estimativa de reserva; em duas delas (brilho -30 e correção gama 1,5), a própria pupila também foi estimada. No conjunto, ρ apresentou média de 0,34, desvio-padrão de 0,08 (coeficiente de variação de 23,6%) e amplitude de 0,17 a 0,41, e 13 das 15 condições receberam o rótulo **valid**.

Tabela 12 – Estabilidade da detecção e da validação em 15 condições (E9)

Condição	D_p (px)	D_i (px)	ρ	τ	ϵ	Rótulo
Original (768 px)	162	402	0,40	0,60	0,27	valid
Escala 384 px	80	220	0,36	0,64	0,17	valid
Escala 576 px	122	312	0,39	0,61	0,23	valid
Escala 1152 px	244	739 [†]	0,33	0,67	0,00	valid
Rotação 10°	162	406	0,40	0,60	0,26	valid
Espelhamento horizontal	162	404	0,40	0,60	0,27	valid
Brilho -30	82 [‡]	492 [†]	0,17	0,83	0,00	borderline
Brilho +30	162	402	0,40	0,60	0,27	valid
Contraste $\times 0,7$	186	492 [†]	0,38	0,62	0,00	valid
Contraste $\times 1,3$	153	492 [†]	0,31	0,69	0,00	valid
Gama 0,7	140	492 [†]	0,29	0,71	0,00	valid
Gama 1,5	82 [‡]	492 [†]	0,17	0,83	0,00	borderline
Ruído gaussiano ($\sigma = 8$)	164	492 [†]	0,33	0,67	0,00	valid
Desfoque gaussiano ($\sigma = 1,5$)	164	492 [†]	0,33	0,67	0,00	valid
Compressão JPEG ($q = 30$)	163	394	0,41	0,59	0,30	valid

Fonte: Elaborada pelo autor (2026).

Nota: †: raio da íris estimado (limbo não encontrado); ‡: pupila estimada.

As falhas na detecção da pupila sob escurecimento têm causa identificável. Com brilho -30 e correção gama 1,5, o percentil 3 da imagem aproxima-se de zero e o limiar do detector passa a 20 e 21 níveis; a máscara escura cresce de 7,0% da imagem para 18,9% e 17,3%, e a maior região escura, que no original correspondia à pupila (17.662 px², circularidade 0,85), passa a fundir a pupila com as partes escuras da íris (62.670 e 57.614 px², circularidade 0,39 e 0,37). Nenhum candidato atinge a circularidade mínima de 0,55, e o detector recorre à estimativa. O limiar relativo ao percentil, adequado à imagem original, torna-se frágil quando o histograma é comprimido nos tons escuros.

O achado mais relevante para a cadeia de análise, contudo, é outro: o validador classificou como **valid** seis condições em que a geometria foi estimada, e não medida. Nas estimativas de reserva, a íris é centrada na pupila, o que força $\epsilon = 0$, e, nesta imagem, o raio estimado (48%

do menor lado) produz valores de ρ dentro da faixa normal. O validador recebe apenas raios e centros e não tem como distinguir uma geometria medida de uma geometria preenchida por padrão. Os indicadores de estimativa produzidos pelo detector precisam, portanto, ser propagados para o validador, de modo que uma geometria estimada nunca seja classificada como valid.

8 DISCUSSÃO

8.1 RESPOSTAS ÀS QUESTÕES DE PESQUISA

Quanto à questão Q1, ajustes de brilho e de contraste não podem aumentar a separabilidade entre estruturas e fundo (Proposição 1), e os experimentos confirmaram esse comportamento nas imagens reais e no fantoma. Entre os realces, o filtro de Frangi produziu o maior ganho, de 2,36 e 2,02 vezes a CNR da melhor linha de base, superou essa linha de base em todos os 24 setores e manteve a vantagem quando os setores contaminados pelos cílios foram excluídos. O banco de Gabor apresentou ganho menor, mas consistente no conjunto de setores. O realce *black-hat*, na configuração padrão, não apresentou ganho consistente, e seu desempenho depende mais da definição da métrica e das escalas escolhidas. A resposta a Q1 é, portanto, afirmativa para o filtro de Frangi e para o banco de Gabor, com a ressalva de que se apoia em duas imagens.

Quanto à questão Q2, a resposta é parcial. A CNR por Otsu ordenou os métodos de forma semelhante à AUC no fantoma (correlação de Spearman de 0,76), mas superestimou o filtro de Frangi sob ruído, porque mapas esparsos separam bem duas classes mesmo quando parte da estrutura detectada é ruído. Além disso, a CNR depende da normalização de saída de cada método (E3) e, para alguns métodos, da região em que o limiar é calculado (E2). A CNR é útil para comparar métodos em uma mesma imagem sob um protocolo fixo, mas não deve ser interpretada como medida absoluta de qualidade nem comparada entre normalizações diferentes. Sempre que houver verdade de referência, ela deve ser acompanhada da AUC.

Quanto à questão Q3, a variação dos parâmetros não alterou a conclusão principal: o filtro de Frangi e o banco de Gabor permaneceram acima da melhor linha de base em todas as configurações testadas. O filtro de Frangi é, no entanto, o mais sensível ao ruído, ao desfoque e à compressão e, no fantoma, degradou rapidamente com o ruído, ao passo que o banco de Gabor foi o mais estável nas duas análises. Os dois resultados têm a mesma origem: na implementação utilizada, o filtro de Frangi opera quase exclusivamente na escala mais fina. O custo de todos os métodos é compatível com processamento em lote.

Quanto à questão Q4, o validador comportou-se conforme projetado nos casos sintéticos e classificou a imagem real como *valid*. A cadeia de detecção e validação, porém, mostrou-se frágil: o limbo não foi encontrado em 8 das 15 condições, e a pupila, em 2. O problema mais grave é que as estimativas de reserva produzem geometrias plausíveis, aceitas pelo validador. O validador cumpre seu papel apenas quando recebe medidas reais, de modo que a robustez da cadeia depende da detecção.

Quanto à questão Q5, os resultados mostram que os métodos funcionam conforme esperado e permitem compará-los, mas nada revelam sobre o DM2: nenhuma imagem possui

rótulo clínico, e as estruturas realçadas não foram validadas contra a densidade vascular. As limitações são detalhadas na Seção 8.3.

8.2 IMPLICAÇÕES PARA A CADEIA DE ANÁLISE

Os resultados conduzem às seguintes recomendações práticas:

- a) empregar o filtro de Frangi como mapa principal de estruturas finas em imagens de boa qualidade e o banco de Gabor como complemento, ou como alternativa quando o ruído for relevante, observando que o banco de Gabor fornece também a orientação local, útil para descritores de fibras radiais;
- b) normalizar as derivadas do filtro de Frangi pela escala antes de utilizar a saída multiescala, para que as fibras mais largas contribuam para o mapa;
- c) revisar a configuração morfológica, uma vez que o elemento de 5 pixels isolado superou a soma de três escalas e que a soma das duas polaridades responde a manchas escuras do fundo;
- d) reavaliar o canal de entrada no conjunto rotulado, já que o canal azul foi ligeiramente superior ao verde nas duas imagens;
- e) propagar os indicadores de estimativa do detector para o validador, rebaixando qualquer geometria estimada, e reduzir a dependência fotométrica da detecção do limbo, por exemplo, com normalização de contraste antes da transformada de Hough ou com o operador integro-diferencial;
- f) medir os descritores de realce sobre a íris normalizada, por setor e por raio, excluindo as regiões marcadas como oclusão (cílios e pálpebras).

8.3 LIMITAÇÕES E AMEAÇAS À VALIDADE

As principais limitações deste estudo e as ameaças à validade de suas conclusões são as seguintes:

- a) dados: apenas duas fotografias públicas, sem rótulo clínico, uma delas com pós-processamento artístico; os valores- p da análise por setores descrevem a consistência dentro de cada imagem, e não a generalização para outras íris;
- b) ausência do conjunto rotulado: o conjunto rotulado para DM2 não estava disponível nesta etapa, de modo que nenhuma associação com a doença foi testada;
- c) modalidade: fotografias RGB não medem fluxo nem densidade vascular, e as estruturas realçadas incluem trabéculas, bordas de criptas e, em parte, vasos;
- d) métrica: a CNR por Otsu depende da normalização de saída, da região do limiar e do nível de ruído e favorece mapas esparsos, ao passo que a AUC foi medida apenas no fantoma;

- e) fantoma: o modelo emprega curvas claras de 1 a 3 pixels, ruído gaussiano e textura suave, sem reproduzir reflexos, cílios, pálpebras, artefatos de compressão ou estruturas escuras, como criptas;
- f) detecção: o detector utiliza limiares fixos e heurísticos, a transformada de Hough mostrou-se sensível à escala e à fotometria, e as estimativas de reserva produzem geometrias de aparência plausível;
- g) validador: as faixas de ρ derivam de valores populacionais publicados, enquanto o limite de excentricidade e as penalidades constituem escolhas de projeto, não ajustadas a dados;
- h) parâmetros: a configuração padrão não foi otimizada, e há configurações com CNR maior, cujo ajuste exige dados separados dos utilizados na avaliação;
- i) tempo de execução: os tempos dependem da máquina e da carga, de modo que apenas a ordem relativa entre os métodos deve ser generalizada.

9 CONCLUSÃO E TRABALHOS FUTUROS

Esta etapa cumpriu as duas metas definidas ao término do PGC I. Três algoritmos consolidados de realce de estruturas finas, a saber, o filtro de Frangi, o banco de filtros de Gabor e a morfologia *top-hat/black-hat*, foram integrados à cadeia de análise e avaliados por um protocolo reprodutível de onze experimentos, e um validador da geometria pupila-íris baseado em faixas fisiológicas foi implementado e testado. O filtro de Frangi foi o realce com maior separação entre estruturas e fundo nas imagens reais, com vantagem consistente entre regiões da íris. O banco de Gabor apresentou ganho menor, mas foi o mais estável sob ruído, desfoque e compressão e o melhor no fantoma com ruído moderado ou alto. O validador classificou corretamente os casos sintéticos e a imagem real.

Três lições metodológicas orientam as próximas etapas. A primeira é que ajustes de brilho e de contraste não podem, por construção, tornar estruturas mais separáveis do fundo e, por isso, não constituem linha de base suficiente para o realce. A segunda é que a métrica sem verdade de referência precisa ser interpretada com cautela, pois depende da normalização de saída e superestima mapas esparsos sob ruído. A terceira é que a vulnerabilidade da validação geométrica não reside nas regras de classificação, mas na detecção do limbo e no tratamento das estimativas de reserva.

Como trabalhos futuros, propõe-se:

- a) aplicar os realces ao conjunto rotulado para DM2, sob particionamento *person-based*, extraindo descritores de densidade de estruturas por setor e por raio sobre a íris normalizada, e testar sua associação com o rótulo em comparação com a linha de base da cadeia de análise;
- b) normalizar as derivadas do filtro de Frangi pela escala (Lindeberg, 1998) e avaliar a variante proposta por Jerman et al. (2016);
- c) ajustar parâmetros como β , λ , as escalas morfológicas e o canal de entrada em dados de ajuste separados dos dados de teste;
- d) anotar manualmente as estruturas finas em um pequeno conjunto de imagens da íris, de modo a medir a AUC em imagens reais;
- e) reduzir a sensibilidade da detecção à fotometria e à escala, com normalização de contraste antes da transformada de Hough, operador integro-diferencial (Daugman, 2004) ou contornos ativos (Kass; Witkin; Terzopoulos, 1988), e propagar os indicadores de estimativa para o validador;
- f) aprender os limiares do validador a partir de dados com rótulo de qualidade, utilizando o vetor de descritores que ele já fornece;

- g) calibrar a escala em milímetros quando a resolução ou a distância de aquisição forem conhecidas, de modo a aproximar o diâmetro pupilar absoluto, biomarcador candidato do DM2 (Cui et al., 2024; Thakar et al., 2025).

Em síntese, os resultados desta etapa indicam que fotografias RGB convencionais permitem realçar, de forma reprodutível, estruturas finas do estroma iridiano e verificar a plausibilidade da geometria pupila-íris. Essas condições são necessárias, mas não suficientes, para a extração de correlatos de biomarcadores oculares do DM2: a existência de associação entre os descritores derivados dos realces e o diagnóstico permanece uma hipótese, cuja verificação depende da aplicação dos métodos ao conjunto rotulado e constitui o foco da próxima etapa do projeto.

REFERÊNCIAS

ABRÀMOFF, M. D.; GARVIN, M. K.; SONKA, M. Retinal imaging and image analysis. **IEEE Reviews in Biomedical Engineering**, [S. l.], v. 3, p. 169-208, 2010. DOI: 10.1109/RBME.2010.2084567.

BOWYER, K. W.; HOLLINGSWORTH, K.; FLYNN, P. J. Image understanding for iris biometrics: a survey. **Computer Vision and Image Understanding**, [S. l.], v. 110, n. 2, p. 281-307, 2008. DOI: 10.1016/j.cviu.2007.08.005.

BRADSKI, G. The OpenCV library. **Dr. Dobb's Journal of Software Tools**, [S. l.], 2000.

CHAUDHURI, S.; CHATTERJEE, S.; KATZ, N.; NELSON, M.; GOLDBAUM, M. Detection of blood vessels in retinal images using two-dimensional matched filters. **IEEE Transactions on Medical Imaging**, [S. l.], v. 8, n. 3, p. 263-269, 1989. DOI: 10.1109/42.34715.

CUI, L.; XIAO, Y.; XIANG, Z.; CHEN, Z.; YANG, C.; ZOU, H. Study on the correlation between iris blood flow, iris thickness and pupil diameter in the resting state and after pharmacological mydriasis in patients with diabetes mellitus. **BMC Ophthalmology**, [S. l.], v. 24, n. 1, art. 52, 2024. DOI: 10.1186/s12886-024-03322-y.

DAUGMAN, J. G. Uncertainty relation for resolution in space, spatial frequency, and orientation optimized by two-dimensional visual cortical filters. **Journal of the Optical Society of America A**, [S. l.], v. 2, n. 7, p. 1160-1169, 1985. DOI: 10.1364/JOSAA.2.001160.

DAUGMAN, J. G. High confidence visual recognition of persons by a test of statistical independence. **IEEE Transactions on Pattern Analysis and Machine Intelligence**, [S. l.], v. 15, n. 11, p. 1148-1161, 1993. DOI: 10.1109/34.244676.

DAUGMAN, J. How iris recognition works. **IEEE Transactions on Circuits and Systems for Video Technology**, [S. l.], v. 14, n. 1, p. 21-30, 2004. DOI: 10.1109/TCSVT.2003.818350.

DICE, L. R. Measures of the amount of ecologic association between species. **Ecology**, [S. l.], v. 26, n. 3, p. 297-302, 1945. DOI: 10.2307/1932409.

DUDA, R. O.; HART, P. E. Use of the Hough transformation to detect lines and curves in pictures. **Communications of the ACM**, [S. l.], v. 15, n. 1, p. 11-15, 1972. DOI: 10.1145/361237.361242.

EFRON, B. Bootstrap methods: another look at the jackknife. **The Annals of Statistics**, [S. l.], v. 7, n. 1, p. 1-26, 1979. DOI: 10.1214/aos/1176344552.

ERNST, E. Iridology: not useful and potentially harmful. **Archives of Ophthalmology**, [S. l.], v. 118, n. 1, p. 120-121, 2000. DOI: 10.1001/archopht.118.1.120.

FAWCETT, T. An introduction to ROC analysis. **Pattern Recognition Letters**, [S. l.], v. 27, n. 8, p. 861-874, 2006. DOI: 10.1016/j.patrec.2005.10.010.

FRANGI, A. F.; NIESSEN, W. J.; VINCKEN, K. L.; VIERGEVER, M. A. Multiscale vessel enhancement filtering. In: INTERNATIONAL CONFERENCE ON MEDICAL IMAGE COMPUTING AND COMPUTER-ASSISTED INTERVENTION, 1., 1998, Cambridge. **Proceedings** [. . .]. Berlin: Springer, 1998. p. 130-137. (Lecture Notes in Computer Science, v. 1496). DOI: 10.1007/BFb0056195.

FRAZ, M. M.; REMAGNINO, P.; HOPPE, A.; UYYANONVARA, B.; RUDNICKA, A. R.; OWEN, C. G.; BARMAN, S. A. Blood vessel segmentation methodologies in retinal images: a survey. **Computer Methods and Programs in Biomedicine**, [S. l.], v. 108, n. 1, p. 407-433, 2012. DOI: 10.1016/j.cmpb.2012.03.009.

GABOR, D. Theory of communication. Part 1: the analysis of information. **Journal of the Institution of Electrical Engineers - Part III: Radio and Communication Engineering**, [S. l.], v. 93, n. 26, p. 429-441, 1946. DOI: 10.1049/ji-3-2.1946.0074.

GONZALEZ, R. C.; WOODS, R. E. **Digital image processing**. 4. ed. New York: Pearson, 2018.

GULSHAN, V. et al. Development and validation of a deep learning algorithm for detection of diabetic retinopathy in retinal fundus photographs. **JAMA**, [S. l.], v. 316, n. 22, p. 2402-2410, 2016. DOI: 10.1001/jama.2016.17216.

HANLEY, J. A.; MCNEIL, B. J. The meaning and use of the area under a receiver operating characteristic (ROC) curve. **Radiology**, [S. l.], v. 143, n. 1, p. 29-36, 1982. DOI: 10.1148/radiology.143.1.7063747.

HARRIS, C. R. et al. Array programming with NumPy. **Nature**, [S. l.], v. 585, n. 7825, p. 357-362, 2020. DOI: 10.1038/s41586-020-2649-2.

HOOVER, A. D.; KOUZNETSOVA, V.; GOLDBAUM, M. Locating blood vessels in retinal images by piecewise threshold probing of a matched filter response. **IEEE Transactions on Medical Imaging**, [S. l.], v. 19, n. 3, p. 203-210, 2000. DOI: 10.1109/42.845178.

HUNTER, J. D. Matplotlib: a 2D graphics environment. **Computing in Science & Engineering**, [S. l.], v. 9, n. 3, p. 90-95, 2007. DOI: 10.1109/MCSE.2007.55.

JAIN, A. K.; FARROKHNI, F. Unsupervised texture segmentation using Gabor filters. **Pattern Recognition**, [S. l.], v. 24, n. 12, p. 1167-1186, 1991. DOI: 10.1016/0031-3203(91)90143-S.

JERMAN, T.; PERNUŠ, F.; LIKAR, B.; ŠPICLIN, Ž. Enhancement of vascular structures in 3D and 2D angiographic images. **IEEE Transactions on Medical Imaging**, [S. l.], v. 35, n. 9, p. 2107-2118, 2016. DOI: 10.1109/TMI.2016.2550102.

KASS, M.; WITKIN, A.; TERZOPOULOS, D. Snakes: active contour models. **International Journal of Computer Vision**, [S. l.], v. 1, n. 4, p. 321-331, 1988. DOI: 10.1007/BF00133570.

KOENDERINK, J. J. The structure of images. **Biological Cybernetics**, [S. l.], v. 50, n. 5, p. 363-370, 1984. DOI: 10.1007/BF00336961.

LINDEBERG, T. Edge detection and ridge detection with automatic scale selection. **International Journal of Computer Vision**, [S. l.], v. 30, n. 2, p. 117-156, 1998. DOI: 10.1023/A:1008097225773.

MENDONÇA, A. M.; CAMPILHO, A. Segmentation of retinal blood vessels by combining the detection of centerlines and morphological reconstruction. **IEEE Transactions on Medical Imaging**, [S. l.], v. 25, n. 9, p. 1200-1213, 2006. DOI: 10.1109/TMI.2006.879955.

NOVÁK, P. **Eye iris**. 2005. 1 fotografia, color. Licença CC BY-SA 2.5. Disponível em: https://commons.wikimedia.org/wiki/File:Eye_iris.jpg. Acesso em: 7 out. 2026.

OTSU, N. A threshold selection method from gray-level histograms. **IEEE Transactions on Systems, Man, and Cybernetics**, [S. l.], v. 9, n. 1, p. 62-66, 1979. DOI: 10.1109/TSMC.1979.4310076.

PECH-PACHECO, J. L.; CRISTÓBAL, G.; CHAMORRO-MARTÍNEZ, J.; FERNÁNDEZ-VALDIVIA, J. Diatom autofocusing in brightfield microscopy: a comparative study. In: INTERNATIONAL CONFERENCE ON PATTERN RECOGNITION, 15., 2000, Barcelona. **Proceedings** [...]. Los Alamitos: IEEE Computer Society, 2000. v. 3, p. 314-317. DOI: 10.1109/ICPR.2000.903548.

PEDREGOSA, F. et al. Scikit-learn: machine learning in Python. **Journal of Machine Learning Research**, [S. l.], v. 12, n. 85, p. 2825-2830, 2011. Disponível em: <https://jmlr.org/papers/v12/pedregosa11a.html>. Acesso em: 7 out. 2026.

PIZER, S. M.; AMBURN, E. P.; AUSTIN, J. D.; CROMARTIE, R.; GESELOWITZ, A.; GREER, T.; TER HAAR ROMENY, B.; ZIMMERMAN, J. B.; ZUIDERVELD, K. Adaptive histogram equalization and its variations. **Computer Vision, Graphics, and Image Processing**, [S. l.], v. 39, n. 3, p. 355-368, 1987. DOI: 10.1016/S0734-189X(87)80186-X.

REYES, C. A. **Iris eclipse - Explored**. 2014. 1 fotografia, color. Licença CC BY 2.0. Disponível em: https://commons.wikimedia.org/wiki/File:Iris_eclipse_-_Explored_-_Flickr_-_creyesk.jpg. Acesso em: 7 out. 2026.

RICCI, E.; PERFETTI, R. Retinal blood vessel segmentation using line operators and support vector classification. **IEEE Transactions on Medical Imaging**, [S. l.], v. 26, n. 10, p. 1357-1365, 2007. DOI: 10.1109/TMI.2007.898551.

ROBERTS, P. K.; GOLDSTEIN, D. A.; FAWZI, A. A. Anterior segment optical coherence tomography angiography for identification of iris vasculature and staging of iris neovascularization: a pilot study. **Current Eye Research**, [S. l.], v. 42, n. 8, p. 1136-1142, 2017. DOI: 10.1080/02713683.2017.1293113.

RÜFER, F.; SCHRÖDER, A.; ERB, C. White-to-white corneal diameter: normal values in healthy humans obtained with the Orbscan II topography system. **Cornea**, [S. l.], v. 24, n. 3, p. 259-261, 2005. DOI: 10.1097/01.ico.0000148312.01805.53.

SAMANT, P.; AGARWAL, R. Machine learning techniques for medical diagnosis of diabetes using iris images. **Computer Methods and Programs in Biomedicine**, [S. l.], v. 157, p. 121-128, 2018. DOI: 10.1016/j.cmpb.2018.01.004.

SATO, Y.; NAKAJIMA, S.; SHIRAGA, N.; ATSUMI, H.; YOSHIDA, S.; KOLLER, T.; GERIG, G.; KIKINIS, R. Three-dimensional multi-scale line filter for segmentation and visualization of curvilinear structures in medical images. **Medical Image Analysis**, [S. l.], v. 2, n. 2, p. 143-168, 1998. DOI: 10.1016/S1361-8415(98)80009-1.

SHANNON, C. E. A mathematical theory of communication. **Bell System Technical Journal**, [S. l.], v. 27, n. 3, p. 379-423, 1948. DOI: 10.1002/j.1538-7305.1948.tb01338.x.

SIMON, A.; WORTHEN, D. M.; MITAS, J. A. An evaluation of iridology. **JAMA**, [S. l.], v. 242, n. 13, p. 1385-1389, 1979. DOI: 10.1001/jama.1979.03300130029014.

SOARES, J. V. B.; LEANDRO, J. J. G.; CESAR JUNIOR, R. M.; JELINEK, H. F.; CREE, M. J. Retinal vessel segmentation using the 2-D Gabor wavelet and supervised classification. **IEEE Transactions on Medical Imaging**, [S. l.], v. 25, n. 9, p. 1214-1222, 2006. DOI: 10.1109/TMI.2006.879967.

SOILLE, P. **Morphological image analysis: principles and applications**. 2. ed. Berlin: Springer, 2004. DOI: 10.1007/978-3-662-05088-0.

SPEARMAN, C. The proof and measurement of association between two things. **The American Journal of Psychology**, [S. l.], v. 15, n. 1, p. 72-101, 1904. DOI: 10.2307/1412159.

STAAL, J.; ABRÀMOFF, M. D.; NIEMEIJER, M.; VIERGEVER, M. A.; VAN GINNEKEN, B. Ridge-based vessel segmentation in color images of the retina. **IEEE Transactions on Medical Imaging**, [S. l.], v. 23, n. 4, p. 501-509, 2004. DOI: 10.1109/TMI.2004.825627.

SURYA, J.; TAMILSELVI, S.; ROY, M.; CHINNASAMY, S.; RAMAN, R.; SUCHETHA, M.; RAJENDRAN, G. Machine learning-based prediction of diabetic retinopathy from pupillary abnormalities in a South Indian population. **PLOS One**, [S. l.], v. 21, n. 1, e0340802, 2026. DOI: 10.1371/journal.pone.0340802.

THAKAR, M.; TRIPATHY, S. P.; DUTTA, P.; BHATTACHARYA, S.; DHAKA, U. Quantitative automated pupillometry in diabetic patients and correlation with retinal nerve fibre layer thickness. **Eye**, [S. l.], v. 39, n. 10, p. 1983-1989, 2025. DOI: 10.1038/s41433-025-03793-3.

VAN DER WALT, S.; SCHÖNBERGER, J. L.; NUNEZ-IGLESIAS, J.; BOULOGNE, F.; WARNER, J. D.; YAGER, N.; GOUILLART, E.; YU, T. scikit-image: image processing in Python. **PeerJ**, [S. l.], v. 2, e453, 2014. DOI: 10.7717/peerj.453.

VIRTANEN, P. et al. SciPy 1.0: fundamental algorithms for scientific computing in Python. **Nature Methods**, [S. l.], v. 17, n. 3, p. 261-272, 2020. DOI: 10.1038/s41592-019-0686-2.

WATSON, A. B.; YELLOTT, J. I. A unified formula for light-adapted pupil size. **Journal of Vision**, [S. l.], v. 12, n. 10, art. 12, 2012. DOI: 10.1167/12.10.12.

WELVAERT, M.; ROSSEEL, Y. On the definition of signal-to-noise ratio and contrast-to-noise ratio for fMRI data. **PLoS ONE**, [S. l.], v. 8, n. 11, e77089, 2013. DOI: 10.1371/journal.pone.0077089.

WILCOXON, F. Individual comparisons by ranking methods. **Biometrics Bulletin**, [S. l.], v. 1, n. 6, p. 80-83, 1945. DOI: 10.2307/3001968.

WILDES, R. P. Iris recognition: an emerging biometric technology. **Proceedings of the IEEE**, [S. l.], v. 85, n. 9, p. 1348-1363, 1997. DOI: 10.1109/5.628669.

ZANA, F.; KLEIN, J.-C. Segmentation of vessel-like patterns using mathematical morphology and curvature evaluation. **IEEE Transactions on Image Processing**, [S. l.], v. 10, n. 7, p. 1010-1019, 2001. DOI: 10.1109/83.931095.

ZECH, J. R.; BADGELEY, M. A.; LIU, M.; COSTA, A. B.; TITANO, J. J.; OERMANN, E. K. Variable generalization performance of a deep learning model to detect pneumonia in chest radiographs: a cross-sectional study. **PLOS Medicine**, [S. l.], v. 15, n. 11, e1002683, 2018. DOI: 10.1371/journal.pmed.1002683.

ZETT, C.; STINA, D. M. R.; KATO, R. T.; NOVAIS, E. A.; ALLEMANN, N. Comparison of anterior segment optical coherence tomography angiography and fluorescein angiography for iris vasculature analysis. **Graefe's Archive for Clinical and Experimental Ophthalmology**, [S. l.], v. 256, n. 4, p. 683-691, 2018. DOI: 10.1007/s00417-018-3935-7.

ZHOU, Y.; WANG, T.; GUO, Z.; SHE, F.; ZENG, J.; ZHU, X. Assessment of iris vasculature in type 2 diabetes mellitus patients without diabetic retinopathy using anterior segment optical coherence tomography angiography. **Scientific Reports**, [S. l.], v. 15, n. 1, art. 19035, 2025. DOI: 10.1038/s41598-025-04463-w.

ZHU, Y.; SUN, S.; HAN, S.; CHEN, J.; WESTERN, D.; ZHANG, L. Automated method for quantitative analysis of iris fluorescein angiography based on machine learning. **Quantitative Imaging in Medicine and Surgery**, [S. l.], v. 16, n. 1, p. 68, 2026. DOI: 10.21037/qims-2025-480.

ZUIDERVELD, K. Contrast limited adaptive histogram equalization. In: HECKBERT, P. S. (ed.). **Graphics gems IV**. Boston: AP Professional, 1994. p. 474-485. DOI: 10.1016/B978-0-12-336156-1.50061-6.

APÊNDICE A – REPRODUTIBILIDADE

Os comandos a seguir, executados a partir da raiz do repositório em PowerShell, reproduzem todos os resultados, executam os testes e compilam este documento. O *script* de experimentos demanda cerca de três minutos na máquina descrita no Quadro 6.

```
.\.venv\Scripts\python.exe experiments\report_experiments.py
.\.venv\Scripts\python.exe -m unittest discover -s tests
cd docs\PGC_2
pdflatex metodologia_vascularizacao_pupila.tex
pdflatex metodologia_vascularizacao_pupila.tex
```

Quadro 6 – Ambiente de execução dos experimentos

Componente	Versão ou descrição
Python	3.12.10
NumPy	2.5.3
OpenCV	5.0.0
scikit-image	0.26.0
SciPy	1.18.1
scikit-learn	1.9.1
Matplotlib	3.11.2
Sistema operacional	Windows 11 (versão 10.0.26300)
Processador	Intel Core i7-1270P (12. ^a geração), 31,6 GB de memória

Fonte: Elaborado pelo autor (2026).

As fontes de aleatoriedade são controladas por sementes fixas: semente 0 no *bootstrap* da análise por setores e no ruído da perturbação dos experimentos E5 e E9, e sementes 0 a 9 nos fantasmas. O Quadro 7 relaciona cada experimento aos arquivos que ele gera.

Quadro 7 – Arquivos gerados por experimento no diretório docs/PGC_2

Experimento	Arquivos
Metodologia	figuras/banco_gabor.png, figuras/clahe_novak.png, figuras/setores_layout_novak.png
E0	tabelas/tab_vasc_principal.tex, dados/cnr_principal.dat, figuras/painel_vascularizacao_novak.png, figuras/painel_vascularizacao_closeup.png, figuras/histograma_estrutura_fundo.png, figuras/detalhe_estroma_closeup.png
E1	tabelas/tab_setores.tex, figuras/setores_cnr_boxplot.png, figuras/setores_polar.png
E2	tabelas/tab_metrica_otsu.tex
E3	tabelas/tab_frangi_escalas.tex, tabelas/tab_frangi_normalizacao.tex, figuras/frangi_escalas_closeup.png
E4	tabelas/tab_sensibilidade.tex
E5	tabelas/tab_robustez.tex, figuras/robustez_frangi_exemplo.png
E6	tabelas/tab_fantoma.tex, dados/auc_ruido.dat, figuras/fantoma_exemplo.png, figuras/fantoma_roc.png
E7	tabelas/tab_tempo.tex
E8	figuras/rubber_sheet_novak.png, figuras/perfil_radial_frangi.png, dados/perfil_radial_novak.dat, dados/perfil_radial_closeup.dat
E9	figuras/validacao_pupila_novak.png, figuras/pupila_curva_pontuacao.png, figuras/pupila_mapa_decisao.png, tabelas/tab_pupila_sinteticos.tex, tabelas/tab_pupila_estabilidade.tex
E10	tabelas/tab_canais.tex

Fonte: Elaborado pelo autor (2026).

APÊNDICE B – CONFIGURAÇÃO COMPLETA

O Quadro 8 reúne os valores utilizados pelo realce, pelo detector, pelo validador e pelos experimentos. Os valores do realce e do validador encontram-se em `src/config.py`; os do detector, em `experiments/demo_vascularization_pupil.py`; e os dos experimentos, em `experiments/report_experiments.py`.

Quadro 8 – Configuração completa utilizada neste relatório

Componente	Parâmetro	Valor
Pré-processamento	imagem de trabalho	lado maior de 768 px
	CLAHE	limite 2,0; grade 8×8
Frangi	frangi_sigmas	(1, 2, 3, 4)
	frangi_beta	0,5
	frangi_gamma (c)	15
	frangi_black_ridges	falso (cristas claras)
	normalização de saída	percentis 2 e 99; gama 0,7
Gabor	gabor_n_orientations	8
	gabor_ksize	21
	gabor_sigma; gabor_lambda	4; 10
	gabor_gamma; fase ψ	0,5; 0
Morfologia	morph_scales	(5, 11, 21), elipses
Detector	filtro de mediana	7×7
	limiar da região escura	percentil 3 + 20
	morfologia da máscara	elipse 9×9 ; fechamento com 2 iterações
	área mínima; circularidade mínima	$0,0015 hw$; 0,55
	transformada de Hough	$d_p = 1,2$; Canny 100; acumulador 40; $r \in [1,6 r_p; 6 r_p]$
	concentricidade do limbo	$\ \mathbf{c}_i - \mathbf{c}_p\ < 0,9 r_p$
	estimativas de reserva	$r_p = 0,08 \min(h, w)$; $r_i = 0,48 \min(h, w)$
Validador	min_pupil_iris_ratio	0,20
	max_pupil_iris_ratio	0,70
	borderline_low_ratio	0,15
	borderline_high_ratio	0,80
	min_thickness_ratio	0,25
	max_concentricity_offset	0,30
	penalidades	0,6; 0,25; 0,3; 0,3
	limiares de rótulo	0,5 e 0,8
Experimentos	setores	12 de 30° ; mínimo de 500 px
	<i>bootstrap</i>	10.000 reamostragens; semente 0
	fantoma	384×384 px; 28 curvas; borda de 12 px; 10 sementes
	<i>rubber sheet</i>	64×720 amostras
	tempo de execução	1 aquecimento e 7 execuções

Fonte: Elaborado pelo autor (2026).