UNIVERSIDADE FEDERAL DO ABC

BACHARELADO EM CIÊNCIA DA COMPUTAÇÃO

VINICIUS SEDRIM

IMAGENS REALÇADAS COMO ENTRADA DO PIPELINE DE CLASSIFICAÇÃO E O PAPEL DA GEOMETRIA PUPILAR:

resultados preliminares para o PGC III

Santo André

2026

VINICIUS SEDRIM

IMAGENS REALÇADAS COMO ENTRADA DO PIPELINE DE CLASSIFICAÇÃO E O PAPEL DA GEOMETRIA PUPILAR:

resultados preliminares para o PGC III

Relatório técnico com resultados preliminares para o Projeto de Graduação em Computação III do curso de Bacharelado em Ciência da Computação da Universidade Federal do ABC, referente ao uso das imagens realçadas diretamente no pipeline de classificação e à necessidade de descritores explícitos para a geometria da pupila.

Orientador: Vladimir Emiliano Moreira Rocha

Santo André

2026

RESUMO

Este relatório responde a duas perguntas sobre um pipeline de classificação de fotografias da íris usado no estudo de correlatos oculares do diabetes mellitus tipo 2 (DM2): se as imagens de três realces consolidados de estruturas finas (*vesselness* de Frangi, banco de Gabor e morfologia *black-hat*) podem substituir diretamente a imagem de entrada, sem descritores manuais de vascularização, e se a geometria da pupila exige descritores explícitos ou se a fotografia basta. Oito representações de entrada, três conjuntos de descritores e cinco classificadores formaram 120 configurações, avaliadas por validação cruzada estratificada repetida (10×5 *folds*) sobre as 123 imagens únicas que restaram da auditoria da base legada (73 cópias exatas removidas de 196 linhas). As imagens filtradas entram no pipeline sem outra alteração e classificam acima do acaso ($p = 0{,}001$). No leiaute principal, com o vetor de pixels, os realces superam a imagem original em 20 de 20 combinações (acurácia balanceada média de 0,699 para até 0,773), mas três controles mostram que o ganho não indica vascularização: ele não se repete no segundo leiaute (10 de 20), diminui quando as faixas espelhadas do olho direito voltam à orientação original (a imagem original passa a 0,752) e desaparece quando só o estroma é usado (10 de 20), concentrando-se nas bordas pupilar e límbica. Oito estatísticas globais de cor chegam a 0,769. Para a pupila, demonstra-se que a normalização *rubber sheet* do pipeline é invariante ao tamanho da pupila: entre $\rho = 0{,}22$ e $\rho = 0{,}62$, a faixa de uma fotografia real mantém SSIM de pelo menos 0,83, contra 0,52 entre íris diferentes. Numa coorte sintética, a faixa não detecta um efeito geométrico (AUC 0,548), a geometria medida na fotografia alcança 0,742 (limite teórico 0,760) e a fusão supera as duas fontes quando ambas têm sinal (0,866). Conclui-se que as imagens filtradas podem entrar diretamente no pipeline, com desempenho equivalente ao da original e menor sensibilidade à orientação das faixas, mas que esta base não permite atribuir o desempenho à vascularização, nem justificaria descritores manuais; e que a pupila exige descritores geométricos explícitos, extraídos automaticamente da fotografia por um detector com erro absoluto médio de 0,0012 em ρ. Os resultados são exploratórios: a base não tem identificadores de pessoa nem rótulos clínicos verificados, e o artigo associado a ela foi retratado.

Palavras-chave: diabetes mellitus tipo 2; íris; filtro de Frangi; normalização *rubber sheet*; geometria pupilar; validação cruzada.

ABSTRACT

This report answers two questions about an iris-photograph classification pipeline used to study ocular correlates of type 2 diabetes mellitus (T2DM): whether the images of three established thin-structure enhancements (Frangi vesselness, a Gabor bank and black-hat morphology) can directly replace the input image, without handcrafted vascular descriptors, and whether pupil geometry requires explicit descriptors or the photograph suffices. Eight input representations, three descriptor sets and five classifiers formed 120 configurations, evaluated with repeated stratified cross-validation (10×5 folds) on the 123 unique images left after auditing the legacy dataset (73 exact copies removed from 196 rows). The filtered images enter the pipeline without further changes and classify above chance ($p = 0.001$). In the main layout, with the pixel vector, the enhancements beat the original image in 20 of 20 combinations (mean balanced accuracy from 0.699 up to 0.773), but three controls show that the gain does not indicate vascular information: it does not replicate in the second layout (10 of 20), it shrinks when the mirrored right-eye strips are returned to their original orientation (the original image rises to 0.752) and it vanishes when only the stroma is used (10 of 20), being concentrated at the pupillary and limbal borders. Eight global colour statistics reach 0.769. For the pupil, the pipeline's rubber-sheet normalization is shown to be invariant to pupil size: between $\rho = 0.22$ and $\rho = 0.62$, the strip of a real photograph keeps an SSIM of at least 0.83, against 0.52 between different irises. In a synthetic cohort, the strip does not detect a geometric effect (AUC 0.548), the geometry measured on the photograph reaches 0.742 (theoretical limit 0.760) and the fusion beats both sources when both carry signal (0.866). Filtered images can therefore enter the pipeline directly, performing on par with the original and with lower sensitivity to strip orientation, but this dataset does not allow the performance to be attributed to vascular structure, nor would it justify handcrafted descriptors; the pupil requires explicit geometric descriptors, extracted automatically from the photograph by a detector with a mean absolute error of 0.0012 in ρ. The results are exploratory: the dataset has neither person identifiers nor verified clinical labels, and the article associated with it has been retracted.

Keywords: type 2 diabetes mellitus; iris; Frangi filter; rubber-sheet normalization; pupil geometry; cross-validation.

LISTA DE FIGURAS

Figura 1 – Pipeline da IC e as duas modificações avaliadas 15
Figura 2 – As oito representações de entrada aplicadas à faixa normalizada de uma fotografia pública 24
Figura 3 – Mapa de Frangi da faixa e vetor de pixels correspondente 24
Figura 4 – Acurácia balanceada média das 120 configurações (`personBase_invert`, 50 *folds*) 25
Figura 5 – Postos médios de Friedman das oito representações e diferença crítica de Nemenyi 26
Figura 6 – Distribuição nula da acurácia balanceada (RL sobre pixels, 1000 permutações) e valor observado de cada representação 27
Figura 7 – Replicação no leiaute `personBase` 28
Figura 8 – Efeito de desfazer o espelhamento das faixas do olho direito 29
Figura 9 – Diferença entre classes por pixel (d de Cohen, diabetes menos controle) em seis representações 30
Figura 10 – Acurácia balanceada média com pixels da faixa inteira, só do estroma e só das bordas 31
Figura 11 – Variação da acurácia balanceada sob perturbações fotométricas 32
Figura 12 – Invariância da faixa normalizada ao tamanho da pupila 33
Figura 13 – Olhos sintéticos com detecção automática e faixas normalizadas 34
Figura 14 – AUC dos quatro modelos nos quatro cenários da coorte sintética 34
Figura 15 – ρ medido contra ρ verdadeiro para os três detectores 35
Figura 16 – Curvas ROC médias por representação (`personBase_invert`) 48
Figura 17 – Postos médios de Friedman pela AUC e diferença crítica de Nemenyi 48

LISTA DE QUADROS

Quadro 1 – Representações de entrada avaliadas no pipeline da IC 20
Quadro 2 – Novas opções do pipeline da IC (main.py) 23
Quadro 3 – Parâmetros dos realces, dos descritores e dos experimentos 49

LISTA DE TABELAS

Tabela 1 – Auditoria dos dois leiautes por pessoa da base legada 20
Tabela 2 – Diferença de acurácia balanceada em relação à imagem original (média dos cinco classificadores) e valor p ajustado por Holm 26
Tabela 3 – Replicação: acurácia balanceada média sobre os 15 blocos e posto de Friedman nos dois leiautes 27
Tabela 4 – Acurácia balanceada média com pixels antes e depois de desfazer o espelhamento, e no leiaute `personBase` 28
Tabela 5 – Acurácia balanceada média com pixels por região radial da faixa e diferença em relação à original 29
Tabela 6 – Controles: acurácia balanceada (AUC entre parênteses), média de 50 *folds* . 31
Tabela 7 – Variação da acurácia balanceada sob perturbações (RL, conjunto padrão da IC; treino na condição original) 32
Tabela 8 – AUC média (IC 95% corrigido) na coorte sintética 2×2 33
Tabela 9 – Erro na medição automática de ρ na coorte sintética 35
Tabela 10 – Grade com o conjunto de pixels 46
Tabela 11 – Grade com o conjunto de textura 46
Tabela 12 – Grade com o conjunto padrão da IC 47
Tabela 13 – Resumo por representação: médias da grade, postos de Friedman, comparações com a original e teste de permutação 47
Tabela 14 – Melhor combinação de cada representação (seleção otimista) 47
Tabela 15 – Replicação no leiaute `personBase`: diferença de acurácia balanceada em relação à original e valor p ajustado por Holm 48

LISTA DE ABREVIATURAS E SIGLAS

AB	Acurácia balanceada, média da sensibilidade e da especificidade
AS-OCT	Tomografia de coerência óptica do segmento anterior (do inglês *anterior segment optical coherence tomography*)
AUC	Área sob a curva ROC (do inglês *area under the curve*)
CLAHE	Equalização adaptativa de histograma com limitação de contraste (do inglês *contrast limited adaptive histogram equalization*)
DM2	Diabetes mellitus tipo 2
FDR	Taxa de falsas descobertas (do inglês *false discovery rate*)
GLCM	Matriz de coocorrência de níveis de cinza (do inglês *gray-level co-occurrence matrix*)
IC	Iniciação Científica (no texto, "pipeline da IC") ou intervalo de confiança (em tabelas, "IC 95%")
LBP	Padrões binários locais (do inglês *local binary patterns*)
MLP	Perceptron multicamadas (do inglês *multilayer perceptron*)
PGC	Projeto de Graduação em Computação
RANSAC	Consenso de amostras aleatórias (do inglês *random sample consensus*)
RF	Floresta aleatória (do inglês *random forest*)
RGB	Vermelho, verde e azul (do inglês *red, green, blue*)
RL	Regressão logística
ROC	Característica de operação do receptor (do inglês *receiver operating characteristic*)
SSIM	Índice de similaridade estrutural (do inglês *structural similarity index*)
SVM	Máquina de vetores de suporte (do inglês *support vector machine*)

LISTA DE SÍMBOLOS

r_p, r_i	Raios da pupila e da íris
$\mathbf{c}_p$, $\mathbf{c}_i$	Centros da pupila e da íris
ρ	Razão entre os raios da pupila e da íris, r_p/r_i
τ	Espessura relativa do anel da íris, $(r_i - r_p)/r_i = 1 - \rho$
ϵ	Excentricidade, $\|\mathbf{c}_p - \mathbf{c}_i\|/r_i$
(s, θ)	Coordenadas normalizadas da faixa: raio relativo e ângulo
$N(s, \theta)$	Faixa normalizada pelo modelo *rubber sheet*
κ	Expoente do modelo não linear de deformação do estroma
k	Número total de *folds* da validação cruzada repetida
n_1, n_2	Tamanhos médios dos conjuntos de treino e de teste
d	Tamanho de efeito de Cohen

SUMÁRIO

1	**INTRODUÇÃO**	**11**
1.1	O PIPELINE DE CLASSIFICAÇÃO E OS REALCES DISPONÍVEIS	11
1.2	PERGUNTAS DESTA ETAPA	12
1.3	CONTRIBUIÇÕES	12
2	**QUESTÕES DE PESQUISA E HIPÓTESES**	**14**
2.1	QUESTÕES	14
2.2	HIPÓTESES	14
3	**FUNDAMENTAÇÃO TEÓRICA**	**15**
3.1	O PIPELINE DA IC	15
3.2	REALCES DE ESTRUTURAS FINAS	15
3.3	NORMALIZAÇÃO DE DAUGMAN E O TAMANHO DA PUPILA	16
3.4	GEOMETRIA PUPILAR: O QUE A FOTOGRAFIA MEDE	17
3.5	AVALIAÇÃO ESTATÍSTICA	17
4	**MATERIAIS E MÉTODOS**	**19**
4.1	BASE DE DADOS E AUDITORIA	19
4.2	REPRESENTAÇÕES DE ENTRADA	20
4.3	DESCRITORES, CLASSIFICADORES E PROTOCOLO	20
4.4	ANÁLISES COMPLEMENTARES	21
4.5	EXPERIMENTOS DA PUPILA	22
4.6	INTEGRAÇÃO AO PIPELINE E REPRODUTIBILIDADE	23
5	**RESULTADOS**	**24**
5.1	O QUE O PIPELINE RECEBE	24
5.2	IMAGENS REALÇADAS COMO ENTRADA DO PIPELINE	25
5.3	DESEMPENHO ACIMA DO ACASO	26
5.4	REPLICAÇÃO NO LEIAUTE `PERSONBASE`	26
5.5	O ESPELHAMENTO DAS FAIXAS EXPLICA A DIFERENÇA ENTRE OS LEIAUTES	27
5.6	ESTROMA OU BORDAS: ONDE ESTÁ O SINAL	28
5.7	CONTROLES: ATALHO DE COR, DESCRITORES MANUAIS E FUSÃO	30
5.8	ROBUSTEZ FOTOMÉTRICA	31
5.9	A FAIXA NORMALIZADA NÃO REGISTRA O TAMANHO DA PUPILA	31
5.10	COORTE SINTÉTICA: FAIXA, GEOMETRIA E FUSÃO	32

5.11 MEDIÇÃO AUTOMÁTICA DE ρ 33

6 DISCUSSÃO 36
6.1 PERGUNTA 1: AS IMAGENS FILTRADAS PODEM ENTRAR DIRETAMENTE NO PIPELINE? 36
6.2 PERGUNTA 2: A PUPILA PRECISA DE DESCRITORES MANUAIS? . . 37
6.3 LIMITAÇÕES 37

7 CONCLUSÃO E PRÓXIMOS PASSOS 39

REFERÊNCIAS 40

APÊNDICE A – REPRODUTIBILIDADE 45

APÊNDICE B – TABELAS COMPLETAS DA GRADE 46

APÊNDICE C – PARÂMETROS 49

1 INTRODUÇÃO

O projeto investiga, sob perspectiva médica e não iridológica, se correlatos de biomarcadores oculares do diabetes mellitus tipo 2 (DM2) podem ser extraídos de fotografias convencionais da íris. A iridologia, que atribui a regiões da íris a condição de órgãos distantes, não se sustenta quando avaliada sob protocolos controlados (Ernst, 2000; Simon; Worthen; Mitas, 1979). A literatura médica, por outro lado, descreve dois grupos de achados oculares associados ao diabetes: alterações da vascularização da íris, observadas por angiografia por tomografia de coerência óptica do segmento anterior (Roberts; Goldstein; Fawzi, 2017; Zett et al., 2018; Zhou et al., 2025), e alterações do diâmetro pupilar e da espessura da íris, ligadas à neuropatia autonômica (Cahill; Eustace; De Jesus, 2001; Cui et al., 2024; Thakar et al., 2025). O projeto pergunta se correlatos dessas grandezas sobrevivem numa fotografia RGB, que não tem a resolução nem a especificidade daquelas modalidades.

1.1 O PIPELINE DE CLASSIFICAÇÃO E OS REALCES DISPONÍVEIS

O ponto de partida é o pipeline de classificação desenvolvido na Iniciação Científica (IC), aqui chamado de *pipeline da IC*. Ele recebe uma fotografia do olho, segmenta a pupila e o limbo, normaliza o anel da íris pelo modelo *rubber sheet* de Daugman (2004) numa faixa retangular de 201×720 pixels (raio $\times$ ângulo), aplica um pré-processamento fotométrico, extrai descritores e treina classificadores clássicos com validação cruzada estratificada. Os descritores disponíveis são o vetor de pixels da faixa subamostrada, os padrões binários locais (LBP) (Ojala; Pietikäinen; Mäenpää, 2002), as estatísticas de coocorrência de níveis de cinza (GLCM) (Haralick; Shanmugam; Dinstein, 1973) e estatísticas de intensidade; os classificadores são a regressão logística (RL), a máquina de vetores de suporte (SVM), a floresta aleatória (RF), o perceptron multicamadas (MLP) e o AdaBoost.

O pré-processamento desse pipeline dispunha apenas de ajustes de brilho, de contraste e de equalização de histograma. Para evidenciar a vascularização, foram incorporados a ele três realces consolidados de estruturas finas, todos aplicados ao canal verde após a equalização adaptativa CLAHE (Zuiderveld, 1994): o filtro de *vesselness* multiescala de Frangi et al. (1998), baseado nos autovalores da matriz hessiana; a resposta máxima de um banco de filtros de Gabor orientados (Daugman, 1985; Jain; Farrokhnia, 1991); e a soma das transformações *top-hat* e *black-hat* morfológicas em três escalas (Soille, 2004). Uma quarta opção combina os mapas de Frangi e *black-hat* com pesos 0,6 e 0,4. Diferentemente de brilho e contraste, que apenas reescalam as intensidades de todos os pixels pela mesma função, esses operadores consideram a vizinhança de cada pixel e respondem à forma das estruturas; a Figura 2, no Capítulo 5, mostra o efeito de cada um numa faixa normalizada. O pipeline também ganhou um validador da geometria

pupila–íris, que calcula a razão ρ entre os raios da pupila e da íris, a espessura relativa τ do anel e a excentricidade ϵ entre os centros.

1.2 PERGUNTAS DESTA ETAPA

Com os realces e o validador implementados, o orientador propôs duas perguntas, que organizam este relatório:

a) **vascularização**: é possível usar as imagens resultantes dos filtros diretamente no pipeline da IC, evitando a criação de descritores manuais de vascularização? Caso os resultados fossem ruins, seria necessário voltar aos descritores manuais;

b) **pupila**: para o diâmetro da pupila e a espessura da íris, será necessário criar descritores manuais ou o pipeline só precisaria da fotografia da íris?

1.3 CONTRIBUIÇÕES

As contribuições desta etapa são:

a) a integração dos realces como entrada direta do pipeline da IC, com a opção `-transform` e o teste `-vascular-test` em main.py, sem nenhum descritor novo;

b) uma auditoria reprodutível da base legada, com leitura segura dos arquivos, remoção de cópias exatas, reparo da costura angular e detecção das faixas espelhadas (Seção 4.1);

c) uma avaliação de 120 configurações com o mesmo protocolo, incluindo correção da variância da validação cruzada repetida, ajuste para comparações múltiplas, teste de permutação, ablação do pré-processamento, controle de atalho por cor, comparação com descritores manuais, fusão, robustez fotométrica e replicação num segundo leiaute da base;

d) duas análises de controle que localizam a origem do sinal, o desespelhamento das faixas e o recorte radial entre estroma e bordas, e que mostram que o ganho aparente dos realces nesta base não vem da vascularização;

e) uma demonstração formal e experimental de que a normalização *rubber sheet* descarta o tamanho da pupila (Proposição 1), com a consequência prática de que a geometria precisa entrar no classificador como um bloco explícito;

f) um detector de pupila e limbo por raios em estrela, RANSAC e refinamento integro-diferencial, que mede ρ automaticamente, e a fusão por empilhamento da textura com a geometria, integrada ao pipeline pela opção `-with-geometry`;

g) a reprodutibilidade de todos os números do texto, gerados pelos *scripts* de experimentos, testes automatizados para os componentes novos e a correção de dois defeitos do pipeline encontrados no caminho: a incompatibilidade do AdaBoost com as versões

atuais do scikit-learn e a leitura repetida das mesmas fotografias em sistemas de arquivos que não diferenciam maiúsculas, que criava cópias entre treino e teste.

O Capítulo 2 formaliza as questões e as hipóteses; o Capítulo 3 reúne a fundamentação; o Capítulo 4 descreve dados, protocolo e experimentos; o Capítulo 5 apresenta os resultados; o Capítulo 6 discute as respostas e as limitações; e o Capítulo 7 conclui e propõe os próximos passos.

2 QUESTÕES DE PESQUISA E HIPÓTESES

2.1 QUESTÕES

a) **Q1**: ao substituir a imagem de entrada do pipeline da IC pela imagem realçada, mantidos os descritores, os classificadores e o protocolo, o desempenho muda? A mudança depende do conjunto de descritores? O ganho, se houver, vem do filtro ou do pré-processamento que os filtros compartilham (canal verde com CLAHE)? Ele supera o acaso, resiste a perturbações fotométricas e se repete noutra amostra da base?

b) **Q2**: a geometria pupila–íris chega ao classificador quando o pipeline recebe a fotografia? Se não chega, o que é preciso: descritores manuais, a fotografia completa ou ambos? A geometria pode ser medida automaticamente com precisão suficiente?

2.2 HIPÓTESES

Hipótese 1 (realce como entrada)**.** O vetor de pixels de uma faixa original é dominado por variações de baixa frequência, como a iluminação, as sombras das pálpebras e o gradiente radial do estroma. Os realces removem esse fundo e preservam as estruturas finas. Espera-se, portanto, que a imagem realçada melhore os classificadores que recebem os pixels, e que o ganho desapareça quando a entrada passa apenas pelo pré-processamento comum, sem o filtro. Para descritores de textura calculados sobre a imagem original, que já resumem a distribuição de intensidades, não se espera ganho.

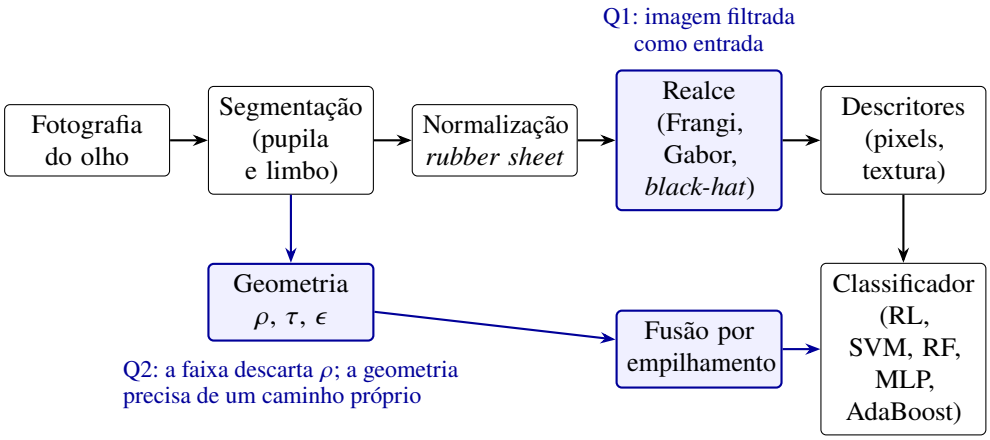
Hipótese 2 (geometria explícita)**.** A normalização *rubber sheet* leva o anel da íris a uma faixa de tamanho fixo independentemente do raio da pupila. Espera-se que a faixa seja aproximadamente invariante a ρ e que um efeito puramente geométrico seja invisível para o pipeline que só recebe a faixa, mas recuperável quando ρ, medido na fotografia, entra como descritor explícito.

3 FUNDAMENTAÇÃO TEÓRICA

3.1 O PIPELINE DA IC

A Figura 1 resume o pipeline e as duas modificações avaliadas. Na entrada, a segmentação estima os círculos da pupila e do limbo. A normalização produz a faixa $N(s, \theta)$, com $s \in [0, 1]$ da borda pupilar ($s = 0$) ao limbo ($s = 1$) e $\theta \in [0, 2\pi)$. O pré-processamento escolhe um canal de cor e aplica uma transformação fotométrica; nesta etapa, os realces de vascularização passam a ser transformações como as demais. Os descritores podem ser o vetor de pixels da faixa subamostrada por um fator 4 ($50 \times 180 = 9000$ valores), a textura (histograma de LBP uniforme com 16 vizinhos e raio 2, seis propriedades de GLCM em três distâncias e quatro direções, e 36 estatísticas de intensidade, num total de 126 valores) ou a concatenação dos dois, que é o conjunto padrão da IC. Os classificadores recebem os descritores padronizados (média zero e variância unitária, estimadas apenas no treino de cada *fold*).

Figura 1 – Pipeline da IC e as duas modificações avaliadas



Fonte: elaborado pelo autor. Em azul, os componentes acrescentados nesta etapa.

3.2 REALCES DE ESTRUTURAS FINAS

O filtro de Frangi et al. (1998) calcula, em cada escala σ, os autovalores $|\lambda_1| \le |\lambda_2|$ da matriz hessiana da imagem suavizada e atribui a cada pixel a resposta

$$V_\sigma = \exp\left(-\frac{R_B^2}{2\beta^2}\right)\left[1 - \exp\left(-\frac{S^2}{2c^2}\right)\right], \qquad R_B = \frac{\lambda_1}{\lambda_2}, \quad S = \sqrt{\lambda_1^2 + \lambda_2^2}, \tag{1}$$

nula quando o sinal de λ_2 não corresponde à polaridade procurada. A resposta final é o máximo sobre as escalas $\sigma \in \{1, 2, 3, 4\}$, com $\beta = 0{,}5$ e $c = 15$. Ela é alta em estruturas alongadas, cuja curvatura é forte numa direção e fraca na outra, e baixa em regiões homogêneas e em manchas isotrópicas. O banco de Gabor usa oito orientações, núcleo de 21×21 pixels, $\sigma = 4$,

comprimento de onda 10 e razão de aspecto 0,5; a resposta é o máximo do valor absoluto entre as orientações. A morfologia soma as transformações *top-hat* (estruturas claras menores que o elemento estruturante) e *black-hat* (estruturas escuras) com elementos elípticos de 5, 11 e 21 pixels. Os três realces descartam, por construção, o nível médio e as variações lentas de intensidade.

3.3 NORMALIZAÇÃO DE DAUGMAN E O TAMANHO DA PUPILA

Sejam $\mathbf{p}(\theta) = \mathbf{c}_p + r_p\,\mathbf{u}(\theta)$ e $\mathbf{i}(\theta) = \mathbf{c}_i + r_i\,\mathbf{u}(\theta)$ os pontos dos círculos da pupila e do limbo na direção $\mathbf{u}(\theta) = (\cos\theta, -\sin\theta)$. A normalização de Daugman (2004) define

$$N(s,\theta) = I\big((1-s)\,\mathbf{p}(\theta) + s\,\mathbf{i}(\theta)\big), \qquad s \in [0,1],\ \theta \in [0, 2\pi). \tag{2}$$

O modelo supõe que o tecido da íris se estica linearmente entre a pupila e o limbo: um ponto do estroma que ocupa a posição relativa s continua em s quando a pupila muda de tamanho. É por isso que a normalização compensa a dilatação no reconhecimento de íris.

Proposição 1. *Se o estroma se deforma segundo o modelo linear de Daugman e o limbo permanece fixo, a faixa N não depende de r_p. Em consequência, nenhum descritor calculado apenas sobre N, e nenhum classificador que receba apenas esses descritores, pode distinguir duas fotografias que diferem só no tamanho da pupila.*

Demonstração. Sejam I_0 e I_1 fotografias do mesmo olho com raios pupilares r_0 e r_1 e o mesmo limbo. Pelo modelo, o ponto de tecido de coordenadas (s,θ) aparece em I_0 na posição $(1-s)\,\mathbf{p}_0(\theta) + s\,\mathbf{i}(\theta)$ e em I_1 na posição $(1-s)\,\mathbf{p}_1(\theta) + s\,\mathbf{i}(\theta)$, com a mesma intensidade. Aplicando a Equação (2) com os círculos de cada fotografia, obtém-se $N_0(s,\theta) = N_1(s,\theta)$ para todo (s,θ). Qualquer função de N assume, portanto, o mesmo valor nas duas fotografias. □

Corolário 1. *Para que o tamanho da pupila influencie a decisão, $\rho = r_p/r_i$ precisa ser medido na segmentação, antes da normalização, e entregue ao classificador como descritor explícito.*

A deformação real do estroma não é exatamente linear (Tomeo-Reyes et al., 2015; Wyatt, 2000), e a dilatação degrada o reconhecimento de íris justamente porque deixa um traço residual na faixa (Hollingsworth; Bowyer; Flynn, 2009). Esse traço é indireto e mistura o tamanho da pupila com a textura de cada pessoa; a proposição continua indicando que a faixa não é o meio adequado para transportar ρ. Na amostragem, a faixa também perde resolução radial quando o anel fica mais fino, o que muda a nitidez sem codificar ρ de forma direta.

Para simular dilatações com o mesmo modelo, é preciso inverter a Equação (2). Para s fixo, os pontos $(1-s)\,\mathbf{p}(\theta) + s\,\mathbf{i}(\theta)$ formam um círculo de centro $\mathbf{c}_p + s(\mathbf{c}_i - \mathbf{c}_p)$ e raio $r_p + s(r_i - r_p)$. Dado um pixel $\mathbf{x}$, com $\mathbf{d} = \mathbf{x} - \mathbf{c}_p$, $\mathbf{v} = \mathbf{c}_i - \mathbf{c}_p$, $a = r_p$ e $b = r_i - r_p$, a coordenada s é a raiz de

$$\big(\|\mathbf{v}\|^2 - b^2\big)s^2 - 2\big(\mathbf{d}\cdot\mathbf{v} + ab\big)s + \big(\|\mathbf{d}\|^2 - a^2\big) = 0, \tag{3}$$

e θ é o ângulo de $\mathbf{x}$ em relação ao centro do círculo correspondente. Essa inversa exata permite gerar a mesma fotografia com outro tamanho de pupila e verificar a Proposição 1 sem aproximação geométrica.

3.4 GEOMETRIA PUPILAR: O QUE A FOTOGRAFIA MEDE

Numa fotografia frontal, a segmentação fornece r_p, r_i e os centros. Daí saem a razão $\rho = r_p/r_i$, a espessura relativa do anel $\tau = (r_i - r_p)/r_i$ e a excentricidade $\epsilon = \|\mathbf{c}_p - \mathbf{c}_i\|/r_i$. Como $\tau = 1 - \rho$, o diâmetro relativo da pupila e a espessura relativa do anel são a mesma informação. Os diâmetros em pixels dependem da distância e da óptica da câmera e só se convertem em milímetros com calibração. Uma aproximação usual toma o diâmetro horizontal visível da íris como régua, com média de 11,7 mm em adultos (Rüfer; Schröder; Erb, 2005); o diâmetro pupilar em milímetros fica então próximo de $\rho \times 11{,}7$ mm, com incerteza de alguns por cento herdada da variação entre pessoas. A espessura anatômica do estroma, por sua vez, não é visível numa fotografia frontal e exige AS-OCT ou biomicroscopia ultrassônica (Cui et al., 2024). O diâmetro pupilar também varia com a iluminação, a idade e a acomodação (Watson; Yellott, 2012); nos estudos clínicos, a redução associada ao diabetes aparece na pupila adaptada ao escuro (Cahill; Eustace; De Jesus, 2001). Uma medida útil de ρ requer, portanto, iluminação controlada e registrada na aquisição.

3.5 AVALIAÇÃO ESTATÍSTICA

Métricas. A acurácia balanceada (AB), média da sensibilidade e da especificidade, não favorece a classe majoritária. A área sob a curva ROC (AUC) mede a separação dos escores independentemente do limiar (Fawcett, 2006; Hanley; McNeil, 1982).

Validação cruzada repetida. Em r repetições de K *folds*, obtêm-se $k = rK$ estimativas que não são independentes, porque os conjuntos de treino se sobrepõem. O intervalo de confiança da média e o teste t pareado entre duas configurações usam então a variância corrigida de Nadeau e Bengio (2003),

$$\hat{\sigma}^2_{\text{corr}} = \left(\frac{1}{k} + \frac{n_2}{n_1}\right)\hat{\sigma}^2, \tag{4}$$

em que $\hat{\sigma}^2$ é a variância amostral das k estimativas (ou das diferenças) e n_1 e n_2 são os tamanhos de treino e de teste. A correção evita a taxa excessiva de falsos positivos do teste t comum (Bouckaert; Frank, 2004).

Comparações múltiplas. Famílias de testes recebem o ajuste de Holm (1979). Para ordenar várias configurações sobre vários blocos, usa-se o teste de Friedman (1937), com a estatística F de Iman e Davenport (1980) e a diferença crítica de Nemenyi (1963), conforme Demšar (2006).

Teste de permutação. Para verificar se uma configuração supera o acaso, os rótulos são permutados e a validação cruzada é refeita (Ojala; Garriga, 2010); o valor p é $(1 + b)/(1 + B)$,

em que b é o número de permutações com desempenho maior ou igual ao observado entre B permutações (Phipson; Smyth, 2010).

Mapas por pixel. A diferença entre classes em cada pixel da faixa é medida pelo d de Cohen (1988), com o teste t de Welch e controle da taxa de falsas descobertas pelo procedimento de Benjamini e Hochberg (1995).

4 MATERIAIS E MÉTODOS

4.1 BASE DE DADOS E AUDITORIA

A única base rotulada disponível é um arquivo legado de faixas já normalizadas ($201 \times 720 \times 3$, BGR), distribuído junto de um artigo sobre a predição de diabetes por regiões da íris que foi retratado pelo IEEE (Moradi et al., 2018). O arquivo traz cinco leiautes (`all`, `L_split`, `R_split`, `personBase` e `personBase_invert`), sem as fotografias originais, sem os contornos, sem identificadores de pessoa e com a classe positiva definida apenas como diabetes informado. Por isso a base não permite conclusões clínicas e não é redistribuída; nenhuma figura deste relatório mostra imagens dela.

A leitura usa um desserializador restrito, que aceita apenas os construtores do NumPy necessários para reconstruir os arrays e bloqueia qualquer outro objeto do arquivo. A auditoria (Tabela 1) encontrou:

a) 73 cópias exatas entre as 196 linhas de cada leiaute por pessoa, com uma mesma imagem repetida até 6 vezes. Mantidas, essas cópias cairiam em *folds* diferentes e inflariam as métricas; elas foram removidas por SHA-256, restando 123 imagens únicas (66 controles e 57 com diabetes informado em `personBase_invert`);

b) no leiaute `personBase_invert`, as faixas do olho direito foram espelhadas: a inversão angular seguida de um deslocamento de 360 colunas leva o ângulo θ a $180^\circ - \theta$, isto é, troca os lados nasal e temporal, provavelmente para alinhar a anatomia dos dois olhos. Desfeita essa transformação, 63 das 63 faixas espelhadas coincidem exatamente com faixas do leiaute `R_split` (olho direito), e 60 das 60 demais, com faixas do `L_split`. A costura angular vazia, uma coluna inteiramente nula, aparece na coluna 360 das faixas espelhadas e na coluna 719 das demais; como ela marca o lado do olho, e o lado não está equilibrado entre as classes (30 controles e 33 casos espelhados), a coluna foi preenchida com a média das vizinhas;

c) nenhum par de imagens únicas com correlação igual ou superior a 0,97 (mediana das correlações entre pares: 0,71; máximo: 0,957). Sem identificadores, cada imagem única forma um grupo próprio na validação cruzada, e olhos da mesma pessoa podem ficar em *folds* diferentes;

d) uma diferença de cor média entre as classes: o canal azul vale 28,3 nos controles e 33,2 nos casos, e o vermelho, 105,4 e 97,9, enquanto o cinza quase não muda. A Seção 5.7 testa se essa diferença basta para classificar.

O leiaute principal é `personBase_invert`, o padrão do código que acompanha a base legada. O leiaute `personBase`, que tem o mesmo número de imagens únicas mas compartilha

Tabela 1 – Auditoria dos dois leiautes por pessoa da base legada

Item	`personBase_invert`	`personBase`
Linhas (controle / diabetes)	108 / 88	108 / 88
Cópias exatas removidas	73	73
Imagens únicas (controle / diabetes)	66 / 57	63 / 60
Maior multiplicidade de uma cópia	6	7
Faixas espelhadas (controle / diabetes)	30 / 33	0 / 0
Coluna nula da costura (coluna: imagens)	360: 63, 719: 60	719: 123
Pares com correlação $\geq 0{,}97$	0	0
Grupos da validação cruzada	123	123

Fonte: elaborada pelo autor.

apenas 33 delas com o principal, serve de replicação.

4.2 REPRESENTAÇÕES DE ENTRADA

O Quadro 1 lista as oito representações. As três primeiras são as linhas de base do pipeline; a quarta é uma ablação que aplica o pré-processamento comum dos filtros (canal verde e CLAHE) sem filtro algum, o que permite atribuir ao filtro, e não ao pré-processamento, qualquer diferença observada. Os realces usam exatamente os parâmetros descritos na fundamentação, sem ajuste nos dados desta etapa.

Quadro 1 – Representações de entrada avaliadas no pipeline da IC

Representação	Canal	Operação sobre a faixa
Original	cinza	nenhuma (entrada original do pipeline)
Equalização global	cinza	equalização de histograma global
CLAHE	cinza	equalização adaptativa com limite de contraste 2,0
Verde + CLAHE	verde	ablação: pré-processamento comum dos filtros, sem filtro
Frangi	verde	CLAHE + *vesselness* multiescala ($\sigma = 1, \ldots, 4$)
Gabor	verde	CLAHE + máximo de 8 filtros de Gabor orientados
Black-hat	verde	CLAHE + *top-hat* e *black-hat* em 3 escalas
Frangi + *black-hat*	verde	$0{,}6\times$ Frangi + $0{,}4\times$ *black-hat*

Fonte: elaborado pelo autor.

4.3 DESCRITORES, CLASSIFICADORES E PROTOCOLO

Cada representação alimenta três conjuntos de descritores do próprio pipeline: *pixels* (9000 valores), *textura* (126 valores) e o conjunto *padrão da IC* (os dois juntos, 9126 valores). Os cinco classificadores mantêm os hiperparâmetros fixos do pipeline: RL com $C = 1$; SVM com núcleo RBF e $C = 1$; RF com 100 árvores; MLP com camadas ocultas de 100 e 50 neurônios; e AdaBoost com 50 estimadores. Nenhum hiperparâmetro foi ajustado nos dados, o que elimina a seleção de modelo como fonte de otimismo.

A avaliação usa validação cruzada estratificada por grupos com 5 *folds*, repetida 10 vezes com sementes fixas, num total de 50 *folds* por configuração ($n_1 \approx 98$ e $n_2 \approx 25$). Todas as 120 configurações (8 representações $\times$ 3 conjuntos $\times$ 5 classificadores) usam exatamente as mesmas partições, o que permite comparações pareadas *fold* a *fold*. A padronização é estimada apenas no treino de cada *fold*.

4.4 ANÁLISES COMPLEMENTARES

a) **Efeito por conjunto de descritores.** Em cada *fold*, a diferença de AB entre uma representação e a original é promediada sobre os cinco classificadores; o teste t corrigido é aplicado às 50 diferenças e o ajuste de Holm, às sete representações de cada conjunto.

b) **Ranking global.** Teste de Friedman sobre 15 blocos (3 conjuntos $\times$ 5 classificadores) e diferença crítica de Nemenyi.

c) **Teste de permutação.** Para cada representação, um modelo pré-especificado, RL sobre os pixels, é avaliado com 5 *folds* e 1000 permutações dos rótulos. A escolha prévia do modelo evita que a seleção da melhor configuração contamine o teste.

d) **Controle de atalho.** Oito estatísticas globais da faixa (média e desvio-padrão de B, G, R e do cinza) alimentam os cinco classificadores. Se elas classificarem bem, a cor ou a iluminação global podem estar servindo de atalho (Geirhos et al., 2020; Zech et al., 2018).

e) **Descritores manuais.** Como referência para a pergunta do orientador, 13 descritores clássicos de vascularização são calculados sobre a resposta bruta de Frangi: média, desvio-padrão e percentil 90 da resposta; densidade da máscara de Otsu; comprimento do esqueleto e números de ramificações e de extremidades por área; e resposta média e densidade em três terços radiais (zona pupilar, intermediária e ciliar).

f) **Fusão.** Os descritores padrão da IC da imagem original são concatenados aos da imagem de Frangi ou de Gabor.

g) **Robustez fotométrica.** Com o modelo RL e o conjunto padrão da IC, cada *fold* treina na condição original e testa as mesmas imagens sob nove perturbações (brilho ± 30, contraste $\times 0{,}7$ e $\times 1{,}3$, gama 0,7 e 1,5, ruído gaussiano, desfoque e compressão JPEG).

h) **Replicação.** A grade inteira é repetida no leiaute `personBase`.

i) **Recorte radial.** Para localizar o sinal, o vetor de pixels de cada representação é dividido em duas regiões: o estroma, com r entre cerca de 0,10 e 0,86 (linhas 5 a 42 das 50 linhas do vetor), e as bordas, que reúnem a margem pupilar ($r < 0{,}10$) e a faixa junto do limbo ($r > 0{,}86$). Cada região é avaliada com os cinco classificadores e o mesmo protocolo.

j) **Desespelhamento.** As faixas espelhadas do leiaute principal são devolvidas à orientação original pela transformação inversa (inversão angular após um deslocamento de -360 colunas), e a grade com pixels é repetida. Esse teste verifica se a diferença entre os leiautes decorre do espelhamento.

k) **Mapas de diferença.** Mapas do d de Cohen por pixel da faixa subamostrada, com FDR de 5%, mostram onde as classes diferem em cada representação. São análises descritivas sobre toda a base, sem papel preditivo.

4.5 EXPERIMENTOS DA PUPILA

B1, invariância. A fotografia pública de Novák (2005) foi reamostrada pela inversa exata (Equação 3) com ρ entre 0,22 e 0,62, mantendo o limbo fixo. Como o olho foi fotografado fora do eixo e o limbo é elíptico, o círculo do limbo foi estimado uma única vez por transformada de Hough (Duda; Hart, 1972) e mantido em todas as simulações; a pupila foi redetectada em cada imagem. O mesmo procedimento foi repetido num olho sintético com geometria conhecida, tanto no modelo linear quanto num modelo não linear ilustrativo, em que a posição s do novo anel busca a posição s^{γ} do anel original, com $\gamma = \big((1-\rho_{\text{novo}})/(1-\rho_{\text{original}})\big)^{\kappa}$ e $\kappa = 1$; assim o tecido próximo da pupila se comprime mais quando ela dilata. A similaridade entre faixas foi medida pelo SSIM (Wang et al., 2004) e comparada à similaridade entre faixas de íris sintéticas diferentes.

B2, coorte sintética 2×2**.** Olhos sintéticos foram gerados com textura procedural de íris no domínio normalizado (fibras radiais por ruído filtrado anisotropicamente, detalhe fino, colarete ondulado, criptas escuras em quantidade de Poisson, franja pigmentar e anel limbar), mapeada no anel pela inversa exata, com escala, centro, excentricidade, cor, iluminação, desfoque e ruído sorteados para cada olho. Dois fatores foram controlados: um efeito geométrico ($\rho \sim \mathcal{N}(0{,}40;\ 0{,}06^2)$ nos controles e $\mathcal{N}(0{,}34;\ 0{,}06^2)$ nos casos, ou seja, $d = 1$) e um efeito de textura (contraste médio das fibras radiais multiplicado por 0,9 nos controles e por 1,1 nos casos, com variação individual de 10% e taxa de criptas fixa). O tamanho do efeito de textura foi escolhido num ensaio preliminar para que o pipeline sobre a faixa alcançasse AUC próxima da obtida pela geometria, de modo que os dois efeitos tivessem peso comparável. Os quatro cenários (nenhum efeito, só geometria, só textura e ambos) têm 100 olhos por classe. Quatro modelos foram comparados com validação cruzada estratificada 5×5: o pipeline da IC sobre a faixa (RL com o conjunto padrão), a geometria medida automaticamente na fotografia (ρ, τ e ϵ com RL), a fusão por empilhamento das duas (Wolpert, 1992) e a geometria verdadeira, como oráculo. Com $d = 1$ e medida perfeita, a AUC máxima de um classificador baseado em ρ é $\Phi(d/\sqrt{2}) = 0{,}760$.

B3, medição de ρ**.** O erro de medição foi comparado entre três detectores: o segmentador por contornos ativos do pipeline da IC (Kass; Witkin; Terzopoulos, 1988), num subconjunto de 12 olhos devido ao custo; um detector simples por limiar e transformada de Hough, incluído

na demonstração do pipeline, que toma como pupila a maior região escura e aproximadamente circular abaixo de um limiar igual ao percentil 3 da imagem mais 20 níveis de cinza e procura o limbo por Hough a partir de 1,6 vez o raio da pupila; e o detector desenvolvido nesta etapa. Este último parte do ponto mais escuro da imagem suavizada, lança 72 raios em estrela (Li; Winfield; Parkhurst, 2005) e toma, em cada raio, o primeiro pico forte da derivada de escuro para claro; ajusta um círculo por RANSAC (Fischler; Bolles, 1981) com mínimos quadrados algébricos (Kåsa, 1976); e refina centro e raio pelo operador integro-diferencial de Daugman (1993), em duas passagens. O limbo segue o mesmo esquema, com raios restritos aos arcos laterais para evitar as pálpebras. Na pupila, o refinamento escolhe o primeiro máximo da derivada que atinge metade do maior valor, o que impede que o colarete, às vezes mais abrupto que a borda pupilar, seja tomado pela pupila.

4.6 INTEGRAÇÃO AO PIPELINE E REPRODUTIBILIDADE

As duas respostas foram incorporadas ao pipeline da IC (Quadro 2). Todos os resultados deste relatório são produzidos por dois *scripts* com sementes fixas, e os números citados no texto são gerados a partir das suas saídas, sem digitação manual. Os componentes novos têm testes automatizados (Apêndice A).

Quadro 2 – Novas opções do pipeline da IC (main.py)

Opção	Efeito
`-transform frangi`	usa a imagem realçada (`frangi`, `gabor`, `blackhat` ou `vessel`) como entrada; o canal verde é escolhido automaticamente
`-vascular-test`	compara a imagem original, a equalização, o CLAHE e os quatro realces com os mesmos descritores e classificadores
`-keep-duplicates`	desliga a remoção de cópias exatas e o reparo da costura (comportamento antigo, sujeito a vazamento)
`-segmenter starburst`	segmenta as fotografias com o detector por raios em estrela e refinamento integro-diferencial
`-with-geometry`	no pipeline completo, mede ρ, τ e ϵ em cada foto, grava geometria.csv e compara textura, geometria e fusão

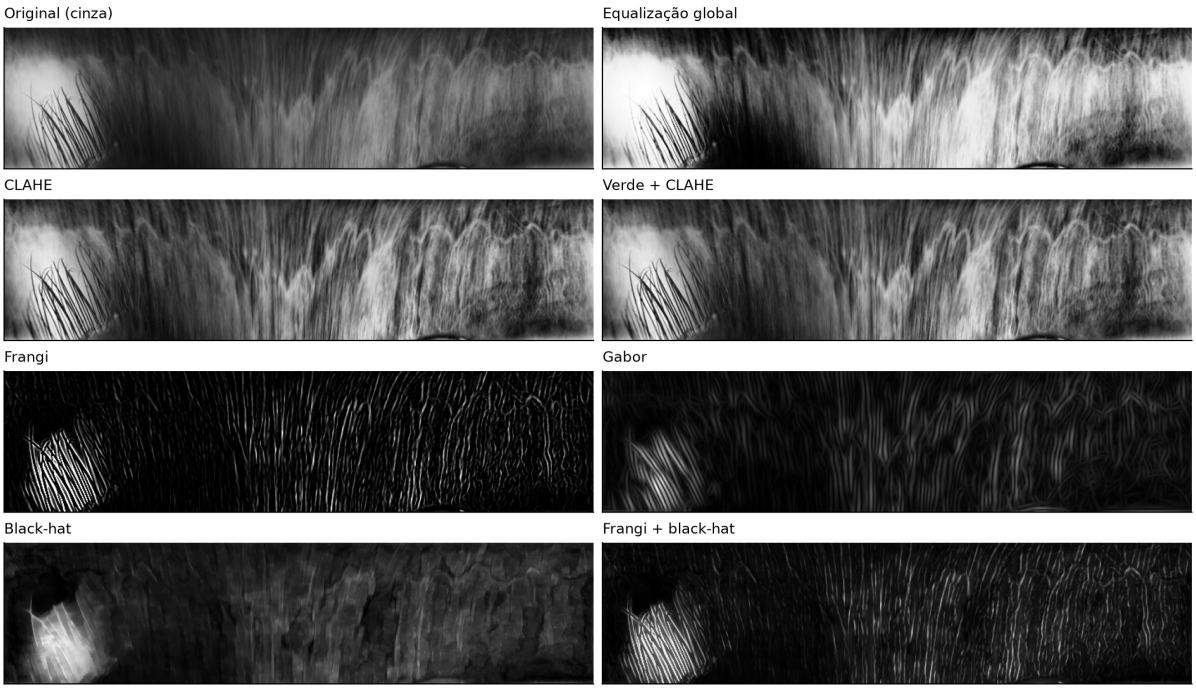
Fonte: elaborado pelo autor.

5 RESULTADOS

5.1 O QUE O PIPELINE RECEBE

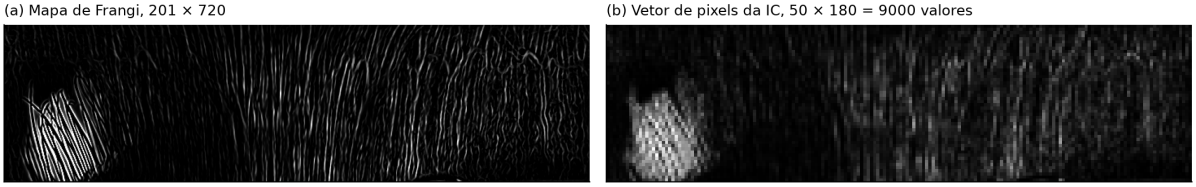
A Figura 2 mostra as oito representações aplicadas à faixa normalizada da fotografia pública. Os realces suprimem o gradiente de iluminação e as manchas de baixa frequência e deixam as fibras radiais em evidência; também respondem fortemente aos cílios do quadrante superior, uma oclusão que precisará de máscara própria. A Figura 3 mostra o mapa de Frangi e o vetor de pixels que o classificador recebe.

Figura 2 – As oito representações de entrada aplicadas à faixa normalizada de uma fotografia pública



Fonte: elaborada pelo autor a partir da fotografia de Novák (2005), sob a mesma licença CC BY-SA 2.5.

Figura 3 – Mapa de Frangi da faixa e vetor de pixels correspondente



Fonte: elaborada pelo autor a partir da fotografia de Novák (2005), sob a mesma licença CC BY-SA 2.5.

5.2 IMAGENS REALÇADAS COMO ENTRADA DO PIPELINE

A Figura 4 resume as 120 configurações no leiaute principal, `personBase_invert`. O padrão depende do conjunto de descritores. Com os **pixels**, ou seja, quando o classificador recebe a própria imagem, os quatro realces superam a imagem original em 20 das 20 combinações de filtro e classificador. A AB média sobre os classificadores passa de 0,699 (original) para 0,767 (Frangi), 0,750 (Gabor), 0,773 (*black-hat*) e 0,772 (Frangi com *black-hat*). As maiores AB com pixels vêm de Frangi com *black-hat* e RF (0,803), Frangi com RF (0,799) e *black-hat* com MLP (0,798, com a maior AUC do conjunto, 0,896). A ablação mostra que a diferença não vem do pré-processamento comum: o canal verde com CLAHE, sem filtro, fica em 0,711, praticamente igual à original. As Seções 5.4 a 5.6 verificam o que essa diferença representa.

Com a **textura**, a situação se inverte: a imagem original e a equalização global são as melhores entradas (AB média 0,839 e 0,838, com até 0,859 na RF com a original), e os realces ficam entre 0,758 e 0,783. No conjunto **padrão da IC**, que reúne pixels e textura, os realces ficam pouco acima da original em média (0,747 contra valores entre 0,767 e 0,775), mas a melhor combinação isolada desse conjunto continua sendo a imagem original com AdaBoost (AB 0,837). As tabelas completas, com a AUC de cada configuração, estão no Apêndice B.

Figura 4 – Acurácia balanceada média das 120 configurações (`personBase_invert`, 50 *folds*)



Fonte: elaborada pelo autor. A linha branca separa as linhas de base e a ablação (acima) dos realces (abaixo).

A Tabela 2 quantifica o efeito de trocar a entrada, com a média sobre os classificadores em cada *fold*. Com pixels, todos os realces têm diferença positiva, de +0,051 (Gabor) a +0,074 (*black-hat*). Os intervalos de 95% de *black-hat* ([+0,012; +0,136]) e de Frangi com *black-hat* ([+0,004; +0,142]) excluem o zero, e o de Frangi toca o zero ([0,000; +0,135], $p = 0{,}051$). Depois do ajuste de Holm para as sete comparações, nenhuma diferença com pixels permanece significativa (p ajustado mínimo de 0,147), o que reflete o tamanho da base e a correção conservadora da variância. Com textura, as diferenças são todas negativas e duas sobrevivem ao ajuste (verde com CLAHE e Frangi com *black-hat*).

O teste de Friedman confirma que as representações diferem quando se consideram os 15 blocos ($\chi^2_F = 27{,}4$, $p < 0{,}001$; $F_F = 4{,}94$). A Figura 5 mostra os postos médios: a equalização

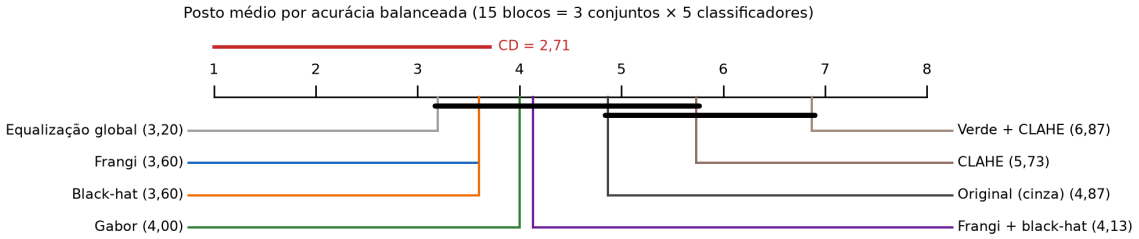
Tabela 2 – Diferença de acurácia balanceada em relação à imagem original (média dos cinco classificadores) e valor p ajustado por Holm

Representação	Pixels	Textura	Padrão da IC
Equalização global	+0,041 (0,395)	−0,001 (0,951)	+0,023 (1,000)
CLAHE	+0,012 (1,000)	−0,038 (0,173)	−0,021 (1,000)
Verde + CLAHE	+0,011 (1,000)	**−0,073 (0,035)**	−0,027 (1,000)
Frangi	+0,067 (0,257)	−0,059 (0,110)	+0,020 (1,000)
Gabor	+0,051 (0,395)	−0,056 (0,109)	+0,020 (1,000)
Black-hat	+0,074 (0,147)	−0,061 (0,089)	+0,028 (1,000)
Frangi + *black-hat*	+0,073 (0,234)	**−0,081 (0,014)**	+0,025 (1,000)

Fonte: elaborada pelo autor. Teste t pareado com a correção de Nadeau e Bengio sobre 50 *folds*; em negrito, p ajustado menor que 0,05.

global (3,20), o *black-hat* (3,60) e o Frangi (3,60) ocupam as primeiras posições, a original fica em 4,87 e a ablação com verde e CLAHE, em último (6,87). Com a diferença crítica de Nemenyi (CD = 2,71), apenas a ablação com verde e CLAHE se distingue das representações mais bem colocadas; as diferenças entre a imagem original e qualquer um dos realces não são significativas.

Figura 5 – Postos médios de Friedman das oito representações e diferença crítica de Nemenyi



Fonte: elaborada pelo autor. Representações ligadas por uma barra preta não diferem segundo o teste de Nemenyi ($\alpha = 0{,}05$).

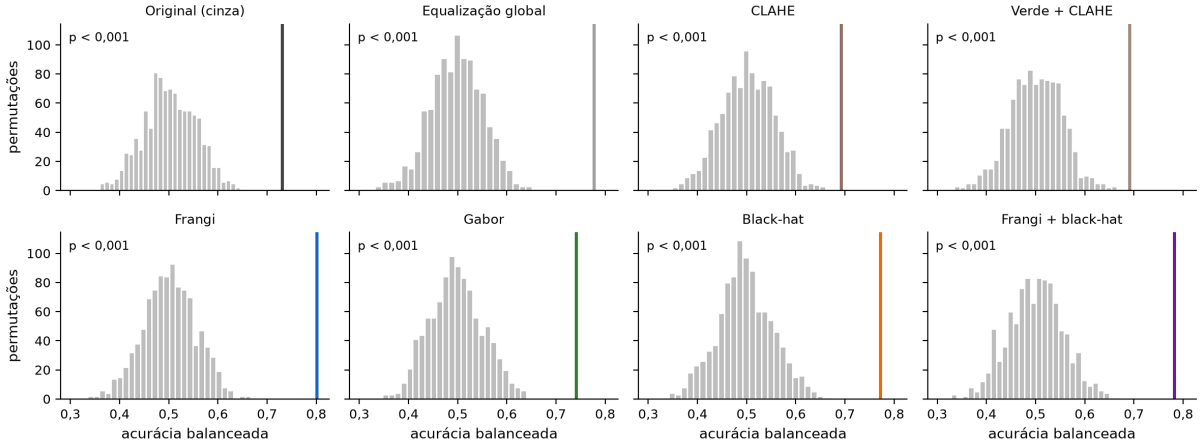
5.3 DESEMPENHO ACIMA DO ACASO

No teste de permutação com o modelo pré-especificado (RL sobre os pixels), todas as representações superam a distribuição nula (Figura 6), com $p = 0{,}001$, o menor valor possível com 1000 permutações. A AB observada vai de 0,691 (verde com CLAHE) a 0,802 (Frangi), contra uma média nula de 0,500 (desvio-padrão 0,055). A imagem original obtém 0,731.

5.4 REPLICAÇÃO NO LEIAUTE PERSONBASE

O segundo leiaute muda a leitura dos pixels (Tabela 3, Figura 7 e Tabela 15, no Apêndice B). Nele, a imagem original com pixels já alcança AB média de 0,793, e os realces ficam entre 0,787 e 0,820. Eles superam a original em apenas 10 das 20 combinações, com diferenças médias de −0,007 (*black-hat*) a +0,026 (Gabor), nenhuma significativa. O ganho com pixels do leiaute principal, portanto, não se repete. Os descritores de textura da imagem original, ao contrário, são

Figura 6 – Distribuição nula da acurácia balanceada (RL sobre pixels, 1000 permutações) e valor observado de cada representação



Fonte: elaborada pelo autor.

estáveis entre os leiautes (0,839 e 0,836). A correlação de Spearman entre as AB médias das 120 configurações nos dois leiautes é 0,45, mas a correlação entre os postos das oito representações é de apenas 0,14: a ordem entre as representações não se sustenta de uma amostra para a outra.

Tabela 3 – Replicação: acurácia balanceada média sobre os 15 blocos e posto de Friedman nos dois leiautes

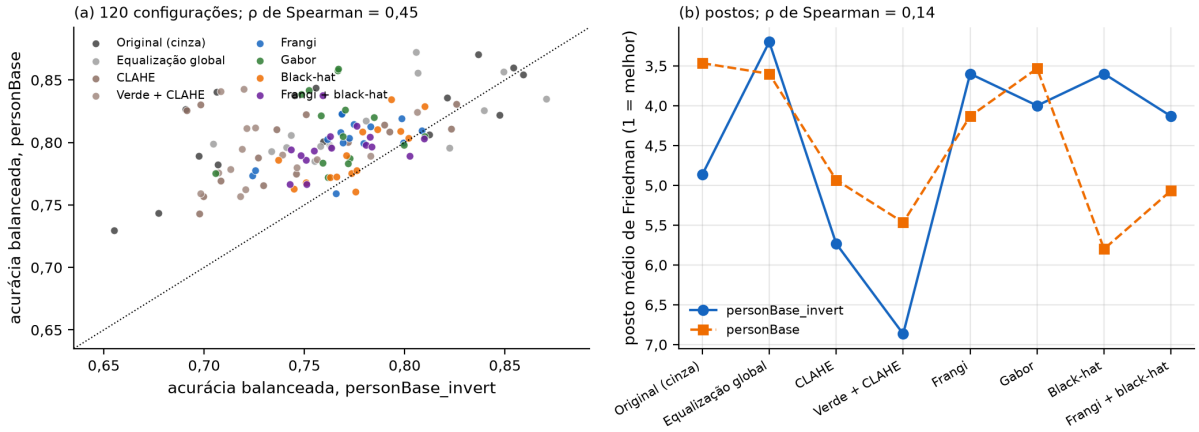
Representação	`personBase_invert`		`personBase`	
	AB média	Posto	AB média	Posto
Original (cinza)	0,762	4,87	0,816	3,47
Equalização global	0,782	3,20	0,815	3,60
CLAHE	0,746	5,73	0,797	4,93
Verde + CLAHE	0,732	6,87	0,794	5,47
Frangi	0,771	3,60	0,802	4,13
Gabor	0,766	4,00	0,812	3,53
Black-hat	0,775	3,60	0,791	5,80
Frangi + *black-hat*	0,767	4,13	0,796	5,07
Friedman, χ^2_F (p)	27,4 (<0,001)		15,2 (0,034)	

Fonte: elaborada pelo autor.

5.5 O ESPELHAMENTO DAS FAIXAS EXPLICA A DIFERENÇA ENTRE OS LEIAUTES

Os dois leiautes diferem num ponto de construção: no principal, as faixas do olho direito foram espelhadas. Quando essas faixas são devolvidas à orientação original (Tabela 4 e Figura 8), a imagem original com pixels passa de 0,699 para 0,752 (diferença de +0,053; $p = 0{,}064$) e o CLAHE, de 0,711 para 0,772 ($p = 0{,}017$), enquanto os realces quase não mudam (Frangi, +0,007; *black-hat*, +0,001). Depois do desespelhamento, a vantagem dos realces sobre a original cai para +0,021 (Frangi) a +0,035 (Frangi com *black-hat*), sem significância após o ajuste de Holm. O mecanismo é direto: o espelhamento leva o ângulo θ a $180° - \theta$ e troca os lados direito e esquerdo

Figura 7 – Replicação no leiaute `personBase`



Fonte: elaborada pelo autor.

da imagem em metade das faixas. Padrões de baixa frequência ligados à câmera e à iluminação, como gradientes de luz e reflexos, ficam do mesmo lado em todas as fotografias; o espelhamento inverte a posição desses padrões nas faixas do olho direito, e o vetor de pixels, que guarda a posição angular de cada valor, passa a ver duas populações desalinhadas. Os realces descartam esses padrões e por isso são pouco afetados. A vantagem dos realces no leiaute principal vem, em grande parte, de uma fragilidade da representação original diante do espelhamento, e não de informação adicional extraída pelos filtros.

Tabela 4 – Acurácia balanceada média com pixels antes e depois de desfazer o espelhamento, e no leiaute `personBase`

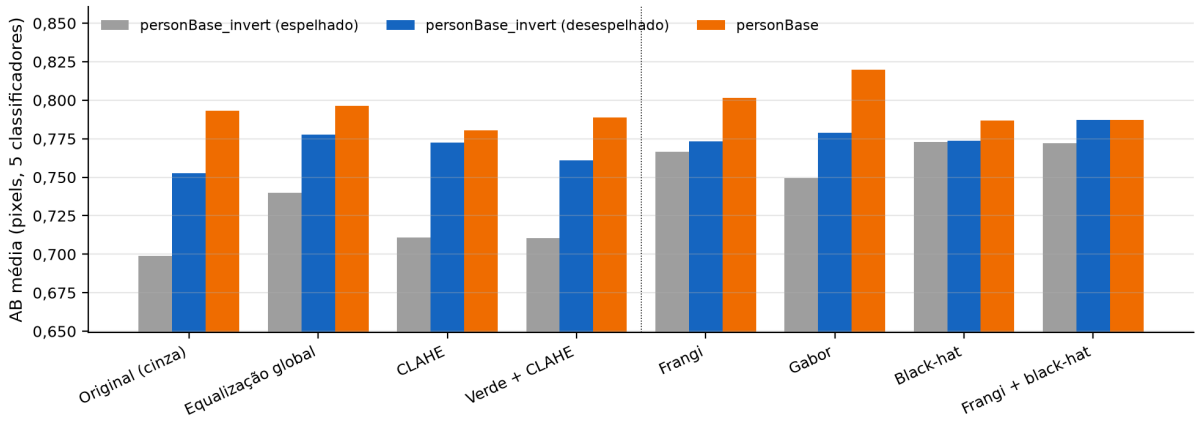
Representação	AB média com pixels			Δ ao desfazer o espelhamento (p)
	`personBase_invert` (espelhado)	`personBase_invert` (desespelhado)	`personBase`	
Original (cinza)	0,699	0,752	0,793	+0,053 (0,064)
Equalização global	0,740	0,778	0,796	+0,038 (0,179)
CLAHE	0,711	0,772	0,780	+0,062 (0,017)
Verde + CLAHE	0,711	0,761	0,789	+0,050 (0,087)
Frangi	0,767	0,773	0,802	+0,007 (0,747)
Gabor	0,750	0,779	0,820	+0,029 (0,202)
Black-hat	0,773	0,774	0,787	+0,001 (0,968)
Frangi + *black-hat*	0,772	0,787	0,787	+0,015 (0,481)

Fonte: elaborada pelo autor. Δ: diferença pareada, *fold* a *fold*, entre as versões desespelhada e espelhada (teste t corrigido).

5.6 ESTROMA OU BORDAS: ONDE ESTÁ O SINAL

A Figura 9 mostra o d de Cohen por pixel no leiaute principal. Na imagem original, apenas 1,6% dos pixels mantêm diferença significativa após o controle da FDR; com os realces, a fração sobe para 8,6% (Frangi), 11,0% (Gabor), 17,5% (Frangi com *black-hat*) e 30,4% (*black-hat*).

Figura 8 – Efeito de desfazer o espelhamento das faixas do olho direito



Fonte: elaborada pelo autor.

A localização, porém, varia: nos mapas de Frangi e de Frangi com *black-hat*, as diferenças se concentram numa faixa junto ao limbo (r próximo de 1); no Gabor, junto à margem pupilar (r próximo de 0); e o *black-hat* mostra, além da faixa límbica, regiões no próprio estroma.

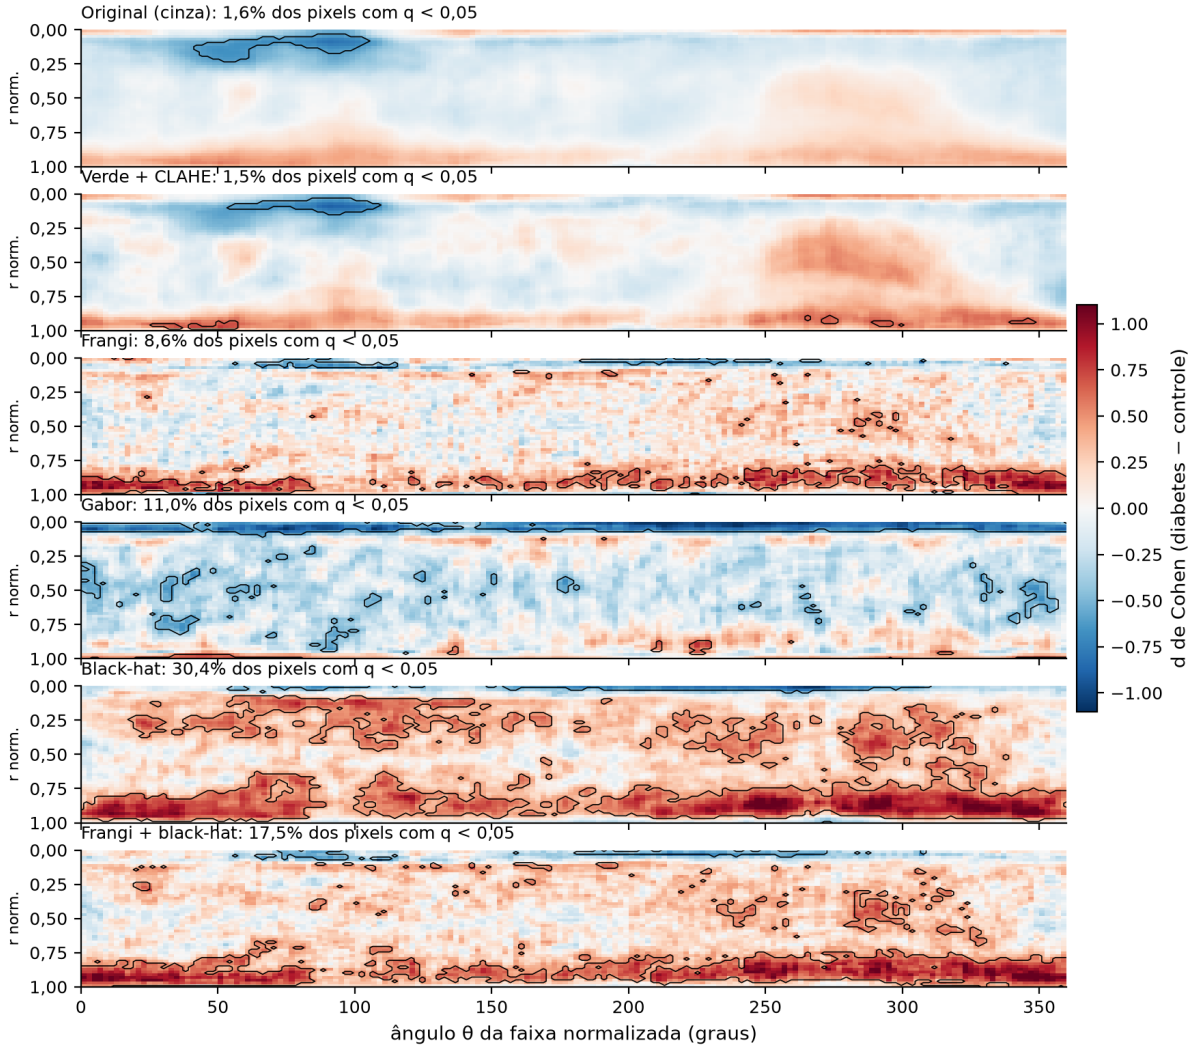
O recorte radial (Tabela 5 e Figura 10) confirma essa leitura. Com apenas o estroma, todas as representações perdem desempenho: a original fica em 0,632 e os realces, entre 0,597 e 0,702, superando a original em 10 das 20 combinações e sem diferença significativa. O *black-hat*, coerente com as regiões de estroma vistas no seu mapa, é o único realce que mantém AB em torno de 0,70 nessa região (0,702), mas sua vantagem sobre a original (+0,070) não sobrevive ao ajuste de Holm ($p = 0{,}207$). Com apenas as bordas, os realces alcançam entre 0,779 e 0,814, contra 0,704 da original, e a superam em 20 das 20 combinações. Para Frangi (+0,110; p ajustado 0,002), Gabor (+0,107; 0,003) e Frangi com *black-hat* (+0,090; 0,038), essa é a única vantagem dos realces que sobrevive ao ajuste de Holm em todo o estudo. O sinal que os realces evidenciam nesta base está, portanto, nas transições da pupila e do limbo, regiões que dependem da segmentação, da nitidez e das condições de aquisição, e não no estroma vascularizado.

Tabela 5 – Acurácia balanceada média com pixels por região radial da faixa e diferença em relação à original

Representação	Faixa inteira	Só estroma		Só bordas	
	AB	AB	Δ (p Holm)	AB	Δ (p Holm)
Original (cinza)	0,699	0,632	–	0,704	–
Equalização global	0,740	0,659	+0,027 (1,000)	0,751	+0,047 (0,319)
CLAHE	0,711	0,638	+0,006 (1,000)	0,725	+0,021 (0,795)
Verde + CLAHE	0,711	0,635	+0,004 (1,000)	0,711	+0,007 (0,795)
Frangi	0,767	0,609	−0,022 (1,000)	0,814	**+0,110 (0,002)**
Gabor	0,750	0,597	−0,035 (1,000)	0,811	**+0,107 (0,003)**
Black-hat	0,773	0,702	+0,070 (0,207)	0,779	+0,075 (0,080)
Frangi + *black-hat*	0,772	0,642	+0,011 (1,000)	0,794	**+0,090 (0,038)**

Fonte: elaborada pelo autor. Estroma: r entre 0,10 e 0,86; bordas: $r < 0{,}10$ ou $r > 0{,}86$. Δ: média dos cinco classificadores; teste t corrigido e ajuste de Holm; em negrito, p ajustado menor que 0,05.

Figura 9 – Diferença entre classes por pixel (*d* de Cohen, diabetes menos controle) em seis representações

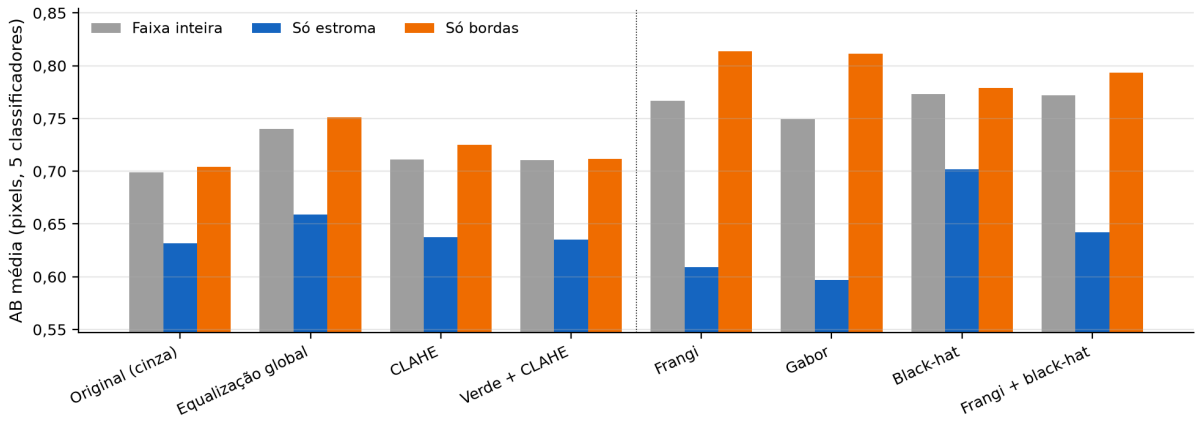


Fonte: elaborada pelo autor. Contornos pretos: pixels com $q < 0{,}05$ após o controle da FDR. Mapas agregados; nenhuma imagem individual da base é mostrada.

5.7 CONTROLES: ATALHO DE COR, DESCRITORES MANUAIS E FUSÃO

A Tabela 6 traz os três controles. As oito estatísticas globais de cor e iluminação alcançam AB de até 0,769 (MLP), o que confirma que a diferença de cor média entre as classes, encontrada na auditoria, carrega informação discriminativa por si só. Os 13 descritores manuais de vascularização alcançam até 0,777 (RL), valor da mesma ordem que o da imagem de Frangi como entrada direta (0,767 em média com pixels e até 0,799 com RF). A fusão da imagem original com a imagem realçada chega a 0,815 (original + Frangi, RF) e 0,804 (original + Gabor, AdaBoost), abaixo da melhor combinação do conjunto padrão da IC com a imagem original (0,837).

Figura 10 – Acurácia balanceada média com pixels da faixa inteira, só do estroma e só das bordas



Fonte: elaborada pelo autor.

Tabela 6 – Controles: acurácia balanceada (AUC entre parênteses), média de 50 *folds*

Entrada	RL	SVM	RF	MLP	AdaBoost
Referência: Original (cinza) (padrão da IC)	0,706 (0,799)	0,677 (0,765)	0,759 (0,830)	0,756 (0,835)	0,837 (0,910)
Referência: Frangi (padrão da IC)	0,775 (0,820)	0,726 (0,801)	0,799 (0,852)	0,769 (0,818)	0,769 (0,830)
Referência: Gabor (padrão da IC)	0,767 (0,834)	0,770 (0,838)	0,785 (0,840)	0,752 (0,812)	0,759 (0,807)
Cor e iluminação globais (8 valores)	0,739 (0,777)	0,684 (0,751)	0,718 (0,797)	0,769 (0,843)	0,685 (0,743)
Descritores manuais de Frangi (13 valores)	0,777 (0,845)	0,721 (0,782)	0,716 (0,736)	0,733 (0,771)	0,716 (0,776)
Fusão: original + Frangi (padrão da IC)	0,771 (0,843)	0,741 (0,803)	0,815 (0,855)	0,756 (0,835)	0,807 (0,861)
Fusão: original + Gabor (padrão da IC)	0,771 (0,846)	0,752 (0,825)	0,794 (0,860)	0,751 (0,829)	0,804 (0,841)

Fonte: elaborada pelo autor.

5.8 ROBUSTEZ FOTOMÉTRICA

A Tabela 7 e a Figura 11 mostram a variação da AB quando o modelo, treinado na condição original, é testado sob perturbações. A equalização global, o CLAHE e o Gabor são as representações mais estáveis (variação absoluta média de 0,025 para CLAHE, 0,030 para Gabor e 0,035 para a equalização global). A imagem original varia 0,068 em média, com quedas significativas sob escurecimento, gama 1,5 e ruído. O ruído gaussiano reduz a AB de quase todas as representações, e os realces de Frangi e *black-hat* são os mais afetados por ele e pelo desfoque (piores quedas de −0,275 e −0,286), o que é coerente com o fato de responderem justamente às estruturas finas que essas perturbações alteram. O Gabor, que combina oito orientações numa banda de frequências mais larga, é o único realce sem queda significativa sob ruído.

5.9 A FAIXA NORMALIZADA NÃO REGISTRA O TAMANHO DA PUPILA

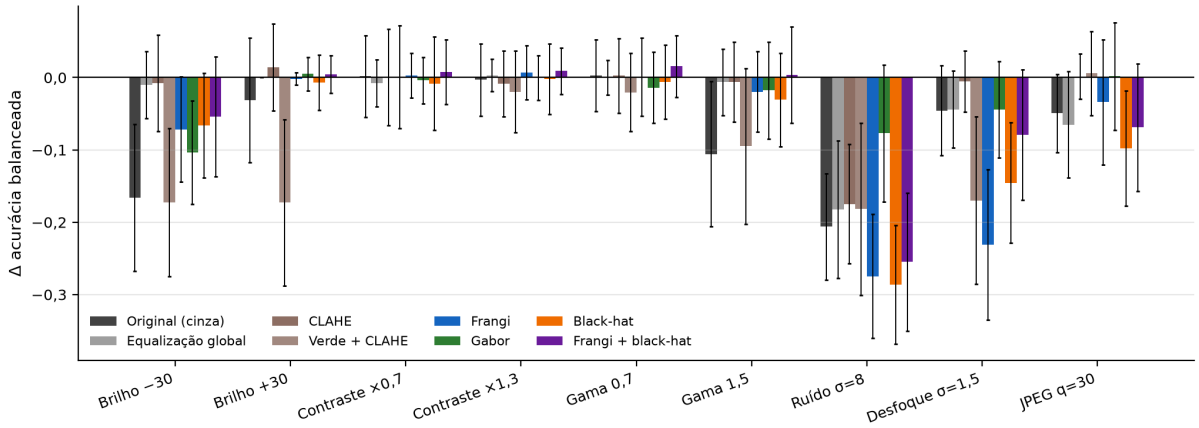
A Figura 12 mostra a fotografia pública com a pupila simulada em três tamanhos e as faixas normalizadas correspondentes, que são visualmente indistinguíveis. No olho sintético com o modelo linear, o SSIM entre a faixa de cada simulação e a de referência é de pelo menos 0,992 em toda a faixa de ρ testada, como prevê a Proposição 1. No modelo não linear, o SSIM cai até 0,76 nos extremos: o traço indireto existe, mas é pequeno diante da diferença entre íris diferentes

Tabela 7 – Variação da acurácia balanceada sob perturbações (RL, conjunto padrão da IC; treino na condição original)

Perturbação	Orig.	Eq.	CLAHE	V+CL	Frangi	Gabor	*B-hat*	F+BH
Brilho −30	**−0,166**	−0,010	−0,008	**−0,173**	−0,072	**−0,103**	−0,066	−0,054
Brilho +30	−0,031	0,000	+0,014	**−0,173**	−0,002	+0,005	−0,007	+0,004
Contraste ×0,7	+0,002	−0,008	+0,000	+0,001	+0,003	−0,004	−0,008	+0,008
Contraste ×1,3	−0,003	+0,003	−0,008	−0,020	+0,007	−0,001	−0,002	+0,009
Gama 0,7	+0,003	+0,000	+0,003	−0,021	+0,001	−0,014	−0,006	+0,016
Gama 1,5	**−0,106**	−0,006	−0,006	−0,095	−0,020	−0,018	−0,031	+0,004
Ruído (σ = 8)	**−0,206**	**−0,182**	**−0,175**	**−0,182**	**−0,275**	−0,077	**−0,286**	**−0,255**
Desfoque (σ = 1,5)	−0,046	−0,044	−0,005	**−0,170**	**−0,231**	−0,044	**−0,146**	−0,079
JPEG (q = 30)	−0,049	−0,065	+0,002	+0,006	−0,034	+0,002	**−0,098**	−0,069
Média de $\lvert\Delta\rvert$	0,068	0,035	0,025	0,093	0,071	0,030	0,072	0,055

Fonte: elaborada pelo autor. Em negrito, intervalo de 95% corrigido que exclui o zero. Abreviaturas: Orig., original; Eq., equalização global; V+CL, verde com CLAHE; B-hat, *black-hat*; F+BH, Frangi com *black-hat*.

Figura 11 – Variação da acurácia balanceada sob perturbações fotométricas



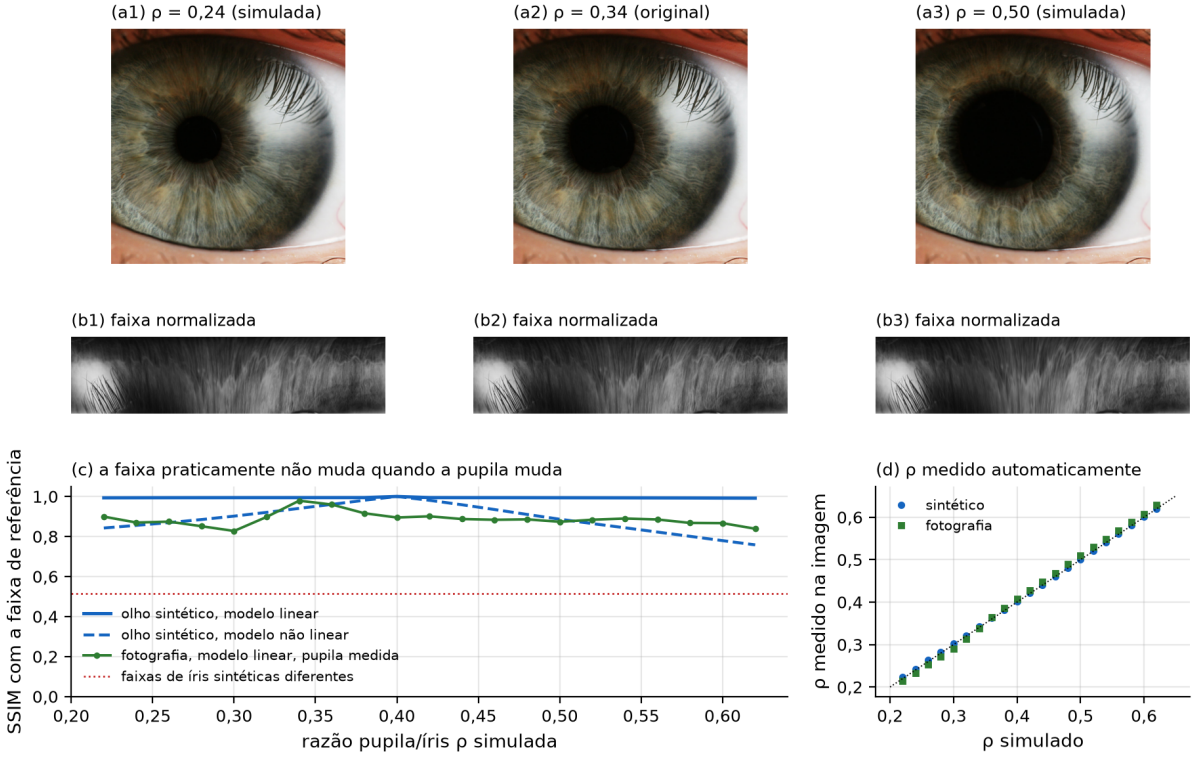
Fonte: elaborada pelo autor. Barras: média de 50 *folds*; hastes: intervalo de 95% corrigido.

(SSIM 0,52). Na fotografia real, com a pupila redetectada em cada imagem, o SSIM mínimo é 0,83; a redução decorre da perda de resolução radial quando o anel afina e do erro residual da detecção. Ao mesmo tempo, ρ medido automaticamente acompanha o valor simulado, com erro absoluto médio de 0,0015 no olho sintético e 0,0077 na fotografia.

5.10 COORTE SINTÉTICA: FAIXA, GEOMETRIA E FUSÃO

A Figura 13 ilustra os olhos sintéticos e as faixas normalizadas, que não mostram o tamanho da pupila. A Tabela 8 e a Figura 14 trazem o experimento 2×2. Sem efeito, todos os modelos ficam próximos de 0,5 (de 0,457 a 0,551), como esperado. Com o efeito só na geometria, o pipeline restrito à faixa fica em AUC 0,548, enquanto a geometria medida na fotografia alcança 0,742, ao lado do oráculo (0,743) e do limite teórico (0,760). Com o efeito só na textura, os papéis se invertem: a faixa alcança 0,870 e a geometria fica em 0,529. Com os dois efeitos, a fusão por

Figura 12 – Invariância da faixa normalizada ao tamanho da pupila



Fonte: elaborada pelo autor. Painéis (a) e (b): fotografia de Novák (2005) e simulações derivadas, sob CC BY-SA 2.5. Painéis (c) e (d): olho sintético e fotografia.

empilhamento (0,866) supera a faixa (0,825) e a geometria (0,755) isoladas; nos cenários com um único efeito, a fusão acompanha o melhor componente.

Tabela 8 – AUC média (IC 95% corrigido) na coorte sintética 2×2

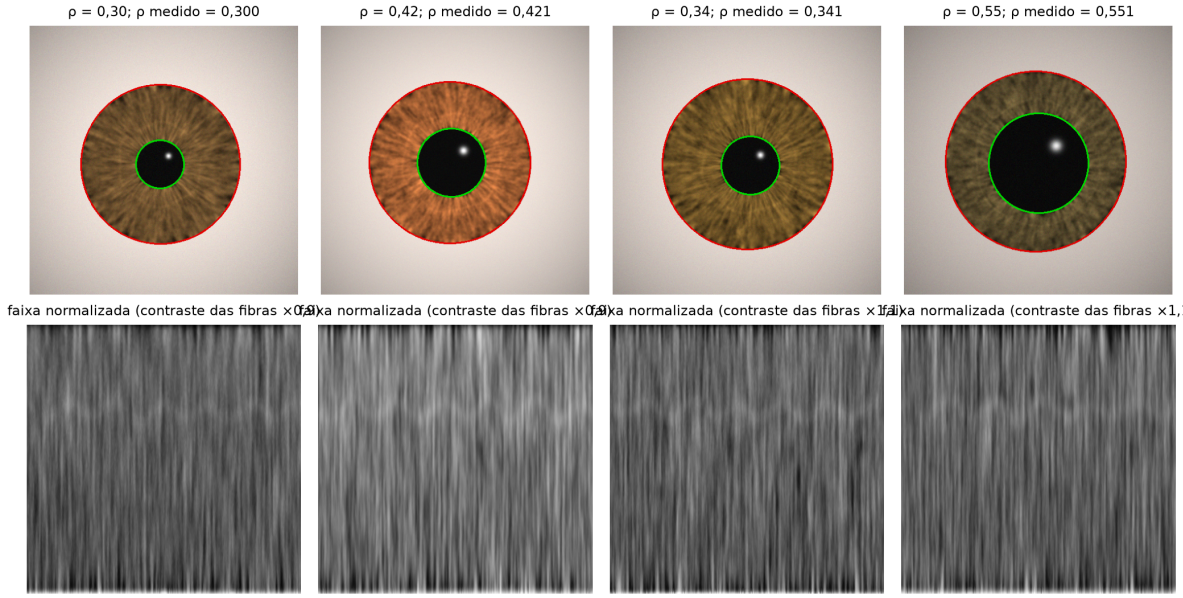
Cenário	Faixa (IC)	Geometria medida	Fusão	Oráculo
Sem sinal	0,551 [0,49; 0,61]	0,461 [0,38; 0,55]	0,526 [0,45; 0,61]	0,457 [0,37; 0,54]
Sinal só na geometria	0,548 [0,47; 0,63]	0,742 [0,65; 0,83]	0,735 [0,65; 0,82]	0,743 [0,65; 0,83]
Sinal só na textura	0,870 [0,82; 0,92]	0,529 [0,41; 0,64]	0,870 [0,82; 0,92]	0,531 [0,41; 0,65]
Sinal na geometria e na textura	0,825 [0,78; 0,87]	0,755 [0,68; 0,83]	0,866 [0,82; 0,91]	0,754 [0,68; 0,83]

Fonte: elaborada pelo autor. Validação cruzada estratificada 5×5 com 100 olhos por classe em cada cenário.

5.11 MEDIÇÃO AUTOMÁTICA DE ρ

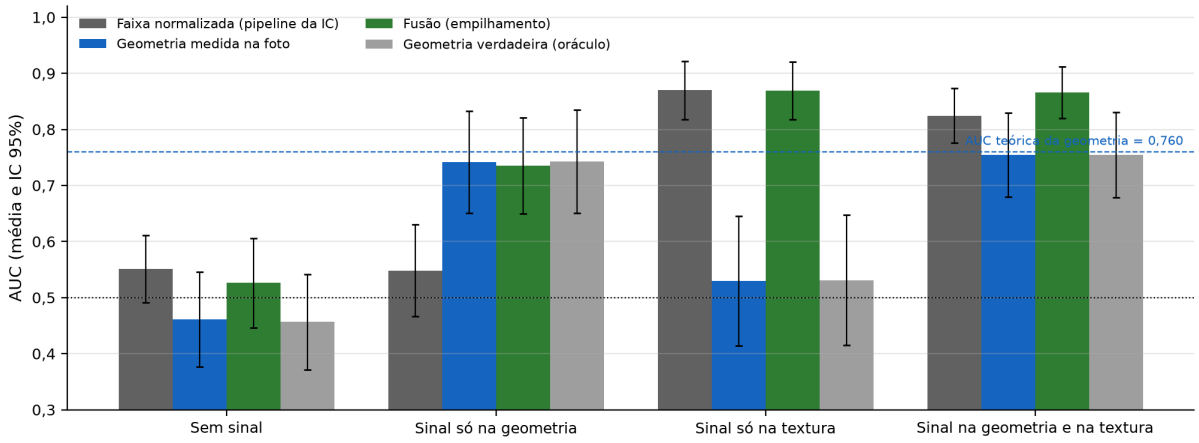
A Tabela 9 e a Figura 15 comparam os detectores. O segmentador por contornos ativos do pipeline da IC errou ρ em mais de 0,03 em 11 dos 12 olhos testados, quase sempre por superestimar a pupila, com tempo médio de 7,5 s por imagem. O detector por limiar e Hough errou em mais de 0,03 em 81 de 800 olhos (erro absoluto médio 0,0152), e seus erros se concentram nas pupilas pequenas. O motivo está no limiar: quando a pupila ocupa menos de 3% da imagem, o que nestas imagens corresponde a ρ abaixo de cerca de 0,33, o percentil 3 cai dentro da íris, e a região escura limiarizada se estende além da pupila. Por construção, esse detector também não encontra

Figura 13 – Olhos sintéticos com detecção automática e faixas normalizadas



Fonte: elaborada pelo autor. Círculos: pupila (verde) e limbo (vermelho) detectados automaticamente.

Figura 14 – AUC dos quatro modelos nos quatro cenários da coorte sintética



Fonte: elaborada pelo autor.

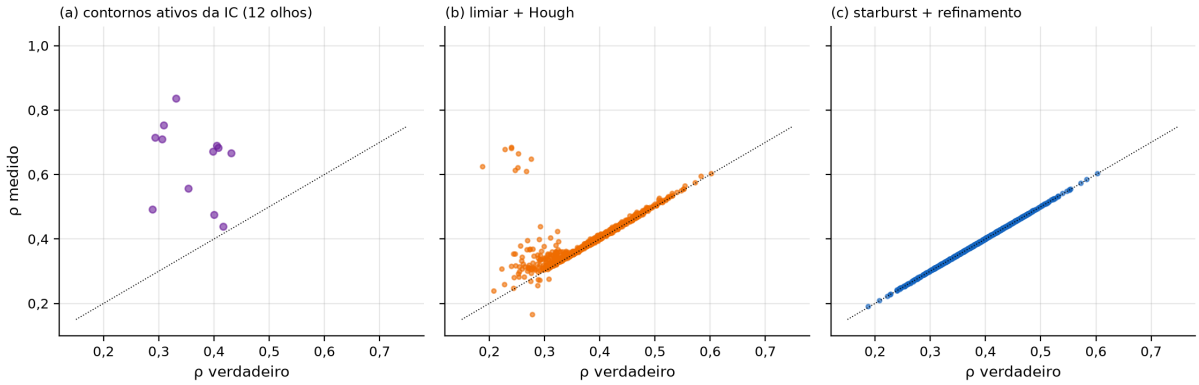
o limbo quando $\rho > 0{,}625$, porque sua busca por Hough começa em 1,6 vez o raio da pupila. O detector desta etapa errou em 0 de 800 olhos, com erro absoluto médio de 0,0012, viés de +0,0012 e correlação de 1,0000 com o valor verdadeiro.

Tabela 9 – Erro na medição automática de ρ na coorte sintética

Medida	Contornos ativos (IC)*	Limiar + Hough	*Starburst* + refinamento
Erro absoluto médio de ρ	0,279	0,0152	0,0012
Erro absoluto mediano	–	0,0055	0,0012
Percentil 95 do erro absoluto	–	0,0470	0,0022
Maior erro absoluto	–	0,451	0,0034
Viés (medido − verdadeiro)	–	0,0145	0,0012
Olhos com erro > 0,03	11 de 12	81 de 800	0 de 800
Correlação com ρ verdadeiro	–	0,743	1,0000
Tempo médio por imagem (s)	7,5	–	0,3

Fonte: elaborada pelo autor. *Subconjunto de 12 olhos, por causa do custo do segmentador.

Figura 15 – ρ medido contra ρ verdadeiro para os três detectores



Fonte: elaborada pelo autor.

6 DISCUSSÃO

6.1 PERGUNTA 1: AS IMAGENS FILTRADAS PODEM ENTRAR DIRETAMENTE NO PIPELINE?

Do ponto de vista técnico, sim: os realces entram no pipeline como qualquer outra transformação, sem nenhum descritor novo, e classificam acima do acaso. A pergunta de fundo, porém, era se essa entrada traria resultados interessantes sobre a vascularização, e nesta base a resposta é negativa. O ganho de cerca de 5 a 7 pontos percentuais observado com pixels no leiaute principal não resistiu a três controles independentes: não se repetiu no segundo leiaute; foi explicado em grande parte pelo espelhamento das faixas, que prejudica a imagem original e quase não afeta os realces; e desapareceu quando apenas o estroma foi usado, concentrando-se nas bordas pupilar e límbica. A Hipótese 1 se confirma no mecanismo (os realces removem os padrões de baixa frequência e deixam o pipeline menos sensível à orientação das faixas), mas não na consequência esperada (uma separação melhor das classes pela estrutura do estroma).

Dois achados reforçam essa leitura. Os descritores de textura da imagem original são os mais altos e os mais estáveis nos dois leiautes, mas incluem o histograma de intensidades, e oito estatísticas globais de cor bastam para AB de 0,769: parte do sinal desta base está em propriedades globais que podem refletir a aquisição das duas classes, e não a íris (Geirhos et al., 2020; Zech et al., 2018). Além disso, as bordas que concentram o sinal dos realces são as regiões mais sensíveis à segmentação, à nitidez e à iluminação. Elas também podem conter alterações do limbo associadas à idade, que a base não permite controlar porque não registra a idade dos participantes.

Quanto à alternativa dos descritores manuais, os 13 descritores calculados sobre a resposta de Frangi alcançaram 0,777 no melhor classificador, sem superar a imagem filtrada nem a textura da original, e incluem o terço externo da faixa, sujeito ao mesmo efeito de borda. Criar descritores manuais de vascularização sobre esta base, portanto, não resolveria o problema, que está na origem do sinal e não na forma de representá-lo.

A robustez segue o mesmo padrão: as representações equalizadas e o Gabor são as mais estáveis, enquanto Frangi e *black-hat* perdem desempenho sob ruído e desfoque. Na prática, a imagem filtrada é uma entrada viável, com desempenho equivalente ao da imagem original e menor sensibilidade à orientação das faixas, e o Gabor é o realce mais estável. Uma avaliação da vascularização que mereça esse nome exige máscaras que excluam as bordas pupilar e límbica, os controles de atalho usados aqui e dados com identificação por pessoa e rótulos verificados.

6.2 PERGUNTA 2: A PUPILA PRECISA DE DESCRITORES MANUAIS?

Precisa de descritores explícitos, mas não de trabalho manual. A Proposição 1 e o experimento B1 mostram que a faixa normalizada, que é o que o pipeline usa depois da segmentação, praticamente não muda quando a pupila muda; o experimento B2 mostra que um efeito puramente geométrico é invisível para o pipeline restrito à faixa e recuperável quando ρ entra como descritor, e que a fusão aproveita as duas fontes quando ambas carregam sinal. A Hipótese 2 se confirma. Esses descritores (ρ, τ e ϵ) são calculados automaticamente a partir da própria fotografia, na etapa de segmentação; nenhuma medida manual é necessária. Em resumo, o pipeline precisa da fotografia do olho inteiro, e não apenas da faixa normalizada, e de um caminho próprio para a geometria, implementado pela fusão por empilhamento. O mesmo comportamento apareceu na execução do pipeline completo pela linha de comando, com fotografias sintéticas.

Três observações completam a resposta. Primeiro, como $\tau = 1 - \rho$, o diâmetro relativo da pupila e a espessura relativa do anel são uma única variável; só a calibração em milímetros, ou uma medida de AS-OCT para a espessura anatômica, acrescentaria informação nova. Segundo, a qualidade da segmentação é decisiva: o segmentador por contornos ativos do pipeline da IC não mediu ρ corretamente em 11 dos 12 olhos testados, e o detector desta etapa foi necessário. Terceiro, a base legada não permite testar a pergunta com dados reais, porque contém apenas faixas normalizadas, das quais a Proposição 1 mostra que ρ não pode ser recuperado.

6.3 LIMITAÇÕES

a) a base legada não tem identificadores de pessoa; olhos de uma mesma pessoa podem ter caído em *folds* diferentes, o que tende a inflar todas as métricas, embora não favoreça uma representação em particular;

b) a classe positiva é diabetes informado, sem verificação clínica nem confirmação do subtipo DM2, e o artigo associado à base foi retratado; os números são exploratórios e não estimam desempenho clínico;

c) a segmentação original das faixas é desconhecida; as diferenças concentradas nas bordas podem refletir essa segmentação ou a aquisição, e não há como separá-las sem as fotografias originais;

d) o leiaute principal mistura faixas espelhadas e não espelhadas, o que prejudica representações que dependem da posição angular;

e) com 123 imagens, os intervalos de confiança são largos, e as melhores combinações de cada representação (Apêndice B) resultam de uma seleção otimista entre 15 alternativas;

f) a coorte sintética demonstra o mecanismo, mas não estima o tamanho real do efeito pupilar no DM2, que depende da iluminação e do protocolo de aquisição; o tamanho

do efeito de textura foi escolhido para equilibrar o desenho;

g) os realces respondem a cílios, pálpebras e reflexos, que ainda não têm máscaras próprias.

7 CONCLUSÃO E PRÓXIMOS PASSOS

As duas perguntas desta etapa têm respostas objetivas. Para a vascularização, as imagens filtradas podem entrar diretamente no pipeline da IC, sem descritores manuais, e classificam tão bem quanto a imagem original, com a vantagem de serem menos sensíveis à orientação das faixas. Nesta base, porém, o desempenho não pode ser atribuído à vascularização: o ganho aparente dos realces não se repetiu no segundo leiaute, foi explicado em grande parte pelo espelhamento das faixas e se concentrou nas bordas pupilar e límbica, e não no estroma. Pelos mesmos motivos, descritores manuais de vascularização não trariam ganho sobre esta base. Para a pupila, a faixa normalizada descarta o tamanho da pupila, então a geometria precisa entrar como descritor explícito; esse descritor é extraído automaticamente da fotografia, e o pipeline já faz essa extração e a fusão. Os resultados negativos sobre a vascularização são, eles próprios, uma contribuição: mostram que métricas altas nesta base podem surgir de bordas, de orientação e de cor, e fornecem o conjunto de controles que qualquer resultado futuro precisa atravessar.

Os próximos passos propostos para o PGC III são:

a) obter um conjunto com fotografias completas (não apenas faixas), identificadores de pessoa, diagnóstico de DM2 verificado, idade e protocolo de iluminação registrados, condição para testar a geometria pupilar em dados reais, separar olhos da mesma pessoa na validação cruzada e controlar o efeito da idade;

b) aplicar máscaras que excluam as bordas pupilar e límbica, os cílios, as pálpebras e os reflexos antes do realce, e avaliar a vascularização apenas no estroma;

c) manter, em qualquer novo conjunto, os controles introduzidos aqui: ablação do pré-processamento, atalho de cor, teste de permutação, replicação, recorte radial e correção para comparações múltiplas;

d) dar preferência ao Gabor entre os realces, pelo equilíbrio entre desempenho e robustez, e padronizar a aquisição (foco, compressão e iluminação);

e) calibrar ρ em milímetros pelo diâmetro da íris e registrar a iluminação, para aproximar o diâmetro pupilar dos estudos clínicos;

f) retomar os descritores manuais de vascularização apenas se, em dados adequados e restritos ao estroma, a imagem filtrada mostrar sinal que justifique uma descrição mais específica.

REFERÊNCIAS

BENJAMINI, Y.; HOCHBERG, Y. Controlling the false discovery rate: a practical and powerful approach to multiple testing. **Journal of the Royal Statistical Society: Series B (Methodological)**, *[S. l.]*, v. 57, n. 1, p. 289-300, 1995. DOI: 10.1111/j.2517-6161.1995.tb02031.x.

BOUCKAERT, R. R.; FRANK, E. Evaluating the replicability of significance tests for comparing learning algorithms. In: PACIFIC-ASIA CONFERENCE ON KNOWLEDGE DISCOVERY AND DATA MINING, 8., 2004, Sydney. **Advances in knowledge discovery and data mining**. Berlin: Springer, 2004. p. 3-12. (Lecture Notes in Computer Science, v. 3056). DOI: 10.1007/978-3-540-24775-3_3.

BRADSKI, G. The OpenCV library. **Dr. Dobb's Journal of Software Tools**, *[S. l.]*, 2000.

CAHILL, M.; EUSTACE, P.; DE JESUS, V. Pupillary autonomic denervation with increasing duration of diabetes mellitus. **British Journal of Ophthalmology**, *[S. l.]*, v. 85, n. 10, p. 1225-1230, 2001. DOI: 10.1136/bjo.85.10.1225.

COHEN, J. **Statistical power analysis for the behavioral sciences**. 2. ed. Hillsdale: Lawrence Erlbaum, 1988.

CUI, L.; XIAO, Y.; XIANG, Z.; CHEN, Z.; YANG, C.; ZOU, H. Study on the correlation between iris blood flow, iris thickness and pupil diameter in the resting state and after pharmacological mydriasis in patients with diabetes mellitus. **BMC Ophthalmology**, *[S. l.]*, v. 24, n. 1, art. 52, 2024. DOI: 10.1186/s12886-024-03322-y.

DAUGMAN, J. G. Uncertainty relation for resolution in space, spatial frequency, and orientation optimized by two-dimensional visual cortical filters. **Journal of the Optical Society of America A**, *[S. l.]*, v. 2, n. 7, p. 1160-1169, 1985. DOI: 10.1364/JOSAA.2.001160.

DAUGMAN, J. G. High confidence visual recognition of persons by a test of statistical independence. **IEEE Transactions on Pattern Analysis and Machine Intelligence**, *[S. l.]*, v. 15, n. 11, p. 1148-1161, 1993. DOI: 10.1109/34.244676.

DAUGMAN, J. How iris recognition works. **IEEE Transactions on Circuits and Systems for Video Technology**, *[S. l.]*, v. 14, n. 1, p. 21-30, 2004. DOI: 10.1109/TCSVT.2003.818350.

DEMŠAR, J. Statistical comparisons of classifiers over multiple data sets. **Journal of Machine Learning Research**, *[S. l.]*, v. 7, p. 1-30, 2006. Disponível em: https://jmlr.org/papers/v7/demsar06a.html. Acesso em: 24 out. 2026.

DUDA, R. O.; HART, P. E. Use of the Hough transformation to detect lines and curves in pictures. **Communications of the ACM**, *[S. l.]*, v. 15, n. 1, p. 11-15, 1972. DOI: 10.1145/361237.361242.

ERNST, E. Iridology: not useful and potentially harmful. **Archives of Ophthalmology**, *[S. l.]*, v. 118, n. 1, p. 120-121, 2000. DOI: 10.1001/archopht.118.1.120.

FAWCETT, T. An introduction to ROC analysis. **Pattern Recognition Letters**, *[S. l.]*, v. 27, n. 8, p. 861-874, 2006. DOI: 10.1016/j.patrec.2005.10.010.

FISCHLER, M. A.; BOLLES, R. C. Random sample consensus: a paradigm for model fitting with applications to image analysis and automated cartography. **Communications of the ACM**, *[S. l.]*, v. 24, n. 6, p. 381-395, 1981. DOI: 10.1145/358669.358692.

FRANGI, A. F.; NIESSEN, W. J.; VINCKEN, K. L.; VIERGEVER, M. A. Multiscale vessel enhancement filtering. In: INTERNATIONAL CONFERENCE ON MEDICAL IMAGE COMPUTING AND COMPUTER-ASSISTED INTERVENTION, 1., 1998, Cambridge. **Proceedings** [. . .]. Berlin: Springer, 1998. p. 130-137. (Lecture Notes in Computer Science, v. 1496). DOI: 10.1007/BFb0056195.

FRIEDMAN, M. The use of ranks to avoid the assumption of normality implicit in the analysis of variance. **Journal of the American Statistical Association**, *[S. l.]*, v. 32, n. 200, p. 675-701, 1937. DOI: 10.1080/01621459.1937.10503522.

GEIRHOS, R.; JACOBSEN, J.-H.; MICHAELIS, C.; ZEMEL, R.; BRENDEL, W.; BETHGE, M.; WICHMANN, F. A. Shortcut learning in deep neural networks. **Nature Machine Intelligence**, *[S. l.]*, v. 2, n. 11, p. 665-673, 2020. DOI: 10.1038/s42256-020-00257-z.

HANLEY, J. A.; MCNEIL, B. J. The meaning and use of the area under a receiver operating characteristic (ROC) curve. **Radiology**, *[S. l.]*, v. 143, n. 1, p. 29-36, 1982. DOI: 10.1148/radiology.143.1.7063747.

HARALICK, R. M.; SHANMUGAM, K.; DINSTEIN, I. Textural features for image classification. **IEEE Transactions on Systems, Man, and Cybernetics**, *[S. l.]*, v. SMC-3, n. 6, p. 610-621, 1973. DOI: 10.1109/TSMC.1973.4309314.

HOLLINGSWORTH, K.; BOWYER, K. W.; FLYNN, P. J. Pupil dilation degrades iris biometric performance. **Computer Vision and Image Understanding**, *[S. l.]*, v. 113, n. 1, p. 150-157, 2009. DOI: 10.1016/j.cviu.2008.08.001.

HOLM, S. A simple sequentially rejective multiple test procedure. **Scandinavian Journal of Statistics**, *[S. l.]*, v. 6, n. 2, p. 65-70, 1979.

IMAN, R. L.; DAVENPORT, J. M. Approximations of the critical region of the Friedman statistic. **Communications in Statistics - Theory and Methods**, *[S. l.]*, v. 9, n. 6, p. 571-595, 1980. DOI: 10.1080/03610928008827904.

JAIN, A. K.; FARROKHNIA, F. Unsupervised texture segmentation using Gabor filters. **Pattern Recognition**, *[S. l.]*, v. 24, n. 12, p. 1167-1186, 1991. DOI: 10.1016/0031-3203(91)90143-S.

KÅSA, I. A circle fitting procedure and its error analysis. **IEEE Transactions on Instrumentation and Measurement**, *[S. l.]*, v. IM-25, n. 1, p. 8-14, 1976. DOI: 10.1109/TIM.1976.6312298.

KASS, M.; WITKIN, A.; TERZOPOULOS, D. Snakes: active contour models. **International Journal of Computer Vision**, *[S. l.]*, v. 1, n. 4, p. 321-331, 1988. DOI: 10.1007/BF00133570.

LI, D.; WINFIELD, D.; PARKHURST, D. J. Starburst: a hybrid algorithm for video-based eye tracking combining feature-based and model-based approaches. In: IEEE COMPUTER SOCIETY CONFERENCE ON COMPUTER VISION AND PATTERN RECOGNITION WORKSHOPS, 2005, San Diego. **Proceedings** [. . .]. Los Alamitos: IEEE Computer Society, 2005. p. 79. DOI: 10.1109/CVPR.2005.531.

MORADI, P.; NAZER, N.; KHASAHMADI, A.; MOHAMMADZADEH, H.; KHOJASTEH JAFARI, H. Retraction notice: Discovering informative regions in iris images to predict diabetes. In: NATIONAL AND INTERNATIONAL IRANIAN CONFERENCE ON BIOMEDICAL ENGINEERING, 25., 2018. **Proceedings** [. . .]. *[S. l.]*: IEEE, 2018. DOI: 10.1109/ICBME45317.2018.10207763. Artigo original retratado: DOI: 10.1109/ICBME.2018.8703564.

NADEAU, C.; BENGIO, Y. Inference for the generalization error. **Machine Learning**, *[S. l.]*, v. 52, n. 3, p. 239-281, 2003. DOI: 10.1023/A:1024068626366.

NEMENYI, P. B. **Distribution-free multiple comparisons**. 1963. Tese (Doutorado) – Princeton University, Princeton, 1963.

NOVÁK, P. **Eye iris**. 2005. 1 fotografia, color. Licença CC BY-SA 2.5. Disponível em: https://commons.wikimedia.org/wiki/File:Eye_iris.jpg. Acesso em: 7 out. 2026.

OJALA, M.; GARRIGA, G. C. Permutation tests for studying classifier performance. **Journal of Machine Learning Research**, *[S. l.]*, v. 11, p. 1833-1863, 2010. Disponível em: https://jmlr.org/papers/v11/ojala10a.html. Acesso em: 24 out. 2026.

OJALA, T.; PIETIKÄINEN, M.; MÄENPÄÄ, T. Multiresolution gray-scale and rotation invariant texture classification with local binary patterns. **IEEE Transactions on Pattern Analysis and Machine Intelligence**, *[S. l.]*, v. 24, n. 7, p. 971-987, 2002. DOI: 10.1109/TPAMI.2002.1017623.

PEDREGOSA, F. et al. Scikit-learn: machine learning in Python. **Journal of Machine Learning Research**, *[S. l.]*, v. 12, n. 85, p. 2825-2830, 2011. Disponível em: https://jmlr.org/papers/v12/pedregosa11a.html. Acesso em: 7 out. 2026.

PHIPSON, B.; SMYTH, G. K. Permutation P-values should never be zero: calculating exact P-values when permutations are randomly drawn. **Statistical Applications in Genetics and Molecular Biology**, *[S. l.]*, v. 9, n. 1, art. 39, 2010. DOI: 10.2202/1544-6115.1585.

ROBERTS, P. K.; GOLDSTEIN, D. A.; FAWZI, A. A. Anterior segment optical coherence tomography angiography for identification of iris vasculature and staging of iris neovascularization: a pilot study. **Current Eye Research**, *[S. l.]*, v. 42, n. 8, p. 1136-1142, 2017. DOI: 10.1080/02713683.2017.1293113.

RÜFER, F.; SCHRÖDER, A.; ERB, C. White-to-white corneal diameter: normal values in healthy humans obtained with the Orbscan II topography system. **Cornea**, *[S. l.]*, v. 24, n. 3, p. 259-261, 2005. DOI: 10.1097/01.ico.0000148312.01805.53.

SIMON, A.; WORTHEN, D. M.; MITAS, J. A. An evaluation of iridology. **JAMA**, *[S. l.]*, v. 242, n. 13, p. 1385-1389, 1979. DOI: 10.1001/jama.1979.03300130029014.

SOILLE, P. **Morphological image analysis**: principles and applications. 2. ed. Berlin: Springer, 2004. DOI: 10.1007/978-3-662-05088-0.

THAKAR, M.; TRIPATHY, S. P.; DUTTA, P.; BHATTACHARYA, S.; DHAKA, U. Quantitative automated pupillometry in diabetic patients and correlation with retinal nerve fibre layer thickness. **Eye**, *[S. l.]*, v. 39, n. 10, p. 1983-1989, 2025. DOI: 10.1038/s41433-025-03793-3.

TOMEO-REYES, I.; ROSS, A.; CLARK, A. D.; CHANDRAN, V. A biomechanical approach to iris normalization. In: INTERNATIONAL CONFERENCE ON BIOMETRICS, 8., 2015, Phuket. **Proceedings** [. . .]. *[S. l.]*: IEEE, 2015. p. 9-16.

VAN DER WALT, S.; SCHÖNBERGER, J. L.; NUNEZ-IGLESIAS, J.; BOULOGNE, F.; WARNER, J. D.; YAGER, N.; GOUILLART, E.; YU, T. scikit-image: image processing in Python. **PeerJ**, *[S. l.]*, v. 2, e453, 2014. DOI: 10.7717/peerj.453.

WANG, Z.; BOVIK, A. C.; SHEIKH, H. R.; SIMONCELLI, E. P. Image quality assessment: from error visibility to structural similarity. **IEEE Transactions on Image Processing**, *[S. l.]*, v. 13, n. 4, p. 600-612, 2004. DOI: 10.1109/TIP.2003.819861.

WATSON, A. B.; YELLOTT, J. I. A unified formula for light-adapted pupil size. **Journal of Vision**, *[S. l.]*, v. 12, n. 10, art. 12, 2012. DOI: 10.1167/12.10.12.

WOLPERT, D. H. Stacked generalization. **Neural Networks**, *[S. l.]*, v. 5, n. 2, p. 241-259, 1992. DOI: 10.1016/S0893-6080(05)80023-1.

WYATT, H. J. A 'minimum-wear-and-tear' meshwork for the iris. **Vision Research**, *[S. l.]*, v. 40, n. 16, p. 2167-2176, 2000.

ZECH, J. R.; BADGELEY, M. A.; LIU, M.; COSTA, A. B.; TITANO, J. J.; OERMANN, E. K. Variable generalization performance of a deep learning model to detect pneumonia in chest radiographs: a cross-sectional study. **PLOS Medicine**, *[S. l.]*, v. 15, n. 11, e1002683, 2018. DOI: 10.1371/journal.pmed.1002683.

ZETT, C.; STINA, D. M. R.; KATO, R. T.; NOVAIS, E. A.; ALLEMANN, N. Comparison of anterior segment optical coherence tomography angiography and fluorescein angiography for iris vasculature analysis. **Graefe's Archive for Clinical and Experimental Ophthalmology**, *[S. l.]*, v. 256, n. 4, p. 683-691, 2018. DOI: 10.1007/s00417-018-3935-7.

ZHOU, Y.; WANG, T.; GUO, Z.; SHE, F.; ZENG, J.; ZHU, X. Assessment of iris vasculature in type 2 diabetes mellitus patients without diabetic retinopathy using anterior segment optical coherence tomography angiography. **Scientific Reports**, *[S. l.]*, v. 15, n. 1, art. 19035, 2025. DOI: 10.1038/s41598-025-04463-w.

ZUIDERVELD, K. Contrast limited adaptive histogram equalization. In: HECKBERT, P. S. (ed.). **Graphics gems IV**. Boston: AP Professional, 1994. p. 474-485. DOI: 10.1016/B978-0-12-336156-1.50061-6.

APÊNDICE A – REPRODUTIBILIDADE

Os comandos a seguir, executados a partir da raiz do repositório em PowerShell, reproduzem os resultados, executam os testes e compilam este documento. A base legada não acompanha o repositório: o caminho do arquivo Data.zip, ou da pasta Data/Data, é informado pela opção `-data` ou pela variável de ambiente `IRIS_LEGACY_DATA`.

```
$env:IRIS_LEGACY_DATA = "C:\caminho\para\Data.zip"
.\.venv\Scripts\python.exe experiments\pgc3_vascular_pipeline.py
.\.venv\Scripts\python.exe experiments\pgc3_pupil_geometry.py
.\.venv\Scripts\python.exe experiments\pgc3_numbers.py
.\.venv\Scripts\python.exe -m unittest discover -s tests
cd docs\PGC_3
pdflatex resultados_preliminares_pgc3.tex
pdflatex resultados_preliminares_pgc3.tex
```

O primeiro *script* levou 117 minutos e o segundo, 3 minutos, numa máquina com 16 processadores lógicos. As features de cada representação ficam guardadas em results/pgc3/cache, de modo que execuções seguintes reaproveitam a extração. As partições da validação cruzada usam as sementes 2026 a 2035; o teste de permutação, as sementes 10000 a 10999; e a coorte sintética, sementes fixas por olho. O ambiente usou Python 3.12.10, NumPy 2.5.3, SciPy 1.18.1, scikit-learn 1.9.1 (Pedregosa et al., 2011), scikit-image 0.26.0 (van der Walt et al., 2014) e OpenCV 5.0.0 (Bradski, 2000).

Os testes automatizados (tests/test_pgc3.py) verificam o bloqueio de objetos arbitrários na leitura dos arquivos legados, a remoção de cópias, o reparo da costura e a detecção de faixas espelhadas; o ajuste de Holm, o alargamento do intervalo pela correção de Nadeau e Bengio e os postos de Friedman; a exatidão da inversa da normalização (Equação 3) e a invariância da faixa à dilatação; a medição de ρ em olhos sintéticos com erro menor que 0,01; a recuperação do sinal geométrico pela fusão; a compatibilidade do AdaBoost com as versões recentes do scikit-learn; e a leitura sem cópias pelo pipeline da IC.

APÊNDICE B – TABELAS COMPLETAS DA GRADE

As Tabelas 10 a 12 trazem a acurácia balanceada e, entre parênteses, a AUC de cada configuração, em média de 50 *folds*; o negrito indica a melhor representação de cada classificador. A Tabela 13 resume as representações, e a Tabela 14 traz a melhor combinação de cada uma, com intervalos de confiança corrigidos. Escolher a melhor entre 15 combinações é uma seleção otimista; esses valores descrevem o teto observado nesta base e não devem ser lidos como estimativas de desempenho.

Tabela 10 – Grade com o conjunto de pixels

Representação	RL	SVM	RF	MLP	AdaBoost
Original (cinza)	0,691 (0,772)	0,655 (0,739)	0,707 (0,776)	0,745 (0,801)	0,697 (0,765)
Equalização global	0,755 (0,843)	0,734 (0,831)	0,743 (0,832)	0,763 (0,841)	0,705 (0,767)
CLAHE	0,691 (0,775)	0,700 (0,795)	0,730 (0,798)	0,736 (0,818)	0,698 (0,772)
Verde + CLAHE	0,708 (0,776)	0,718 (0,806)	0,707 (0,785)	0,721 (0,787)	0,698 (0,764)
Frangi	0,768 (0,812)	0,724 (0,795)	0,799 (0,843)	0,769 (0,819)	**0,772 (0,834)**
Gabor	0,766 (0,832)	0,758 (0,836)	0,769 (0,820)	0,748 (0,817)	0,706 (0,763)
Black-hat	**0,779 (0,859)**	0,763 (0,851)	0,774 (0,852)	**0,798 (0,896)**	0,751 (0,811)
Frangi + *black-hat*	0,751 (0,807)	**0,781 (0,816)**	**0,803 (0,854)**	0,784 (0,847)	0,743 (0,808)

Fonte: elaborada pelo autor.

Tabela 11 – Grade com o conjunto de textura

Representação	RL	SVM	RF	MLP	AdaBoost
Original (cinza)	0,821 (0,891)	**0,847 (0,880)**	**0,859 (0,908)**	0,812 (0,902)	**0,854 (0,903)**
Equalização global	**0,822 (0,893)**	0,840 (0,884)	0,849 (0,883)	**0,871 (0,924)**	0,806 (0,871)
CLAHE	0,790 (0,875)	0,823 (0,877)	0,792 (0,863)	0,826 (0,903)	0,772 (0,851)
Verde + CLAHE	0,756 (0,850)	0,783 (0,861)	0,746 (0,837)	0,806 (0,882)	0,739 (0,809)
Frangi	0,809 (0,861)	0,783 (0,861)	0,779 (0,839)	0,761 (0,825)	0,766 (0,829)
Gabor	0,762 (0,813)	0,800 (0,848)	0,810 (0,858)	0,773 (0,858)	0,772 (0,826)
Black-hat	0,775 (0,851)	0,793 (0,863)	0,771 (0,850)	0,810 (0,884)	0,737 (0,800)
Frangi + *black-hat*	0,763 (0,833)	0,776 (0,828)	0,759 (0,824)	0,748 (0,809)	0,743 (0,798)

Fonte: elaborada pelo autor.

A Figura 16 mostra as curvas ROC médias de cada representação no leiaute principal, para o modelo pré-especificado (RL com o conjunto padrão da IC) e para a melhor combinação de cada representação, e a Figura 17 repete o ranking de Friedman com a AUC.

Tabela 12 – Grade com o conjunto padrão da IC

Representação	RL	SVM	RF	MLP	AdaBoost
Original (cinza)	0,706 (0,799)	0,677 (0,765)	0,759 (0,830)	0,756 (0,835)	**0,837 (0,910)**
Equalização global	0,763 (0,855)	0,741 (0,844)	0,781 (0,869)	0,758 (0,849)	0,806 (0,872)
CLAHE	0,698 (0,787)	0,708 (0,804)	0,727 (0,804)	0,751 (0,832)	0,746 (0,829)
Verde + CLAHE	0,720 (0,786)	0,721 (0,813)	0,713 (0,800)	0,726 (0,799)	0,719 (0,801)
Frangi	0,775 (0,820)	0,726 (0,801)	0,799 (0,852)	0,769 (0,818)	0,769 (0,830)
Gabor	0,767 (0,834)	0,770 (0,838)	0,785 (0,840)	0,752 (0,812)	0,759 (0,807)
Black-hat	**0,786 (0,863)**	0,766 (0,852)	0,776 (0,855)	**0,802 (0,898)**	0,745 (0,811)
Frangi + *black-hat*	0,755 (0,812)	**0,783 (0,818)**	**0,810 (0,845)**	0,763 (0,830)	0,751 (0,806)

Fonte: elaborada pelo autor.

Tabela 13 – Resumo por representação: médias da grade, postos de Friedman, comparações com a original e teste de permutação

Representação	Média da grade		Posto médio		vs. original (Holm)		Permutação
	AB	AUC	AB	AUC	↑ / ↓	ΔAB médio	p
Original (cinza)	0,762	0,832	4,87	4,67	–	–	<0,001
Equalização global	0,782	0,857	3,20	2,20	0 / 0	+0,021	<0,001
CLAHE	0,746	0,826	5,73	4,73	0 / 0	−0,016	<0,001
Verde + CLAHE	0,732	0,810	6,87	6,67	0 / 0	−0,030	<0,001
Frangi	0,771	0,829	3,60	4,47	0 / 0	+0,010	<0,001
Gabor	0,766	0,827	4,00	5,20	0 / 0	+0,005	<0,001
Black-hat	0,775	0,853	3,60	2,80	0 / 0	+0,013	<0,001
Frangi + *black-hat*	0,767	0,822	4,13	5,27	0 / 0	+0,006	<0,001

Fonte: elaborada pelo autor. AB: acurácia balanceada; ↑/↓: combinações significativamente melhores ou piores que a original após o ajuste de Holm sobre as 105 comparações; permutação: RL sobre os pixels.

Tabela 14 – Melhor combinação de cada representação (seleção otimista)

Representação	Combinação	AB [IC 95%]	AUC [IC 95%]	Sensib.	Especif.
Original (cinza)	Textura + RF	0,859 [0,773; 0,946]	0,908 [0,834; 0,981]	0,819	0,899
Equalização global	Textura + MLP	0,871 [0,805; 0,936]	0,924 [0,866; 0,982]	0,837	0,905
CLAHE	Textura + MLP	0,826 [0,750; 0,902]	0,903 [0,845; 0,962]	0,794	0,857
Verde + CLAHE	Textura + MLP	0,806 [0,726; 0,887]	0,882 [0,814; 0,949]	0,778	0,834
Frangi	Textura + RL	0,809 [0,733; 0,884]	0,861 [0,784; 0,937]	0,755	0,862
Gabor	Textura + RF	0,810 [0,725; 0,895]	0,858 [0,774; 0,943]	0,770	0,849
Black-hat	Textura + MLP	0,810 [0,726; 0,894]	0,884 [0,814; 0,955]	0,794	0,826
Frangi + *black-hat*	Padrão da IC + RF	0,810 [0,744; 0,876]	0,845 [0,768; 0,923]	0,714	0,906

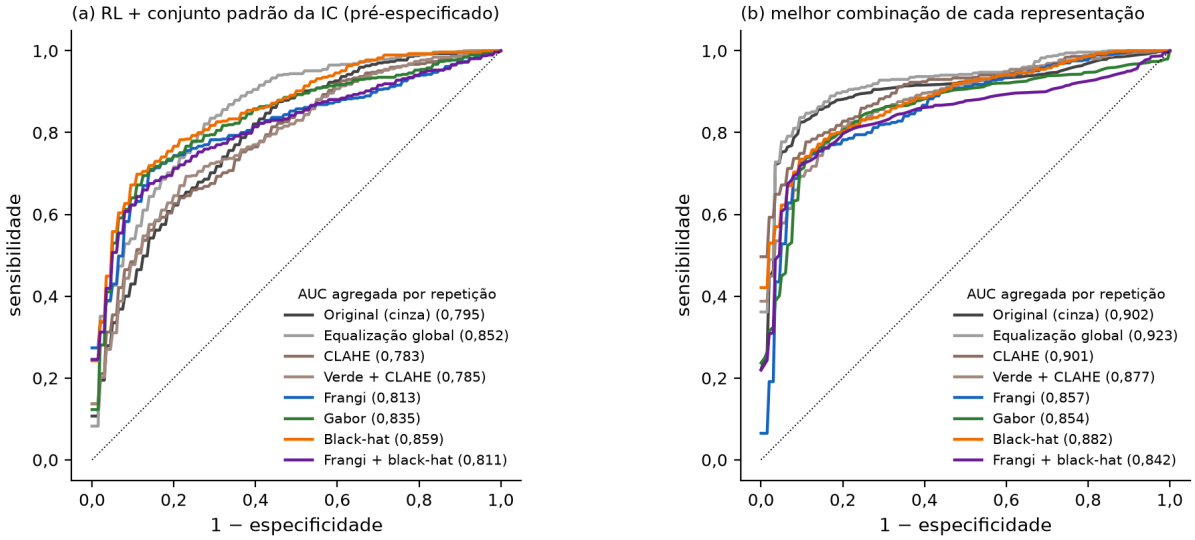
Fonte: elaborada pelo autor.

Tabela 15 – Replicação no leiaute `personBase`: diferença de acurácia balanceada em relação à original e valor p ajustado por Holm

Representação	Pixels	Textura	Padrão da IC
Equalização global	+0,003 (1,000)	−0,002 (0,917)	−0,004 (1,000)
CLAHE	−0,013 (1,000)	−0,023 (0,601)	−0,023 (1,000)
Verde + CLAHE	−0,004 (1,000)	−0,042 (0,090)	−0,022 (1,000)
Frangi	+0,008 (1,000)	−0,039 (0,601)	−0,013 (1,000)
Gabor	+0,026 (1,000)	−0,047 (0,372)	+0,006 (1,000)
Black-hat	−0,007 (1,000)	−0,036 (0,601)	−0,034 (1,000)
Frangi + *black-hat*	−0,006 (1,000)	−0,030 (0,601)	−0,025 (1,000)

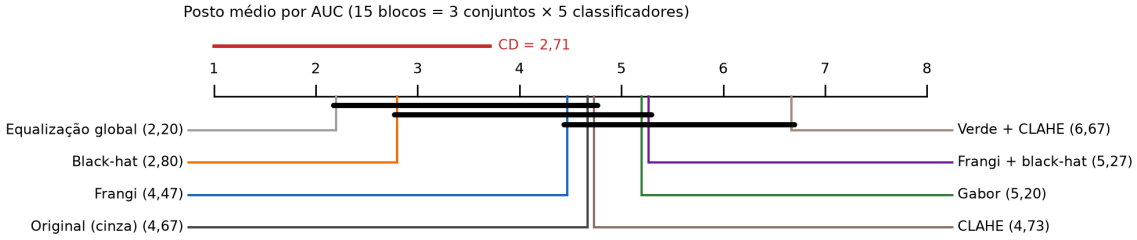
Fonte: elaborada pelo autor.

Figura 16 – Curvas ROC médias por representação (`personBase_invert`)



Fonte: elaborada pelo autor. Escores fora do *fold* agregados por repetição; o painel (b) resulta de uma seleção otimista.

Figura 17 – Postos médios de Friedman pela AUC e diferença crítica de Nemenyi



Fonte: elaborada pelo autor.

APÊNDICE C – PARÂMETROS

Quadro 3 – Parâmetros dos realces, dos descritores e dos experimentos

Componente	Valores
CLAHE	limite de contraste 2,0; grade de 8×8
Frangi	$\sigma \in \{1, 2, 3, 4\}$; $\beta = 0{,}5$; $c = 15$; cristas claras; exibição por percentis 2 e 99 com gama 0,7
Gabor	8 orientações; núcleo 21×21; $\sigma = 4$; $\lambda = 10$; $\gamma = 0{,}5$; média do núcleo removida
Morfologia	*top-hat* e *black-hat* com elementos elípticos de 5, 11 e 21 pixels
Pixels	subamostragem por 4 com suavização (50×180)
LBP	uniforme, 16 vizinhos, raio 2, histograma de 18 posições
GLCM	64 níveis; distâncias 1, 2 e 3; ângulos 0°, 45°, 90° e 135°; contraste, dissimilaridade, homogeneidade, energia, correlação e ASM
Estatísticas de intensidade	média, desvio-padrão, assimetria, curtose e histograma de 32 posições
Classificadores	RL ($C = 1$); SVM RBF ($C = 1$, γ automático); RF (100 árvores); MLP (100 e 50 neurônios, Adam); AdaBoost (50 estimadores); semente 42
Validação cruzada	estratificada por grupos, 5 *folds*, 10 repetições (sementes 2026 a 2035)
Permutação	RL sobre pixels; 5 *folds*; 1000 permutações
Detector de pupila	72 raios; pico a 30% do máximo do raio; RANSAC com tolerância de 2 pixels; refinamento integro-diferencial com $\sigma = 1{,}5$ e primeiro pico a 50%
Detector de limbo	arcos laterais de $-45°$ a 45° e de 135° a 225°; RANSAC com tolerância de 3 pixels
Coorte sintética	imagens de 480×480; raio da íris entre 29% e 35% do lado; excentricidade de até 0,04; ruído com desvio de 1,5 a 4,5

Fonte: elaborado pelo autor.