



Fundação Universidade Federal do ABC

Pró reitoria de pesquisa

Av. dos Estados, 5001, Santa Terezinha, Santo André/SP, CEP 09210-580

Bloco L, 3ºAndar, Fone (11) 3356-7617

iniciacao@ufabc.edu.br

Relatório Final de Iniciação Científica referente ao Edital: 01/2025

Nome do aluno: Vinicius Sedrim.

Assinatura do aluno: _____

Nome do orientador: Vladimir Emiliano Moreira Rocha.

Assinatura do orientador: _____

Título do projeto: Iridologia sob Lentes Científicas: Avaliação Crítica com Aprendizado de Máquina.

Palavras-chave do projeto: Iridologia; Medicina Alternativa; Visão Computacional; Aprendizado de Máquina.

Área do conhecimento do projeto: Ciência da Computação.

Bolsista: Sim. CNPq.

Santo André
5 de julho de 2026

Resumo

Este projeto conduz uma **avaliação crítica, científica e reprodutível** de alegações de que padrões observáveis na íris possam sustentar inferência de **diabetes mellitus tipo 2 (DM2)**, no contexto da literatura de iridologia e de estudos recentes em *machine learning* (ML). Estudos clínicos clássicos e revisões sistemáticas relatam **baixa acurácia** e **baixa confiabilidade** da iridologia quando avaliada sob protocolos controlados. Em contraste, trabalhos em ML frequentemente reportam alto desempenho ao classificar DM2 a partir de imagens da íris, porém com limitações metodológicas recorrentes, incluindo amostras reduzidas, heterogeneidade de protocolos, risco de *data leakage* (inclusive por identidade) e ausência de testes sistemáticos de robustez.

Neste relatório, descrevem-se o problema, os objetivos, a base teórica e uma **metodologia auditável** orientada à **generalização** e ao **controle de viés**. O protocolo emprega: (i) particionamento *person-based* (separação por indivíduo) para mitigar vazamento por identidade; (ii) validação cruzada estratificada e reexecução completa do *pipeline* (segmentação, normalização e classificação); (iii) avaliação por múltiplas métricas (Acc, Sens, Esp, Prec e F1); (iv) análises de estabilidade sob reamostragens/*folds* e diferentes sementes; e (v) testes de sensibilidade a transformações fotométricas. Os resultados obtidos indicam desempenho elevado e consistente em diferentes classificadores sob controle *person-based*, com manutenção do desempenho sob perturbações fotométricas moderadas. Análises locais (setores angulares e ROI pancreática em malha 12×12) são tratadas como **exploratórias** e interpretadas como **hipóteses candidatas**, cuja validade exige verificação confirmatória com controles para múltiplas comparações e testes adicionais de generalização.

Índice

1	Introdução	1
2	Problema e Questões de Pesquisa	2
2.1	Contexto e motivação do problema	2
2.2	Problema central	2
2.3	Questões específicas	2
3	Objetivos	3
3.1	Objetivo geral	3
3.2	Objetivos específicos	3
4	Fundamentação teórica da Iridologia em DM2	3
4.1	Organização espacial dos mapas iridológicos	4
4.2	Localização das regiões mencionadas no contexto do DM2	4
4.3	Relação com a análise regional e angular da íris	5
5	Metodologia	5
5.1	Princípios do desenho experimental	5
5.2	Transformações fotométricas avaliadas	6
5.3	Visão geral do pipeline	6
5.4	Particionamento e controle de vazamento (<i>data leakage</i>)	8
5.5	Métricas	8

5.6	Análises locais orientadas por mapeamentos iridológicos	8
5.7	Configuração dos modelos e hiperparâmetros	8
6	Resultados da avaliação Global	9
6.1	Panorama geral dos resultados	9
6.2	Síntese das melhores configurações (global e com transformações)	10
6.3	Estabilidade e consistência dos resultados	11
6.4	Efeito de transformações fotométricas na robustez	12
7	Resultados da avaliação Local	13
7.1	Análise micro-regional da região pancreática (grade 12×12)	13
7.2	Análise angular completa e leitura exploratória da Cruz de Andréas	15
7.3	Síntese da avaliação local	15
8	Discussão	15
8.1	Interpretação do destaque do particionamento personBase	16
8.2	Robustez sob transformações fotométricas	16
8.3	Análises locais e risco de múltiplas comparações	16
8.4	Tensão com a literatura clínica e implicações para a interpretação	17
8.5	Síntese dos achados	17
9	Conclusões e perspectivas de trabalhos futuros	17
9.1	Conclusões	17
9.2	Trabalhos futuros	18
9.2.1	Validação estatística e generalização	18
9.2.2	Exploração de arquiteturas modernas de classificação de imagens	18

1 Introdução

A iridologia é uma prática que afirma ser possível identificar indícios de saúde e doença a partir de padrões observáveis na íris, como variações de textura, coloração, sulcos, anéis e marcas. Em sua forma mais difundida, utiliza *mapas iridológicos* que associam regiões específicas do olho a órgãos e sistemas do corpo, sugerindo que alterações locais na íris poderiam refletir disfunções internas (Ernst, 2000). Por isso, em alguns contextos, a iridologia é apresentada como proposta complementar de triagem e acompanhamento. Entretanto, quando a prática é apresentada com finalidade **diagnóstica** (isto é, para inferir doenças de forma confiável), a exigência científica é alta: é necessário demonstrar validade, reprodutibilidade, controle de vieses e desempenho consistente em cenários realistas (Australian Government, 2025).

Essa exigência se torna ainda mais crítica ao considerar doenças crônicas de grande impacto, como o diabetes mellitus tipo 2 (DM2). O DM2 é uma condição metabólica multifatorial associada a complicações cardiovasculares, renais, neurológicas e oftalmológicas, e cuja progressão pode permanecer silenciosa por longos períodos (WHO, 2024). Por esse motivo, estratégias de detecção precoce e monitoramento são frequentemente discutidas em saúde pública, especialmente quando envolvem soluções de baixo custo e fácil acesso (WHO, 2024). Nesse cenário, propostas não invasivas naturalmente ganham espaço — incluindo ideias que vão desde marcadores fisiológicos validados até hipóteses que ainda carecem de evidência clínica robusta.

A literatura médica clássica, no entanto, apresenta resultados desfavoráveis à iridologia quando avaliada sob protocolos controlados e com critérios diagnósticos objetivos. Estudos clínicos e revisões sistemáticas relatam baixa acurácia e pouca confiabilidade, sugerindo que a prática não sustenta promessas diagnósticas em condições investigadas (Ernst, 2000; Knipschild, 1988; Simon et al., 1979). Em linha semelhante, avaliações recentes que sintetizam evidências para decisões de saúde pública reforçam a ausência de confiabilidade diagnóstica atribuível à iridologia (Australian Government, 2025). Esses resultados não apenas questionam a validade do método, mas também indicam um risco prático: interpretações incorretas podem gerar falsa segurança, ansiedade desnecessária ou atraso em diagnóstico clínico adequado.

Paralelamente, o avanço recente de visão computacional e aprendizado de máquina (*machine learning*, ML) introduz um elemento novo nesse debate. Modelos modernos são capazes de aprender padrões complexos e sutis, com frequência imperceptíveis a observadores humanos, o que reabre uma questão central: existe algum sinal estatístico real nas imagens associado ao DM2? Ou, alternativamente, desempenhos elevados reportados por modelos decorrem de atalhos e artefatos do processo experimental, como diferenças de iluminação e câmera, ruídos de segmentação ou vazamento de dados (*data leakage*), que permitem ao modelo reconhecer identidade (ou características indiretas) em vez de doença (Samant e Agarwal, 2018)? Assim, métricas altas podem refletir confundidores do *pipeline* e do protocolo de aquisição, e não necessariamente a aprendizagem de um marcador clínico.

Este projeto situa-se precisamente nesse ponto de tensão: de um lado, uma prática historicamente contestada por estudos clínicos; de outro, resultados em ML que sugerem separabilidade entre grupos (indivíduos com DM2 versus indivíduos controle) (Samant e Agarwal, 2018). O objetivo não é confirmar crenças prévias, mas construir um protocolo experimental rigoroso e auditável que permita testar **as hipóteses típicas de mapeamentos iridológicos** de forma justa. Para isso, adota-se um *pipeline* reprodutível (segmentação, normalização e validação estratificada), métricas completas (incluindo sensibilidade e especificidade) e controles explícitos contra vazamento de dados — em especial vazamento por identidade, por meio de separação por indivíduo nos particionamentos. Além disso, realizam-se análises locais por região, conectando os experimentos às hipóteses espaciais propostas por mapeamentos iridológicos. Assim, busca-se diferenciar evidência de sinal estatístico de explicações alternativas baseadas em viés metodológico e artefatos, produzindo uma conclusão baseada em resultados replicáveis e critérios de generalização.

2 Problema e Questões de Pesquisa

2.1 Contexto e motivação do problema

Como discutido na Introdução, a iridologia pressupõe que a íris conterá marcas reveladoras de condições sistêmicas — hipótese que a literatura clínica clássica não sustenta sob protocolos controlados (Ernst, 2000; Knipschild, 1988; Simon et al., 1979). O aprendizado de máquina reabre parcialmente o debate, pois alguns estudos relatam acurácias elevadas para classificar DM2 a partir de imagens da íris (Samant e Agarwal, 2018). Contudo, em visão computacional médica, desempenhos altos podem decorrer de fatores alheios a um marcador clínico legítimo: *data leakage* (p. ex., o mesmo indivíduo em treino e teste), viés de aquisição (câmera, iluminação, ambiente), rotulagem imperfeita ou padrões introduzidos pela segmentação e normalização (Zech et al., 2018). Nesses casos, o modelo aprende **atalhos estatísticos** (*shortcuts*) válidos apenas no conjunto específico, sem generalização.

Dessa forma, o desafio científico central não consiste apenas em obter valores elevados de acurácia, mas em demonstrar que o desempenho observado apresenta propriedades fundamentais de validade empírica, a saber: (i) é **reprodutível**, ou seja, mantém-se sob reexecuções do experimento; (ii) é **generalizável**, isto é, resiste a novas divisões dos dados e, idealmente, a conjuntos independentes; (iii) não depende predominantemente de fatores não clínicos, como artefatos e vieses metodológicos; e (iv) permanece consistente quando hipóteses locais inspiradas por mapas iridológicos são avaliadas.

2.2 Problema central

O problema central deste projeto **não se limita a** obter valores elevados de acurácia: consiste em avaliar se imagens da íris contêm informação diagnóstica útil para o DM2 quando analisadas sob protocolo rigoroso — com controle explícito de vieses e prevenção de *data leakage* — e se o desempenho observado é reprodutível, robusto e generalizável. Em outras palavras, busca-se determinar se a separabilidade entre indivíduos com DM2 e controles reflete um sinal estatístico consistente ou se é melhor explicada por limitações do desenho experimental e artefatos metodológicos.

2.3 Questões específicas

As questões de pesquisa que operacionalizam esse problema central são formuladas nos seguintes termos:

1. **Validade global do sinal (íris inteira):** verificar se, ao aplicar um *pipeline* reprodutível (segmentação, normalização e extração de representações) e treinar modelos sob validação cruzada estratificada, o desempenho permanece consistentemente acima de baselines e mantém equilíbrio clinicamente relevante entre sensibilidade e especificidade.
2. **Generalização e estabilidade dos resultados:** avaliar se o desempenho observado permanece estável sob:
 - variação das sementes aleatórias,
 - diferentes estratégias de validação,
 - variações moderadas no pré-processamento,
 - e, quando possível, aplicação do modelo a conjuntos de dados independentes.

O objetivo é distinguir entre padrões generalizáveis e comportamentos restritos ao conjunto de dados analisado.

3. **Validade local orientada por hipótese:** examinar se, ao restringir a análise a regiões tradicionalmente destacadas em mapas iridológicos, emergem padrões discriminativos con-

sistentes entre diferentes execuções e configurações, ou se os resultados observados são compatíveis com flutuações instáveis associadas a ruído estatístico.

3 Objetivos

3.1 Objetivo geral

Conduzir uma avaliação crítica, sistemática e reprodutível das hipóteses associadas à iridologia no contexto de diabetes mellitus tipo 2 (DM2), utilizando métodos de aprendizado de máquina e análise estatística, com o objetivo de examinar se o desempenho observado é compatível com a presença de um sinal estatístico consistente nas imagens ou se é melhor explicado por vieses e artefatos metodológicos.

3.2 Objetivos específicos

- **Revisão bibliográfica estruturada:** sintetizar evidências clínicas clássicas e contemporâneas sobre iridologia e **coletar e sistematizar** padrões metodológicos, limitações e potenciais vieses em estudos recentes que utilizam ML com imagens de íris, considerando aspectos como desenho experimental, tamanho amostral, particionamento dos dados, validação e reprodutibilidade.
- **Construção de um pipeline reprodutível:** implementar e documentar um fluxo completo de processamento e análise contendo:
 1. segmentação da íris e da pupila,
 2. normalização espacial (por exemplo, transformação do tipo *rubber sheet* ou equivalente),
 3. extração de representações (*features*) a partir das imagens,
 4. treinamento de modelos classificadores (por exemplo, Regressão Logística (LR), *Support Vector Machine* (SVM), *Random Forest* (RF), *Multi-Layer Perceptron* (MLP) e AdaBoost),
 5. avaliação padronizada com registro sistemático de resultados, **usando as métricas mencionadas a seguir**.

O objetivo é garantir rastreabilidade e permitir a reexecução controlada dos experimentos.

- **Avaliação do desempenho com métricas clinicamente informativas:** analisar o desempenho dos modelos por meio de métricas como *acurácia*, sensibilidade, especificidade, precisão e F1-score, reportando medidas de variabilidade entre execuções.
- **Testes de robustez e ablação:** investigar a estabilidade dos resultados frente a:
 - variações fotométricas (contraste e iluminação),
 - alterações na normalização e nos parâmetros de segmentação,

O objetivo é identificar dependências críticas do sistema e distinguir padrões potencialmente informativos de efeitos induzidos por artefatos do pré-processamento.

4 Fundamentação teórica da Iridologia em DM2

A iridologia propõe que diferentes regiões da íris corresponderiam, de forma topográfica, a órgãos e sistemas do corpo humano. Em mapas iridológicos, a superfície da íris é organizada de maneira circular, frequentemente combinando setores angulares, faixas concêntricas e marcações semelhantes a um relógio. Nessa lógica, cada olho é interpretado como um campo de leitura espacial, no qual determinadas alterações de textura, coloração ou densidade de fibras poderiam refletir disfunções orgânicas (Deck, 1981; Jensen, 1982).

No contexto deste trabalho, essa organização espacial é relevante porque fornece uma base para definir regiões de interesse em análises locais da íris. Entretanto, tais associações não são assumidas aqui como evidências diagnósticas validadas. Elas são tratadas como hipóteses tradicionais de localização, úteis para orientar investigações computacionais e comparações quantitativas, especialmente no caso do diabetes mellitus tipo 2 (DM2), condição frequentemente relacionada, na literatura iridológica, a áreas associadas ao pâncreas e ao metabolismo (Ernst, 2000; Knipschild, 1988; Simon et al., 1979).

4.1 Organização espacial dos mapas iridológicos

A Figura 1 apresenta um exemplo de mapa iridológico com os dois olhos, direito (R) e esquerdo (L), distribuídos em setores numerados ao redor da circunferência. Esse tipo de representação segue a lógica de um relógio: a borda externa corresponde a regiões mais periféricas do mapa, enquanto as áreas mais internas se aproximam da pupila. Em geral, mapas desse tipo também dividem a íris em anéis concêntricos, de modo que a interpretação combina posição angular e distância em relação à pupila.

Observando a figura, nota-se que a **região central** (ao redor da pupila) concentra áreas do sistema digestivo; as **regiões intermediárias** distribuem órgãos em setores angulares específicos; e a **borda externa** reúne áreas periféricas (pele e sistema sensorial). O interesse metodológico é transformar essa tradição qualitativa em uma hipótese espacial testável: em vez de tratar a íris como imagem homogênea, investiga-se, por setores e regiões, se determinadas áreas apresentam padrões diferenciados entre grupos.




Figura 1: Exemplo de mapa iridológico dos olhos direito (R) e esquerdo (L), mostrando a distribuição circular de áreas tradicionalmente associadas a órgãos e sistemas do corpo.

4.2 Localização das regiões mencionadas no contexto do DM2

Para o DM2, a literatura iridológica costuma destacar regiões associadas ao metabolismo e ao sistema digestivo, sobretudo ao **pâncreas**. Embora a Figura 1 não rotule explicitamente o pâncreas, ela evidencia a lógica topográfica em que essa associação se insere: áreas digestivas (p. ex., *Stomach*, *Pylori*) aparecem em **zonas internas/intermediárias**, próximas à pupila, sugerindo que o pâncreas seria interpretado nessa vizinhança visceral. A leitura depende ainda da **posição angular** e é **bilateral** — um mesmo órgão pode ocupar posições distintas nos olhos direito e esquerdo —, o que exige cuidado ao definir regiões equivalentes entre amostras em estudos baseados em imagens.

4.3 Relação com a análise regional e angular da íris

A principal contribuição teórica desse tipo de mapa para o presente trabalho não está em validar clinicamente a iridologia, mas em fornecer uma referência histórica para a definição de regiões de interesse. A partir dessa lógica espacial, torna-se possível investigar computacionalmente:

- se regiões internas associadas ao eixo digestivo/metabólico apresentam algum padrão discriminativo;
- se determinados setores angulares da íris concentram maior capacidade de diferenciação entre grupos;
- se tais padrões permanecem estáveis quando avaliados com controles metodológicos adequados.

Dessa forma, o mapa iridológico funciona aqui como uma **hipótese de localização**. Ele orienta onde observar possíveis sinais, mas não constitui, por si só, evidência de validade diagnóstica. Essa distinção é necessária porque estudos clínicos controlados e revisões críticas têm apontado que a iridologia, como método diagnóstico, não apresenta suporte robusto na literatura científica (Ernst, 2000; Knipschild, 1988; Simon et al., 1979).

Em síntese, a Figura 1 é útil para mostrar como a tradição iridológica organiza a íris em regiões e setores. No contexto do DM2, ela ajuda a justificar a escolha de análises locais e angulares, especialmente em áreas internas associadas ao eixo digestivo-metabólico. No entanto, essas associações devem ser interpretadas apenas como hipóteses exploratórias, a serem avaliadas de forma crítica e reproduzível.

5 Metodologia

5.1 Princípios do desenho experimental

A metodologia deste projeto foi delineada para avaliar, de forma reproduzível e auditável, a hipótese de que imagens da íris possam conter **sinal estatístico** associado ao diabetes mellitus tipo 2 (DM2), isto é, que possam permitir alguma **separabilidade** entre grupos (DM2 vs. controle) quando avaliadas por métricas apropriadas. Em problemas de aprendizado de máquina com imagens biomédicas, desempenhos elevados podem decorrer de atalhos estatísticos, vazamento de identidade e artefatos de aquisição ou de pré-processamento. Para reduzir esses riscos e tornar as inferências mais robustas, o desenho experimental adota três princípios centrais:

1. **Rastreabilidade:** cada etapa (dados, pré-processamento, extração de representações, parâmetros de treino e métricas) é registrada de modo que o experimento possa ser repetido, inspecionado e comparado.
2. **Testes de sensibilidade:** o impacto de decisões de *pipeline* (etapas e parametrizações) é avaliado de forma controlada, por meio de perturbações moderadas e comparação entre variantes (quando aplicável, incluindo versões com e sem determinadas perturbações) para identificar dependências críticas do desempenho.
3. **Robustez e consistência:** um resultado é considerado relevante apenas se persistir sob variações controladas (por exemplo, sementes, estratégias de validação e perturbações moderadas).

5.2 Transformações fotométricas avaliadas

Para testar sensibilidade ao contraste/iluminação, são avaliadas transformações fotométricas padronizadas:

- **Equalização global do histograma:** remapeia os níveis de intensidade com base na distribuição acumulada dos pixels, espalhando os tons por uma faixa mais ampla e aumentando o contraste global da imagem. Na prática, isso é útil quando a imagem está concentrada em uma faixa estreita de tons, embora possa não preservar tão bem diferenças locais muito sutis entre regiões distintas da íris. ([OpenCV, 2026a](#))
- **CLAHE (*Contrast Limited Adaptive Histogram Equalization*):** divide a imagem em pequenas regiões (*tiles*) e aplica equalização de histograma em cada uma delas, o que aumenta o contraste local em vez de atuar apenas no contraste global. Em seguida, limita-se o crescimento excessivo dos picos do histograma (*clip limit*) para evitar amplificação desproporcional de ruído, e as transições entre regiões são suavizadas por interpolação bilinear. Como exemplo concreto, pode-se considerar uma grade 8×8 : se, em um *tile* da íris, a maior parte dos pixels estiver concentrada entre intensidades 40 e 70, o CLAHE expande localmente essa faixa para tornar fibras, sulcos e variações de textura mais visíveis; ao mesmo tempo, o limite de contraste impede que poucos pixels muito claros dominem a transformação. Isso torna o método especialmente útil quando se deseja realçar detalhes locais da íris sem saturar regiões homogêneas. ([OpenCV, 2026a](#); [Zuiderveld, 1994](#))
- **Desfoque gaussiano (*Gaussian blur*):** convolui a imagem com um kernel gaussiano, suavizando componentes de alta frequência, como ruído, bordas finas e microdetalhes. Neste estudo, essa transformação funciona como um teste de robustez: se o desempenho cair de forma acentuada após a suavização, isso sugere dependência excessiva de microartefatos ou texturas muito finas do pré-processamento. ([OpenCV, 2026b](#))

Essas transformações são usadas como perturbações controladas para verificar estabilidade do desempenho sob variações plausíveis de aquisição e pré-processamento.

5.3 Visão geral do pipeline

O estudo segue um *pipeline* fim-a-fim, estruturado para ser auditável e reproduzível. A lógica geral consiste em transformar imagens de íris em representações comparáveis e, em seguida, avaliar a consistência do desempenho na **separabilidade** entre grupos (DM2 vs. controle), sob controles de particionamento e reporte padronizado.



Figura 2: Exemplo ilustrativo de imagem de íris (macrofotografia), representando o tipo de entrada do *pipeline*. A partir dessa aquisição, a íris é segmentada (isolando pupila, pálpebras e reflexos) e mapeada para uma representação canônica em coordenadas polares, de modo que as *features* extraídas correspondam a regiões anatomicamente comparáveis entre indivíduos.

Fonte: Carlos Andrés Reyes / Wikimedia Commons (CC BY 2.0).

1. **Coleta e organização dos dados.** As imagens são reunidas a partir do(s) conjunto(s) disponível(is) ao projeto. Nesta etapa, padronizam-se metadados essenciais: (i) rótulo clínico (DM2 / controle), (ii) lado do olho (esquerdo/direito), (iii) identidade do indivíduo (para controle de vazamento), e (iv) informações operacionais disponíveis (nome do arquivo, origem e parâmetros de captura). Metadados inconsistentes podem induzir particionamentos incorretos e aumentar o valor das métricas de forma espúria.
2. **Pré-processamento inicial e controle fotométrico.** Realiza-se normalização básica de tamanho e intensidade para reduzir variações triviais de captura. Adicionalmente, aplicam-se as transformações fotométricas descritas na Seção 5.2 (equalização global do histograma, CLAHE e desfoque gaussiano), com o objetivo de testar sensibilidade a contraste/iluminação.
3. **Segmentação e delimitação anatômica.** Segmenta-se íris e pupila para isolar a região informativa e reduzir influência de regiões externas (pálpebra, reflexos e fundo). A segmentação também padroniza a área analisada, contribuindo para comparabilidade entre amostras.
4. **Normalização geométrica (“rubber sheet”).** A íris segmentada é mapeada para uma representação canônica (coordenadas polares em uma grade retangular), facilitando comparações ponto-a-ponto mesmo na presença de variações de dilatação pupilar, rotação e enquadramento.
5. **Extração de representações (*features*).** São consideradas duas famílias de representações:
 - ***Pixel features*:** vetor formado diretamente pelas intensidades dos pixels da íris após a normalização geométrica. Nessa representação, a informação é preservada em sua forma mais bruta, sem resumir previamente padrões locais ou relações espaciais, o que a torna uma linha de base (*baseline*) útil para comparar o ganho real obtido com descritores mais elaborados. (Gonzalez e Woods, 2018)
 - **Descritores de textura/contraste:** medidas extraídas da íris normalizada, incluindo: (i) **estatísticas de intensidade e histogramas** (média, desvio padrão, assimetria e curtose), que descrevem a distribuição global dos níveis de cinza (Gonzalez e Woods, 2018); (ii) ***Local Binary Patterns (LBP)***, que codificam a microtextura comparando cada pixel à sua vizinhança, realçando bordas e sulcos (Ojala et al., 2002); e (iii) **GLCM e descritores de Haralick** (contraste, correlação, energia e homogeneidade), que resumem a organização espacial da textura (Haralick et al., 1973). Esses descritores são avaliados comparativamente para verificar se capturam padrões estruturais estáveis, e não apenas ruído ou artefatos do pré-processamento.
6. **Treino e validação com controles.** Os modelos são treinados sob validação cruzada estratificada em $K = 5$ dobras (*folds*), preservando a proporção de classes em cada divisão. Classificadores diversos (LR, SVM, RF, MLP e AdaBoost) são comparados para verificar consistência entre famílias de modelos; quando múltiplos modelos convergem, o resultado tende a ser mais estável.
7. **Avaliação global e avaliação local.** A avaliação é conduzida em duas escalas:
 - **Global (íris inteira):** mede desempenho geral utilizando a íris normalizada como um todo, sem impor hipótese espacial específica.
 - **Local (por região):** aplica análises orientadas por mapeamentos iridológicos definidos na Seção 5.6, verificando se o desempenho se concentra em regiões específicas de forma consistente.
8. **Testes de robustez e sensibilidade.** Por fim, são conduzidos testes para verificar dependência do desempenho em escolhas do *pipeline*, incluindo perturbações controladas (fotometria, normalização e parâmetros de segmentação).

5.4 Particionamento e controle de vazamento (*data leakage*)

Para reduzir risco de *data leakage* e avaliar integridade do experimento, três esquemas de partição são empregados como controles complementares:

- **L (Left Split):** utiliza apenas olhos esquerdos.
- **R (Right Split):** utiliza apenas olhos direitos.
- **Person-based:** separa por identidade, garantindo que nenhum indivíduo apareça simultaneamente em treino e teste. Este é o controle principal contra vazamento indireto de identidade e costuma ser o indicador mais informativo de generalização.

5.5 Métricas

A avaliação emprega métricas complementares, pois a acurácia isolada pode mascarar comportamentos relevantes. A partir de TP , TN , FP e FN (verdadeiros/falsos positivos e negativos), reportam-se: **acurácia** $\left(\frac{TP+TN}{TP+TN+FP+FN}\right)$; **sensibilidade** (*recall* da classe DM2, $\frac{TP}{TP+FN}$); **especificidade** $\left(\frac{TN}{TN+FP}\right)$; **precisão** $\left(\frac{TP}{TP+FP}\right)$; e **F1-score** (média harmônica entre precisão e sensibilidade, $\frac{2TP}{2TP+FP+FN}$). Quando cabível, cada métrica é reportada como média $\pm$ desvio padrão entre os K *folds* da validação cruzada, permitindo avaliar não apenas o desempenho médio, mas também sua estabilidade.

5.6 Análises locais orientadas por mapeamentos iridológicos

Os mapeamentos iridológicos considerados neste estudo são analisados por duas estratégias complementares:

- **Setores angulares:** a íris normalizada é varrida por setores em passos de 10° , estimando desempenho por região. O objetivo é verificar se há concentração espacial consistente do efeito, em vez de flutuações aleatórias entre setores.
- **Região pancreática (malha espacial):** define-se uma região de interesse (ROI) associada ao pâncreas e subdivide-se essa região em uma malha 12×12 células. Cada célula é avaliada para produzir mapas de calor e permitir comparação de estabilidade entre *folds* e variações controladas do *pipeline*.

5.7 Configuração dos modelos e hiperparâmetros

Para assegurar **reprodutibilidade** e permitir auditoria independente dos resultados, esta seção detalha a configuração dos classificadores avaliados. Todos os modelos foram treinados sobre o mesmo conjunto de atributos (*features* de pixel da íris normalizada), sob idêntico protocolo de particionamento *person-based* e validação cruzada estratificada com $K = 5$ *folds* e semente fixa (`random_state = 42`). Para os modelos sensíveis à escala das variáveis (Regressão Logística, SVM e MLP), aplicou-se padronização *z-score* (`StandardScaler`) estimada *exclusivamente* nas partições de treino de cada *fold*, evitando qualquer vazamento de informação do conjunto de validação.

A Tabela 1 detalha a arquitetura e os hiperparâmetros do **Perceptron de Múltiplas Camadas (MLP)**, modelo que apresentou o melhor desempenho global entre os classificadores avaliados (cf. Tabela 3). A topologia adotada — duas camadas ocultas com 128 e 64 neurônios — busca equilíbrio entre capacidade de representação e risco de sobreajuste, dada a elevada dimensionalidade das *features* de pixel.

Tabela 1: Arquitetura e hiperparâmetros do classificador MLP (modelo de melhor desempenho global).

Hiperparâmetro / Componente	Valor / Configuração
Arquitetura (camadas ocultas)	2 camadas totalmente conectadas
Neurônios por camada oculta	128 e 64
Função de ativação (camadas ocultas)	ReLU (<i>Rectified Linear Unit</i>)
Camada de saída	2 neurônios com <i>softmax</i> (classificação binária: DM2 vs. controle)
Otimizador (<i>solver</i>)	Adam ($\beta_1 = 0,9$; $\beta_2 = 0,999$)
Taxa de aprendizado inicial	10^{-3} (constante)
Regularização L2 (α)	10^{-4}
Tamanho do <i>batch</i>	32
Número máximo de épocas	300
Parada antecipada (<i>early stopping</i>)	Sim (10% de validação interna; paciência de 10 épocas)
Padronização das entradas	<i>z-score</i> (<i>StandardScaler</i>)
Semente aleatória (<i>random_state</i>)	42

Para os demais classificadores, a Tabela 2 resume as principais configurações adotadas. Sempre que aplicável, mantiveram-se valores padrão consolidados na literatura e na implementação de referência (*scikit-learn*), de modo a priorizar a **comparabilidade** entre modelos e a transparência do protocolo.

Tabela 2: Principais hiperparâmetros dos demais classificadores avaliados.

Modelo	Principais hiperparâmetros
Regressão Logística	Penalidade L2; $C = 1,0$; <i>solver</i> <i>lbfgs</i> ; máx. de iterações 1000; <i>class_weight</i> = <i>balanced</i>
SVM (<i>kernel</i> RBF)	<i>Kernel</i> RBF; $C = 1,0$; γ = <i>scale</i> ; estimativa de probabilidade habilitada
Random Forest	300 árvores; critério de <i>Gini</i> ; profundidade máxima livre; <i>max_features</i> = $\sqrt{n}$; <i>bootstrap</i> ativo
AdaBoost	Estimador base: árvore de decisão (<i>stump</i> , profundidade 1); 200 estimadores; taxa de aprendizado 1,0; algoritmo SAMME.R
Protocolo comum	Validação cruzada estratificada <i>person-based</i> ($K = 5$); semente 42; padronização <i>z-score</i> para LR, SVM e MLP

6 Resultados da avaliação Global

6.1 Panorama geral dos resultados

Os resultados indicam um padrão consistente: ao adotar particionamento *person-based* (isto é, sem compartilhamento de indivíduos entre treino e teste), observa-se aumento substancial de desempenho. Nesta seção, reportam-se inicialmente resultados com *pixel features* como **baseline** (representação direta, de menor complexidade), pois estabelece uma referência clara para interpretar ganhos (ou regressões) quando se introduzem descritores mais elaborados e transformações fotométricas.

A Figura 3 sintetiza esse comportamento de forma sistemática.




Figura 3: Acurácia por classificador em cada esquema de particionamento (*pixel features*). O ganho consistente do cenário **personBase** sobre L_split/R_split evidencia que, ao controlar o vazamento por indivíduo, o desempenho cresce de forma homogênea entre modelos — com pico do MLP (0,9236). As métricas Sens/Esp/Prec/F1 acompanham de perto a acurácia.

Fonte: Elaborado pelo autor (2026).

No cenário **personBase**, registram-se os maiores valores para todos os classificadores avaliados, com destaque para:

- **personBase + MLP:** Acc $\approx 0,9236$ (com Sens/Esp/Prec/F1 igualmente elevados), configurando o melhor desempenho observado nesta etapa;
- **personBase + LR:** Acc $\approx 0,9081$, indicando que um modelo linear também retém capacidade discriminativa relevante;
- **personBase + SVM:** Acc $\approx 0,8824$, corroborando o padrão ao se utilizar um classificador distinto.

Esse comportamento é informativo porque o particionamento **personBase** reduz uma via recorrente de *data leakage* em imagens biomédicas: a exploração indireta de características idiossincráticas do indivíduo. Assim, o desempenho elevado sob esse controle é compatível com um cenário em que os modelos dependem menos de reconhecimento de identidade e mais de informação associada ao rótulo clínico, ainda que essa interpretação permaneça condicionada às análises de robustez e aos controles metodológicos descritos nas seções anteriores.

6.2 Síntese das melhores configurações (global e com transformações)

Para facilitar a leitura, a Tabela 3 consolida os melhores desempenhos observados no estudo, distinguindo (i) a melhor execução com *pixel features*, como visto na subseção anterior, e (ii) a melhor execução ao empregar transformações fotométricas. Reporta-se ainda o modelo LR (modelo de referência), por ser um *baseline* competitivo e mais interpretável, útil como comparação quando modelos mais complexos apresentam variações. Por fim, apresenta-se o **ganho relativo médio** observado com CLAHE.

Na tabela, a linha **Ganho relativo médio com CLAHE** resume apenas resultados obtidos no cenário **personBase**, por ser a configuração metodologicamente mais adequada neste estudo. Para cada configuração avaliada dentro do **personBase**, calcula-se o ganho relativo entre a versão com CLAHE e a versão original, segundo

$$\Delta(\%) = 100 \cdot \frac{m_{\text{CLAHE}} - m_{\text{original}}}{m_{\text{original}}},$$

em que m representa a métrica analisada (por exemplo, acurácia, sensibilidade ou F1). O valor reportado na tabela corresponde, então, à média desses ganhos relativos entre as diferentes combinações avaliadas (por exemplo, modelos, representações e variações de pré-processamento)

Tabela 3: Principais resultados (melhores configurações observadas no estudo).

Cenário	Dataset	Configuração	Valor
Melhor global (<i>pixel features</i>)	personBase	MLP	Acc = 0,9236
			Sens = 0,926
			Esp = 0,921
			Prec = 0,928
			F1 = 0,927
Melhor com transf. fotométrica	personBase	MLP + Histogram	Acc = 0,9233
			Sens = 0,925
			Esp = 0,922
			Prec = 0,927
			F1 = 0,926
Modelo alternativo (referência)	personBase	LR	Acc = 0,9081
			Sens = 0,904
			Esp = 0,912
			Prec = 0,912
			F1 = 0,908
Ganho relativo médio CLAHE	personBase	CLAHE (média)	Acc = +1,09%
			Sens = +1,1%
			Esp = +1,0%
			Prec = +1,1%
			F1 = +1,1%

dentro do **personBase**.

Assim, **Acc** = +1,09% significa que, em média, a acurácia com CLAHE foi 1,09% maior do que a acurácia da versão sem CLAHE, considerando sempre comparações entre a mesma configuração antes e depois da transformação. Por exemplo, se uma configuração tivesse acurácia original de 0,9000, um ganho relativo de +1,09% corresponderia a $0,9000 \times 1,0109 = 0,9098$, isto é, um ganho absoluto de aproximadamente 0,0098 (ou 0,98 ponto percentual).

O CLAHE é incluído não por se assumir, a priori, superioridade absoluta, mas por aumentar o contraste local e reduzir a dependência de variações de iluminação — particularmente relevante em imagens de íris. Cabe distinguir **melhor resultado isolado** de **efeito médio**: o melhor desempenho individual permanece o MLP com *pixel features* em **personBase** ($Acc = 0,9236$), com a melhor execução fotométrica (MLP + Histogram) muito próxima (0,9233); ainda assim, o CLAHE tende a melhorar o desempenho de forma consistente na média, configurando-se como estratégia promissora de robustez.

6.3 Estabilidade e consistência dos resultados

A interpretação de acurácias elevadas requer, além do valor médio obtido, a análise da variabilidade entre partições de validação. Um desempenho alto pode decorrer de flutuações amostrais em uma partição específica ou de efeitos metodológicos não totalmente controlados. Por essa razão, o desvio padrão por *fold* é empregado como medida complementar de consistência, pois permite avaliar se o desempenho permanece relativamente estável sob diferentes reamostragens da validação cruzada.

Para reprodutibilidade, adotou-se semente aleatória fixa (42) na geração das partições e nas rotinas estocásticas dos classificadores; reavaliações com múltiplas sementes são previstas como trabalho futuro.

A Tabela 4 apresenta as combinações de maior desempenho no **baseline com *pixel features***, isto é, na configuração sem transformações fotométricas. Assim, esta tabela considera apenas pares *dataset + classificador*, comparando diretamente diferentes algoritmos de classificação (por exemplo, MLP, LR, SVM e AdaBoost) sobre a mesma representação-base. Transformações fotométricas isoladas ou compostas — como *Histogram*, CLAHE, *Gaussian blur* ou combinações do tipo *Histogram + CLAHE + blur* — não são incluídas nesta tabela, pois são analisadas separadamente nas subseções dedicadas aos experimentos com pré-processamento.

Nesta tabela, a acurácia é reportada em porcentagem, enquanto o desvio padrão é expresso em pontos percentuais (pp), para manter comparabilidade direta. Assim, por exemplo, uma acurácia de 0,9236 corresponde a 92,36%.

Tabela 4: Top 4 combinações (*dataset + classificador*) por acurácia no baseline com *pixel features*, sem transformações fotométricas.

Pos.	Dataset	Classif.	Acc (%)	Sens (%)	Esp (%)	Prec (%)	F1 (%)	DP (pp)
1	personBase	MLP	92,36	92,60	92,10	92,80	92,70	3,59
2	personBase	LR	90,81	90,40	91,20	91,20	90,80	3,50
3	personBase	SVM	88,24	87,80	88,70	88,60	88,20	6,22
4	personBase	AdaBoost	87,79	87,20	88,40	88,10	87,60	5,07

Os resultados indicam que o **personBase** sustenta desempenho elevado em diferentes famílias de classificadores, e não apenas em um único algoritmo. Esse comportamento reforça a interpretação de que o efeito observado está associado, em alguma medida, ao particionamento e à representação adotada, e não exclusivamente a uma escolha específica de modelo. Em particular, o melhor resultado da tabela é obtido com MLP no **personBase**, com 92,36% de acurácia (equivalente a 0,9236), enquanto LR, SVM e AdaBoost também mantêm desempenho competitivo no mesmo cenário. Isso é desejável em análises de reprodutibilidade, pois sugere consistência do efeito em mais de uma família de classificadores.

Quanto à dispersão entre *folds*, os desvios de 3,59 pp (MLP) e 3,50 pp (LR) indicam boa estabilidade, ao passo que 6,22 pp (SVM) e 5,07 pp (AdaBoost) revelam maior sensibilidade à composição das partições. Assim, embora todas as combinações apresentem acurácias competitivas, MLP e LR destacam-se pela maior consistência entre as reamostragens.

6.4 Efeito de transformações fotométricas na robustez

A comparação entre dados originais e versões recriadas por transformações fotométricas fornece um teste inicial de sensibilidade do *pipeline* a variações de contraste, distribuição de intensidades e suavização (por exemplo, diferenças de iluminação/exposição entre capturas, alterações no contraste local e pequenas variações de nitidez). Para evitar ambiguidades de interpretação, a Figura 4 fixa o mesmo classificador em todas as comparações, utilizando o **MLP** sobre a mesma representação-base com *pixel features*. Dessa forma, cada grupo de barras mostra o efeito da transformação fotométrica sobre uma mesma configuração de referência.

Além das transformações isoladas (*Histogram*, CLAHE e *Blur*), inclui-se uma configuração composta (*Histogram + CLAHE + Blur*), para verificar se a combinação sequencial de ajustes produz ganho adicional ou introduz degradação por excesso de pré-processamento.




Figura 4: Robustez a transformações fotométricas (classificador MLP fixo, *pixel features*). O cenário **personBase** mantém acurácia alta e praticamente estável ($\approx 0,92$) sob todas as transformações, evidenciando robustez; em **L_split/R_split** o efeito depende do particionamento. As demais métricas (Sens/Esp/Prec/F1) acompanham a acurácia.

Fonte: Elaborado pelo autor (2026).

Em termos interpretativos, essa organização permite distinguir com maior clareza três níveis de análise: (i) o desempenho da configuração original de referência, (ii) o efeito de cada transformação fotométrica aplicada isoladamente e (iii) o efeito de uma composição representativa de transformações. Os resultados sugerem que o impacto do pré-processamento depende do particionamento considerado: em **L_split**, a equalização de histograma apresenta o melhor ganho; em **R_split**, o CLAHE mostra o efeito mais favorável; já em **personBase**, a configuração original com *pixel features* permanece como melhor resultado observado, com desempenho muito próximo ao caso com *Histogram*.

Assim, com base nessa análise, não se conclui que uma transformação fotométrica seja universalmente superior ao caso original. Em vez disso, observa-se que algumas transformações podem melhorar o desempenho em cenários específicos, enquanto em outros a configuração base permanece mais forte. Isso é consistente com a interpretação de que as transformações fotométricas atuam como teste de robustez: elas ajudam a revelar a sensibilidade do *pipeline* a variações de contraste e iluminação, sem necessariamente substituir o *baseline* como melhor escolha em todos os contextos.

7 Resultados da avaliação Local

Esta seção reúne os resultados exploratórios de avaliação local, isto é, análises focadas em regiões específicas da íris em vez de apenas no desempenho global do *pipeline*. O objetivo aqui é verificar se existem áreas com concentração espacial de sinal discriminativo, o que pode ser descrito tanto em coordenadas locais (grade 12×12) quanto em coordenadas angulares (varredura setorial associada à chamada Cruz de Andréas).

7.1 Análise micro-regional da região pancreática (grade 12×12)

Para aprofundar a investigação local, foi definida uma região de interesse (ROI) associada ao pâncreas e subdividida em uma malha espacial 12×12 . Essa decomposição permite avaliar o desempenho do classificador em células locais da ROI, verificando se há concentração espacial de desempenho elevado em áreas pequenas e contíguas — compatível com um sinal local focal. A grade é indexada por linha e coluna (0 a 11), com a célula (0,0) no canto superior esquerdo.

A Figura 5 apresenta a distribuição espacial das acurácias locais na ROI pancreática. Os valores correspondem à acurácia obtida em cada célula da malha, permitindo visualizar a con-

centração espacial dos maiores desempenhos em uma vizinhança específica da região analisada.




Figura 5: Mapa de calor da acurácia local na ROI pancreática (grade 12×12 ; célula (0,0) no canto superior esquerdo). Observa-se um *hotspot* nítido em torno da célula (3,3) (pico de 0,95), com decaimento suave na vizinhança — padrão espacialmente concentrado, e não difuso.

Fonte: Elaborado pelo autor (2026).

A Tabela 5 resume as principais células de maior desempenho observadas na grade, reportando não apenas a acurácia, mas também sensibilidade, especificidade, precisão e F1-score. Foram priorizadas células que se destacam simultaneamente por alto desempenho e por estarem agrupadas em uma mesma vizinhança espacial da ROI, em vez de pontos isolados.

Tabela 5: Principais hotspots locais na ROI pancreática (grade 12×12), com métricas por célula.

Célula	Acc	Sens	Esp	Prec	F1
(3,3)	0,950	0,958	0,942	0,951	0,954
(3,2)	0,920	0,931	0,909	0,922	0,926
(2,3)	0,910	0,918	0,902	0,912	0,915
(3,4)	0,900	0,908	0,892	0,902	0,905
(2,4)	0,890	0,901	0,879	0,893	0,897
(4,3)	0,890	0,896	0,884	0,891	0,893
(2,2)	0,880	0,889	0,871	0,883	0,886
(4,2)	0,870	0,878	0,862	0,873	0,875
(4,4)	0,860	0,868	0,852	0,862	0,865

A leitura da grade e da tabela mostra que os principais picos de desempenho local não aparecem de forma isolada, mas concentrados em uma mesma vizinhança espacial da ROI. Em particular, as posições (3,3), (3,2), (2,3) e (3,4) formam um agrupamento de alto desempenho, o que é mais informativo do que um único pico disperso. Esse padrão sugere uma **concentração espacial contígua** de sinal discriminativo na região analisada.

Do ponto de vista metodológico, essa organização justifica a inclusão da análise micro-regional: se o desempenho elevado estivesse distribuído aleatoriamente pela grade, a interpretação seria mais compatível com ruído. Aqui, porém, a presença de um pequeno bloco de células vizinhas com métricas altas sustenta a hipótese de um hotspot local. Ainda assim, esse resultado não deve ser tratado como conclusão diagnóstica. Como a malha envolve múltiplas comparações

entre regiões, os hotspots devem ser entendidos como candidatos para verificação posterior com reexecuções, controle entre *folds*, diferentes sementes e correções estatísticas apropriadas.

7.2 Análise angular completa e leitura exploratória da Cruz de Andréas

Além da grade local, a avaliação foi conduzida por setores angulares em passos de 10° , cobrindo toda a circunferência da íris. A Figura 6 apresenta a varredura angular completa, permitindo observar o comportamento global da curva antes de destacar as regiões mais informativas.




Figura 6: Varredura angular (passos de 10°) da acurácia ao longo da circunferência da íris. Destacam-se os picos em 80° (L_split, 92,40%) e em $20^\circ/120^\circ$ (R_split, 90,15%/89,80%), evidenciando resposta não uniforme por setor angular.

Fonte: Elaborado pelo autor (2026).

A Figura 6 indica que o desempenho angular também é não uniforme. No olho esquerdo (L_split), o principal pico ocorre em 80° , com 92,40%, após uma elevação progressiva entre 50° e 80° . No olho direito (R_split), os maiores valores aparecem em 20° (90,15%) e 120° (89,80%), formando dois pontos de destaque em faixas distintas da circunferência.

Interpretativamente, a resposta do classificador varia conforme a posição angular, sustentando uma leitura exploratória de setores mais informativos. A relação com a Cruz de Andréas, porém, deve ser formulada com cautela: os dados mostram **picos angulares localizados**, e não uma validação de mapa iridológico específico — úteis, sobretudo, para identificar setores candidatos a testes confirmatórios posteriores.

7.3 Síntese da avaliação local

Tomadas em conjunto, as duas abordagens apontam para o mesmo padrão: o desempenho discriminativo parece concentrar-se em regiões específicas — um núcleo de células vizinhas na grade 12×12 e picos em setores angulares bem delimitados —, e não distribuído uniformemente pela íris. Isso é consistente com a hipótese de que a informação relevante, quando presente, tende a ser localizada. Por se tratar de etapa exploratória, o valor principal é orientar a investigação futura: indicar **onde** o sinal parece concentrar-se, antes de afirmar **por que** ocorre.

8 Discussão

As análises apresentadas nos Resultados — em especial as Figuras 3 e 4 e as Tabelas 3 e 4 — fornecem a base empírica para a interpretação crítica desenvolvida nesta seção. Em conjunto, os achados indicam que o desempenho observado não é pontual nem restrito a uma única escolha de modelagem; ao contrário, ele se manifesta de forma consistente sob diferentes classificadores,

esquemas de particionamento e condições fotométricas. Além da acurácia, observa-se que Sensibilidade, Especificidade, Precisão e F1 seguem o mesmo padrão geral, reforçando que a leitura não depende de uma única métrica.

De forma geral, os resultados desta etapa são promissores em termos de **desempenho computacional**, mas demandam cautela em termos de **validade científica**. A principal contribuição até o momento é mostrar que, sob um protocolo que controla uma via recorrente de vazamento por identidade (**personBase**), é possível atingir desempenho elevado e relativamente estável em múltiplos classificadores, com destaque para MLP e Regressão Logística. Esse ponto é relevante porque a separação por indivíduo reduz um dos atalhos mais comuns em visão computacional biomédica: a exploração de características idiossincráticas do sujeito (“assinatura” de identidade) em vez de padrões associados ao rótulo clínico de interesse.

8.1 Interpretação do destaque do particionamento **personBase**

O desempenho superior de **personBase** frente a **L_split** e **R_split** sugere que esse cenário é mais favorável ao *pipeline*: a separação por indivíduo mitiga dependências indevidas de identidade e pode reduzir heterogeneidades internas (p. ex., mistura de condições de aquisição) que degradam a separabilidade entre classes.

Ainda assim, trata-se de **consistência interna sob um controle importante**, e não de prova de generalização: diferenças entre particionamentos e *datasets* podem refletir variações na distribuição de aquisição (câmera, iluminação, resolução, pré-processamento), além de amostragem e rotulagem. Permanece necessário testar a estabilidade sob mudanças de distribuição e, quando possível, validar em dados independentes.

8.2 Robustez sob transformações fotométricas

O teste de sensibilidade a variações fotométricas moderadas é favorável: em vez de colapsar sob pequenas alterações de iluminação e tom — o que indicaria dependência de artefatos superficiais da captura —, o desempenho se preserva e, em alguns cenários, aumenta (Figura 4), com destaque para o ganho médio associado ao CLAHE (Tabela 3).

Essa estabilidade é compatível com a hipótese de que o modelo explora **texturas e contrastes locais** que persistem sob perturbações simples. Robustez fotométrica, porém, não implica validade clínica: indica um sinal menos frágil que o associado a uma condição específica de iluminação, mas não estabelece causalidade nem exclui confundidores estruturais (p. ex., padrões sistemáticos introduzidos por segmentação, normalização ou pela composição do conjunto de dados).

8.3 Análises locais e risco de múltiplas comparações

As análises por setores angulares e pela malha 12×12 podem produzir picos locais de desempenho expressivos, por vezes superiores ao desempenho global. No entanto, por sua natureza exploratória, esse tipo de varredura envolve um número elevado de testes em múltiplas regiões. Consequentemente, está sujeito ao fenômeno de **múltiplas comparações**: mesmo na ausência de um sinal real, algumas regiões podem apresentar valores elevados por flutuação estatística.

Dessa forma, a interpretação apropriada nesta etapa é que os picos locais devem ser tratados como **hipóteses espaciais candidatas**, e não como conclusões diagnósticas. O interesse científico desses achados reside na possibilidade de coerência geométrica (por exemplo, recorrências em faixas angulares discutidas na literatura iridológica). Contudo, tal coerência exige

validação por meio de reanálises com controles mais estritos, reexecuções com diferentes sementes, verificação de estabilidade entre *folds*, e aplicação de correções estatísticas apropriadas para múltiplos testes (por exemplo, Bonferroni).

8.4 Tensão com a literatura clínica e implicações para a interpretação

Mesmo diante de desempenhos elevados em modelos de aprendizado de máquina, a literatura clínica clássica permanece amplamente cética quanto à validade diagnóstica da iridologia (Australian Government, 2025; Ernst, 2000; Simon et al., 1979). Essa tensão não invalida os experimentos realizados; ao contrário, ela delimita o problema científico central do projeto: distinguir desempenho genuinamente associado ao fenômeno de interesse de desempenho induzido por artefatos e vieses.

8.5 Síntese dos achados

Os resultados obtidos são tecnicamente relevantes porque:

- atingem desempenho elevado sob um controle importante contra vazamento por identidade (`personBase`);
- apresentam convergência entre diferentes classificadores;
- mantêm desempenho sob transformações fotométricas moderadas, sugerindo menor fragilidade do *pipeline*;
- motivam hipóteses espaciais para análises confirmatórias, desde que acompanhadas de controles para múltiplas comparações.

Ao mesmo tempo, a interpretação permanece deliberadamente cautelosa: métricas altas são um ponto de partida, não um ponto de chegada. Elas abrem a discussão sobre generalização, confundidores, estabilidade e interpretação biológica, alinhando os próximos passos do estudo à transição de consistência interna para evidência mais geral e metodologicamente robusta.

9 Conclusões e perspectivas de trabalhos futuros

9.1 Conclusões

Este trabalho investigou, sob uma perspectiva crítica e reprodutível, em que medida padrões extraídos de imagens de íris permitem discriminar indivíduos com diabetes mellitus tipo 2 (DM2) de controles, confrontando as alegações históricas da iridologia com evidência quantitativa obtida por aprendizado de máquina. A partir de um *pipeline* padronizado — segmentação, normalização em coordenadas polares, extração de *features* de pixel e classificação sob validação cruzada estratificada *person-based* — avaliaram-se cinco classificadores em cenários globais e locais.

Os resultados obtidos evidenciam desempenho global elevado e *consistente* entre modelos, com destaque para o MLP (acurácia de 0,9236), seguido de perto pela Regressão Logística (0,9081) e pelo SVM (0,8824). Esse desempenho manteve-se estável sob perturbações fotométricas moderadas (equalização de histograma, CLAHE e suavização), o que sugere que a informação discriminativa não depende trivialmente de um único ajuste de brilho ou contraste.

É fundamental, contudo, interpretar esses números com rigor e parcimônia. **Alta separabilidade estatística entre as classes não constitui, por si só, validação das hipóteses diagnósticas da iridologia.** O controle *person-based* reduz — mas não elimina completamente — o risco de vazamento de informação (*data leakage*) e de atalhos (*shortcut learning*) associ-

ados a características de aquisição, iluminação ou individuais não relacionadas à fisiopatologia do DM2. As análises locais, por sua vez, permanecem *exploratórias* e demandam correção para múltiplas comparações antes de qualquer afirmação sobre regiões anatomicamente específicas. Assim, a principal contribuição deste trabalho é *metodológica*: um protocolo transparente, audível e conservador para avaliar criticamente alegações da medicina alternativa, evitando tanto a rejeição apriorística quanto o entusiasmo injustificado.

9.2 Trabalhos futuros

9.2.1 Validação estatística e generalização

As próximas etapas priorizam a transição de *consistência interna* para *evidência externa*: (i) reexecução com múltiplas sementes, reportando média $\pm$ desvio-padrão por *fold* e avaliando a estabilidade do *ranking* de modelos; (ii) validação em **bases independentes** e, idealmente, multicêntricas, com protocolos de aquisição distintos, para testar a generalização para fora do conjunto original; (iii) correção para múltiplas comparações (por exemplo, FDR de Benjamini-Hochberg ou Bonferroni) nas análises locais; e (iv) **pré-registro** das hipóteses, com separação explícita entre análises exploratórias e confirmatórias, reforçando a validade estatística das conclusões.

9.2.2 Exploração de arquiteturas modernas de classificação de imagens

Os classificadores empregados neste estudo operam sobre *features* de pixel previamente extraídas e, portanto, não exploram diretamente a estrutura espacial hierárquica das imagens de íris. Uma direção natural é avaliar **arquiteturas profundas** de ponta a ponta, capazes de aprender representações a partir dos próprios pixels:

- **Redes Neurais Convolucionais (CNNs)**: arquiteturas como a ResNet (He et al., 2016) introduzem conexões residuais que viabilizam o treinamento de redes profundas e capturam padrões locais (bordas, texturas, criptas e lacunas da íris) de forma hierárquica, constituindo um *baseline* profundo robusto.
- **Vision Transformers (ViT)**: propostos por Dosovitskiy et al. (2021), os ViTs dividem a imagem em *patches* e aplicam o mecanismo de autoatenção (Vaswani et al., 2017), modelando dependências de longo alcance entre regiões distantes da íris — algo particularmente atraente quando se hipotetiza que eventuais padrões possam estar distribuídos espacialmente. Em contrapartida, ViTs puros são *ávidos por dados* e tendem a exigir grandes volumes de treinamento; variantes **eficientes em dados** como o DeiT (Touvron et al., 2021) e o uso de *transfer learning* a partir de modelos pré-treinados mitigam essa limitação em contextos de dados escassos, como o aqui estudado.
- **Arquiteturas híbridas e hierárquicas**: modelos como o Swin Transformer (Liu et al., 2021) combinam a atenção com janelas locais e hierarquia multiescala, aproximando as vantagens de CNNs e Transformers e mostrando-se eficientes para imagens de alta resolução.
- **Aprendizado auto-supervisionado e *transfer learning***: o pré-treinamento em grandes acervos de imagens (naturais ou oftalmológicas), seguido de *fine-tuning*, tende a melhorar a generalização quando os dados rotulados são limitados.

É imprescindível ressaltar, porém, uma tensão metodológica central: **quanto maior a capacidade do modelo, maior o risco de *shortcut learning*** — isto é, de o classificador explorar artefatos de aquisição ou de identidade em vez de sinais fisiopatológicos legítimos. Portanto, a adoção de arquiteturas mais potentes deve vir acompanhada de *controles ainda mais*

rigorosos: particionamento estritamente *person-based* (e, quando possível, *leave-one-subject-out*), auditoria sistemática de vazamento e, sobretudo, **interpretabilidade**.

Técnicas de explicabilidade como o Grad-CAM (Selvaraju et al., 2017) e a visualização dos mapas de atenção dos Transformers permitem verificar se o modelo concentra a decisão em regiões anatomicamente plausíveis da íris ou em artefatos espúrios (bordas, reflexos, pálpebras). A Figura 7 ilustra esquematicamente esse tipo de mapeamento de ativação de classe, que deverá integrar a etapa final de validação, articulando desempenho preditivo e escrutínio crítico das alegações iridológicas.




Figura 7: Esquema de mapeamento de ativação de classe (CAM/Grad-CAM) em uma rede convolucional: as ativações das últimas camadas convolucionais são combinadas para produzir um mapa de calor que evidencia as regiões mais influentes na decisão do modelo. Em trabalhos futuros, essa interpretabilidade será empregada para auditar se arquiteturas profundas (CNNs e ViTs) atendem a regiões anatomicamente plausíveis da íris, em vez de artefatos de aquisição.

Fonte: adaptado de Selvaraju et al. (2017).

Referências

- Australian Government Department of Health and Aged Care. Iridology evidence evaluation: Appendices A–H (final), 2025. Disponível em: https://www.health.gov.au/sites/default/files/2025-03/02_iridology_appendices_a-h_final.pdf
- Deck, J. *Iris Diagnosis and Treatment*. Thorsons Publishers, 1981.
- Dosovitskiy, A.; Beyer, L.; Kolesnikov, A.; Weissenborn, D.; Zhai, X.; Unterthiner, T.; Dehghani, M.; Minderer, M.; Heigold, G.; Gelly, S.; Uszkoreit, J.; Houlsby, N. An image is worth 16x16 words: Transformers for image recognition at scale. In: *International Conference on Learning Representations (ICLR)*, 2021.
- Ernst, E. Iridology: a systematic review. *Archives of Ophthalmology*, 118(1):120–121, 2000.
- Gonzalez, R. C.; Woods, R. E. *Digital Image Processing*. 4. ed. Pearson, 2018.
- Haralick, R. M.; Shanmugam, K.; Dinstein, I. Textural features for image classification. *IEEE Transactions on Systems, Man, and Cybernetics*, v. 3, n. 6, p. 610–621, 1973. doi: 10.1109/TSMC.1973.4309314.
- He, K.; Zhang, X.; Ren, S.; Sun, J. Deep residual learning for image recognition. In: *IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 2016, p. 770–778. doi: 10.1109/CVPR.2016.90.
- Jensen, B. *Science and Practice of Iridology*. Bernard Jensen International, 1982.
- Knipschild, P. Looking for gall bladder disease in the patient’s iris. *BMJ*, 297(6663):1578–1581, 1988.
- Liu, Z.; Lin, Y.; Cao, Y.; Hu, H.; Wei, Y.; Zhang, Z.; Lin, S.; Guo, B. Swin Transformer: Hierarchical vision transformer using shifted windows. In: *IEEE/CVF International Conference on Computer Vision (ICCV)*, 2021, p. 10012–10022.
- Münstedt, K., El-Safadi, S., Brück, F., Zygmunt, M., Hackethal, A., Tinneberg, H.-R. Can iridology detect susceptibility to cancer? A prospective case-controlled study. *Journal of Alternative and Complementary Medicine*, 11(3):515–519, 2005.
- Ojala, T.; Pietikäinen, M.; Mäenpää, T. Multiresolution gray-scale and rotation invariant texture classification with local binary patterns. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, v. 24, n. 7, p. 971–987, 2002. doi: 10.1109/TPAMI.2002.1017623.
- OpenCV. Histogram Equalization. *OpenCV Documentation*, versão 4.x, acesso em 27 fev. 2026. Disponível em: https://docs.opencv.org/4.x/d4/d1b/tutorial_histogram_equalization.html
- OpenCV. Smoothing Images. *OpenCV Documentation*, versão 4.x, acesso em 27 fev. 2026. Disponível em: https://docs.opencv.org/4.x/d4/d13/tutorial_py_filtering.html
- Samant, P., Agarwal, R. Machine learning techniques for medical diagnosis of diabetes using iris images. *Computer Methods and Programs in Biomedicine*, 157:121–128, 2018.
- Selvaraju, R. R.; Cogswell, M.; Das, A.; Vedantam, R.; Parikh, D.; Batra, D. Grad-CAM: Visual explanations from deep networks via gradient-based localization. In: *IEEE International Conference on Computer Vision (ICCV)*, 2017, p. 618–626. doi: 10.1109/ICCV.2017.74.
- Simon, A., Worthen, D. M., Mitas, J. A. An evaluation of iridology. *JAMA*, 242(13):1385–1389, 1979.

- Touvron, H.; Cord, M.; Douze, M.; Massa, F.; Sablayrolles, A.; Jégou, H. Training data-efficient image transformers & distillation through attention. In: *International Conference on Machine Learning (ICML)*, 2021, p. 10347–10357.
- Vaswani, A.; Shazeer, N.; Parmar, N.; Uszkoreit, J.; Jones, L.; Gomez, A. N.; Kaiser, Ł.; Polosukhin, I. Attention is all you need. In: *Advances in Neural Information Processing Systems (NeurIPS)*, 2017, p. 5998–6008.
- World Health Organization (WHO). Diabetes (Fact sheet), 2024. Disponível em: <https://www.who.int/news-room/fact-sheets/detail/diabetes>
- Zech, J. R., Badgeley, M. A., Liu, M., Costa, A. B., Titano, J. J., Oermann, E. K. Variable generalization performance of a deep learning model to detect pneumonia in chest radiographs: A cross-sectional study. *PLOS Medicine*, 15(11):e1002683, 2018.
- Zuiderveld, K. J. Contrast Limited Adaptive Histogram Equalization. In: Heckbert, P. S. (ed.). *Graphics Gems*. Elsevier, 1994, p. 474–485.